ระบบตรวจจับและประเมินความรุนแรงของสนิมบนโครงสร้างเหล็กด้วยเทคนิคการเรียนรู้เชิงลึก

RustVision AI: Rust Detection and Severity Assessment System on Steel Structures using Deep Learning Techniques

นายอานนท์ รวยเงิน

65122250062

โครงงานนี้เป็นส่วนหนึ่งของการศึกษาตามหลักสูตรปริญญาวิทยาศาสตรบัณฑิต

สาขาวิทยาการคอมพิวเตอร์ คณะวิทยาศาสตร์และเทคโนโลยี

มหาวิทยาลัยราชภัฏสวนสุนันทา

ปีการศึกษา 2567

บทที่ 1
บทนำ

1. ที่มาและความสำคัญของปัญหา

โครงสร้างพื้นฐานทางวิศวกรรมไม่ว่าจะเป็น สะพาน อาคารโรงงาน หรือเครื่องจักรในภาคอุตสาหกรรม ล้วนพึ่งพาโลหะเป็นองค์ประกอบหลักในการรับน้ำหนักและความแข็งแรงทนทาน อย่างไรก็ตาม ปัญหาที่หลีกเลี่ยงไม่ได้เมื่อโลหะทำปฏิกิริยากับสภาพแวดล้อมคือ "การกัดกร่อน" หรือการเกิดสนิม (Rust) ซึ่งเป็นกระบวนการทางธรรมชาติที่ค่อยๆ บั่นทอนความสมบูรณ์ของโครงสร้าง การตรวจสอบสภาพผิวโลหะอย่างสม่ำเสมอจึงเป็นมาตรการสำคัญในการบำรุงรักษาเชิงป้องกัน (Preventive Maintenance) เพื่อความปลอดภัยในชีวิตและทรัพย์สิน รวมถึงการวางแผนซ่อมบำรุงก่อนที่ความเสียหายจะลุกลามจนเกินแก้ไข

ในทางปฏิบัติ การประเมินความรุนแรงของสนิมจำเป็นต้องมีมาตรฐานกลางเพื่อความชัดเจนในการสื่อสาร โดยมาตรฐานที่ได้รับการยอมรับในระดับสากลคือ ASTM D610 ซึ่งใช้ในการจัดลำดับเกรดความเสียหายของผิวเคลือบโลหะ โดยแบ่งระดับคะแนนจาก 10 (สมบูรณ์) ไปจนถึง 0 (วิกฤต) ตามสัดส่วนพื้นที่ที่เกิดสนิม การประเมินที่ถูกต้องแม่นยำตามมาตรฐานนี้มีความสำคัญอย่างยิ่ง เพราะส่งผลโดยตรงต่อการคำนวณดัชนีความเสี่ยงทางโครงสร้าง (Structural Risk Index) และการตัดสินใจของวิศวกรว่าจะต้องดำเนินการซ่อมแซมเร่งด่วนเพียงใด

ปัจจุบันกระบวนการตรวจสอบสนิมส่วนใหญ่ยังคงพึ่งพาการใช้สายตามนุษย์ (Visual Inspection) เป็นหลัก ซึ่งก่อให้เกิดปัญหาสำคัญหลายประการ ประการแรกคือ ความไม่แน่นอน (Subjectivity) เนื่องจากผู้ตรวจสอบแต่ละคนอาจประเมินพื้นที่ความเสียหายและให้ระดับคะแนนที่แตกต่างกันตามดุลยพินิจและประสบการณ์ ส่งผลให้ข้อมูลขาดความเที่ยงตรง ประการที่สองคือ ข้อจำกัดด้านสภาพแวดล้อม เช่น แสงเงาที่ตกกระทบบนผิวโลหะที่ทำให้การมองเห็นคลาดเคลื่อน หรือความเสี่ยงในการเข้าถึงพื้นที่อันตราย และประการสุดท้ายคือ ความล่าช้า ในการทำรายงานผลการตรวจสอบ ซึ่งอาจไม่ทันต่อสถานการณ์หากโครงสร้างมีความเสียหายรุนแรง

เพื่อแก้ไขปัญหาดังกล่าว จึงได้พัฒนา "RustVision AI" ซึ่งเป็นโครงงานพัฒนาระบบตรวจสอบสุขภาพโครงสร้างอัจฉริยะ เพื่อความสะดวกในการใช้งานภาคสนาม โดยระบบนี้ได้ประยุกต์ใช้เทคโนโลยีปัญญาประดิษฐ์ Computer Vision ด้วยโมเดล YOLO26-Seg (Instance Segmentation) มาช่วยในการจำแนกและระบุตำแหน่งของสนิมในระดับพิกเซล ซึ่งช่วยให้สามารถคำนวณเปอร์เซ็นต์ความเสียหายและระบุเกรดตามมาตรฐาน ASTM D610 ได้อย่างแม่นยำและเป็นกลาง พร้อมทั้งสร้างรายงานการตรวจสอบได้ทันที ซึ่งช่วยลดความผิดพลาดจากดุลยพินิจของมนุษย์และเพิ่มประสิทธิภาพในการประเมินความเสี่ยงโครงสร้างได้อย่างเป็นรูปธรรม

2. วัตถุประสงค์ของการวิจัย

1. เพื่อพัฒนา Desktop Application สำหรับตรวจจับสนิมด้วย AI เพื่อสร้างซอฟต์แวร์ที่ทำงานแบบ Offline โดยประยุกต์ใช้เทคโนโลยี Computer Vision และโมเดล YOLO26-Seg ในการระบุตำแหน่งและขอบเขตของสนิมบนภาพถ่ายได้อย่างอัตโนมัติ
2. เพื่อประเมินความรุนแรงตามมาตรฐาน ASTM D610 เพื่อพัฒนาระบบคำนวณเปอร์เซ็นต์พื้นที่สนิมและจัดลำดับเกรดความเสียหายตามมาตรฐาน ASTM D610 พร้อมทั้งคำนวณค่า Structural Risk Index เพื่อใช้เป็นข้อมูลสนับสนุนการตัดสินใจทางวิศวกรรม
3. เพื่อเพิ่มประสิทธิภาพระบบ Reporting และการวางแผน Maintenance เพื่อสร้างเครื่องมือที่สามารถ Generate PDF Report ได้ทันทีหลังการวิเคราะห์ ช่วยลดระยะเวลาในการทำเอกสารและให้ข้อมูลที่แม่นยำสำหรับการวางแผนซ่อมบำรุง

3. ขอบเขตของการทำวิจัย

3.1. ขอบเขตด้านเนื้อหา (Content Scope)

1. ศึกษาและประยุกต์ใช้เทคนิคการประมวลผลภาพดิจิทัล (Digital Image Processing) ด้วยอัลกอริทึม CLAHE (Contrast Limited Adaptive Histogram Equalization) เพื่อปรับปรุงคุณภาพของภาพถ่ายและลดผลกระทบจากแสงเงาบนผิวโลหะก่อนนำเข้าสู่กระบวนการวิเคราะห์
2. ศึกษาและพัฒนาโมเดลปัญญาประดิษฐ์ประเภท Deep Learning สถาปัตยกรรม YOLO26-Seg (Instance Segmentation) เพื่อใช้ในการตรวจจับ จำแนก และระบุขอบเขตของสนิม (Rust Segmentation) ในระดับพิกเซล
3. พัฒนากระบวนการประเมินความเสียหายโดยอ้างอิงมาตรฐานสากล ASTM D610 เพื่อจัดลำดับเกรดความรุนแรงของสนิมจากระดับ 0 ถึง 10 และคำนวณดัชนีความเสี่ยงทางโครงสร้าง (Structural Risk Index) จากสัดส่วนพื้นที่ความเสียหายและความหนาแน่นของการกระจายตัว

3.2. ขอบเขตด้านเครื่องมือและเทคโนโลยี (Technical Scope)

1. ภาษาที่ใช้ในการพัฒนา: Python 3.x สำหรับการประมวลผลหลักและการทำงานของโมเดล
2. เครื่องมือสำหรับส่วนติดต่อผู้ใช้งาน (GUI): พัฒนาด้วยเฟรมเวิร์ก Flet ในรูปแบบ Desktop Application ที่รองรับการทำงานแบบ Offline
3. ไลบรารีที่เกี่ยวข้อง:

- Ultralytics YOLO: สำหรับการสร้างและใช้งานโมเดล AI
- OpenCV & NumPy: สำหรับการประมวลผลภาพและคำนวณทางคณิตศาสตร์
- FPDF: สำหรับการสร้างรายงานผลการตรวจสอบในรูปแบบไฟล์ PDF

3.3. ขอบเขตด้านระบบและการใช้งาน (Functional Scope)

1. ระบบรองรับการนำเข้าข้อมูลรูปภาพ (Input) ของโครงสร้างโลหะผ่านการอัปโหลดไฟล์จากเครื่องคอมพิวเตอร์ส่วนบุคคล
2. ระบบสามารถแสดงผลลัพธ์การวิเคราะห์ในรูปแบบภาพซ้อนทับ (Overlay Masks), แผนภาพความร้อน (Heatmaps) และตารางเปรียบเทียบค่าความเสียหาย
3. ระบบมีฟังก์ชันการบันทึกประวัติการวิเคราะห์ (History Log) จำนวน 20 รายการล่าสุด และสามารถออกรายงานสรุปผล (Audit Report) ที่ประกอบด้วยรูปภาพเปรียบเทียบและคำแนะนำทางวิศวกรรมได้

4. ประโยชน์ที่คาดว่าจะได้รับ

1. ได้ต้นแบบระบบตรวจสอบสนิมอัจฉริยะที่มีประสิทธิภาพ ได้ซอฟต์แวร์ต้นแบบ (Prototype) ที่สามารถตรวจจับและจำแนกสนิมบนโครงสร้างโลหะได้อย่างแม่นยำด้วยเทคโนโลยีปัญญาประดิษฐ์ (YOLO26-Seg) ซึ่งสามารถนำไปประยุกต์ใช้ในงานตรวจสอบความแข็งแรงของโครงสร้างอาคาร สะพาน และโรงงานอุตสาหกรรมได้จริง
2. ลดความผิดพลาดและเพิ่มมาตรฐานในการตรวจสอบ ช่วยลดความคลาดเคลื่อนที่เกิดจากดุลยพินิจของผู้ตรวจสอบ (Human Error/Subjectivity) โดยใช้เกณฑ์การตัดสินใจตามมาตรฐานสากล ASTM D610 ทำให้ผลการประเมินมีความเที่ยงตรง เป็นกลาง และสามารถเปรียบเทียบผลการตรวจสอบย้อนหลังได้อย่างเป็นระบบ
3. เพิ่มความรวดเร็วในการจัดทำรายงานและวางแผนซ่อมบำรุง ลดระยะเวลาและขั้นตอนการทำงานของวิศวกรด้วยระบบสร้างรายงานผลการตรวจสอบ (Audit Report) แบบอัตโนมัติ ทำให้สามารถนำข้อมูลดัชนีความเสี่ยง (Structural Risk Index) ไปใช้วางแผนการซ่อมบำรุงเชิงป้องกันได้ทันท่วงที ก่อนที่จะเกิดความเสียหายรุนแรง
4. สามารถใช้งานในพื้นที่จำกัดหรือห่างไกลได้ เนื่องจากระบบถูกออกแบบให้เป็น Desktop Application ที่ทำงานแบบ Offline จึงสามารถนำไปติดตั้งและใช้งานในพื้นที่หน้างานที่ไม่มีสัญญาณอินเทอร์เน็ตได้ ซึ่งช่วยเพิ่มความยืดหยุ่นในการปฏิบัติงานภาคสนาม

5. นิยามศัพท์เฉพาะ

1. RustVision AI หมายถึง ชื่อเฉพาะของโปรแกรมคอมพิวเตอร์ (Desktop Application) ที่ผู้จัดทำพัฒนาขึ้นเพื่อใช้ในการตรวจสอบและวิเคราะห์สนิมบนโครงสร้างโลหะแบบ Offline โดยประมวลผลผ่านโมเดลปัญญาประดิษฐ์และการประมวลผลภาพ
2. Instance Segmentation หมายถึง เทคนิคทาง Computer Vision ที่ใช้ในการตรวจจับวัตถุโดยไม่เพียงแค่ระบุตำแหน่ง (Bounding Box) แต่ยังสามารถจำแนกขอบเขตของวัตถุในระดับพิกเซล (Masks) ได้ ในงานวิจัยนี้ใช้โมเดล YOLO26-Seg เพื่อระบุรูปร่างที่แท้จริงของรอยสนิมบนภาพถ่าย
3. ASTM D610 หมายถึง มาตรฐานสากลสำหรับการประเมินระดับการเกิดสนิมบนผิวเหล็กที่ทาสี (Standard Practice for Evaluating Degree of Rusting on Painted Steel Surfaces) โดยมีการจัดลำดับความรุนแรงเป็นเกรดคะแนนตั้งแต่ 10 (สภาพสมบูรณ์) ไปจนถึง 0 (สภาพเสียหายวิกฤต) ตามสัดส่วนพื้นที่ที่ถูกกัดกร่อน
4. Structural Risk Index หมายถึง ดัชนีความเสี่ยงทางโครงสร้าง ซึ่งเป็นค่าดัชนีชี้วัด (Composite Score) ที่มีค่าตั้งแต่ 0 ถึง 100 ที่ระบบคำนวณขึ้นจากการนำค่าเปอร์เซ็นต์พื้นที่การเกิดสนิม (Coverage Percentage) และค่าความหนาแน่นของการกระจายตัว (Region Density Penalty) มาประมวลผลร่วมกัน เพื่อใช้บ่งชี้ระดับความเร่งด่วนในการซ่อมบำรุง
5. CLAHE (Contrast Limited Adaptive Histogram Equalization) หมายถึง อัลกอริทึมการประมวลผลภาพที่ช่วยปรับปรุงความคมชัดและความเปรียบต่าง (Contrast) ของภาพแบบปรับตัวตามพื้นที่ย่อย เพื่อลดผลกระทบจากแสงเงาหรือแสงสะท้อนบนผิวโลหะ ทำให้โมเดลสามารถตรวจจับสนิมได้แม่นยำยิ่งขึ้น

บทที่ 2
เอกสารและงานวิจัยที่เกี่ยวข้อง

การพัฒนาระบบตรวจจับและประเมินระดับความรุนแรงของสนิมบนโครงสร้างโลหะด้วยปัญญาประดิษฐ์ (RustVision AI) ซึ่งครอบคลุมถึงการใช้เทคโนโลยีการประมวลผลภาพ (Image Processing) ร่วมกับการเรียนรู้เชิงลึก (Deep Learning) เพื่อเพิ่มประสิทธิภาพในการตรวจสอบความปลอดภัยทางวิศวกรรม การศึกษาในบทนี้จะช่วยให้เห็นถึงหลักการทฤษฎีและแนวทางปฏิบัติที่นำมาประยุกต์ใช้ในการสร้างซอฟต์แวร์ที่สามารถทำงานแบบ Offline และมีความแม่นยำตามมาตรฐานสากล ผู้จัดทำได้ศึกษาค้นคว้าเอกสารและงานวิจัยที่เกี่ยวข้องตามหัวข้อต่อไปนี้

2.1. ความรู้เกี่ยวกับสนิมและการตรวจสอบมาตรฐาน ASTM
- 2.1.1.ทฤษฎีการเกิดการกัดกร่อนของโลหะ (Corrosion Theory)
- 2.1.2.ความสำคัญของการบำรุงรักษาโครงสร้าง (Structural Health Monitoring)
- 2.1.3.มาตรฐาน ASTM D610 สำหรับการประเมินระดับสนิม
- 2.1.4.เกณฑ์การแบ่งระดับความรุนแรง (Degree of Rusting)
- 2.1.5.การคำนวณดัชนีความเสี่ยงทางโครงสร้าง (Structural Risk Index)

2.2. แนวคิดเกี่ยวกับปัญญาประดิษฐ์และการเรียนรู้เชิงลึก (Deep Learning)
- 2.2.1.ความหมายและหลักการทำงานของ Computer Vision
- 2.2.2.สถาปัตยกรรมโครงข่ายประสาทเทียมแบบคอนโวลูชัน (CNN)
- 2.2.3.อัลกอริทึม YOLO (You Only Look Once) สำหรับการตรวจจับวัตถุ
- 2.2.4.เทคนิค Instance Segmentation กับการจำแนกพื้นที่ระดับพิกเซล
- 2.2.5.ความแตกต่างระหว่าง Object Detection และ Instance Segmentation
- 2.2.6.สถาปัตยกรรมโมเดล YOLO26-Seg และประสิทธิภาพการทำงาน

2.3. ทฤษฎีการประมวลผลภาพดิจิทัล (Digital Image Processing)
- 2.3.1.หลักการปรับปรุงคุณภาพของภาพ (Image Enhancement)
- 2.3.2.เทคนิค Histogram Equalization
- 2.3.3.อัลกอริทึม CLAHE (Contrast Limited Adaptive Histogram Equalization) เพื่อลดผลกระทบจากแสงเงา
- 2.3.4.การแปลงปริภูมิสี (Color Space Conversion)
- 2.3.5.การคำนวณสัดส่วนพื้นที่จากพิกเซลภาพ (Pixel-to-Area Calculation)

2.4. เครื่องมือและเทคโนโลยีในการพัฒนาระบบ

2.4.1.ภาษา Python และไลบรารีสำหรับงาน Data Science (NumPy, Pandas)

2.4.2.ไลบรารี OpenCV สำหรับการจัดการรูปภาพ

2.4.3.Framework Flet สำหรับการพัฒนา Desktop Application

2.4.4.ไลบรารี FPDF สำหรับการสร้างรายงานอัตโนมัติ

2.4.5.ระบบจัดการฐานข้อมูลและสภาพแวดล้อมจำลอง (Database & Containerization)

2.5. งานวิจัยที่เกี่ยวข้อง

2.5.1.งานวิจัยในประเทศ

2.5.2.งานวิจัยต่างประเทศ

2.1. ความรู้เกี่ยวกับสนิมและการตรวจสอบมาตรฐาน ASTM

2.1.1. ทฤษฎีการเกิดการกัดกร่อนของโลหะ (Corrosion Theory)

การกัดกร่อน (Corrosion) คือกระบวนการเสื่อมสภาพของวัสดุโลหะที่เกิดจากปฏิกิริยาทางเคมีหรือไฟฟ้าเคมี (Electrochemical Reaction) กับสภาพแวดล้อม ส่งผลให้โลหะสูญเสียคุณสมบัติเดิมและเปลี่ยนสภาพไปเป็นสารประกอบออกไซด์ที่มีความเสถียรมากขึ้น ซึ่งในกรณีของเหล็ก (Iron) สารประกอบที่ได้คือ "สนิม" (Rust) หรือ Hydrated Iron(III) Oxide

กลไกการเกิดสนิมสามารถอธิบายได้ด้วยทฤษฎีเซลล์กัลวานิก (Galvanic Cell) ซึ่งประกอบด้วยองค์ประกอบสำคัญ 4 ประการ ที่ต้องเกิดขึ้นพร้อมกันจึงจะเกิดกระบวนการกัดกร่อนได้อย่างสมบูรณ์ ได้แก่

1. ขั้วแอโนด (Anode): บริเวณที่โลหะเกิดการจ่ายอิเล็กตรอน (Oxidation) ทำให้เนื้อโลหะถูกกัดกร่อนและละลายออกมาเป็นไอออน $Fe \rightarrow Fe^{2+} + 2e^{-}$
2. ขั้วแคโทด (Cathode): บริเวณที่เกิดการรับอิเล็กตรอน (Reduction) ซึ่งมักเกิดปฏิกิริยากับออกซิเจนและความชื้นในอากาศ
3. อิเล็กโทรไลต์ (Electrolyte): สารละลายหรือความชื้นที่เป็นตัวกลางในการนำประจุไฟฟ้า เช่น น้ำฝน หรือความชื้นสัมพัทธ์ในอากาศ
4. วงจรโลหะ (Metallic Path): ทางเดินของอิเล็กตรอนที่เชื่อมต่อระหว่างแอโนดและแคโทด (ซึ่งก็คือตัวเนื้อเหล็กเอง)

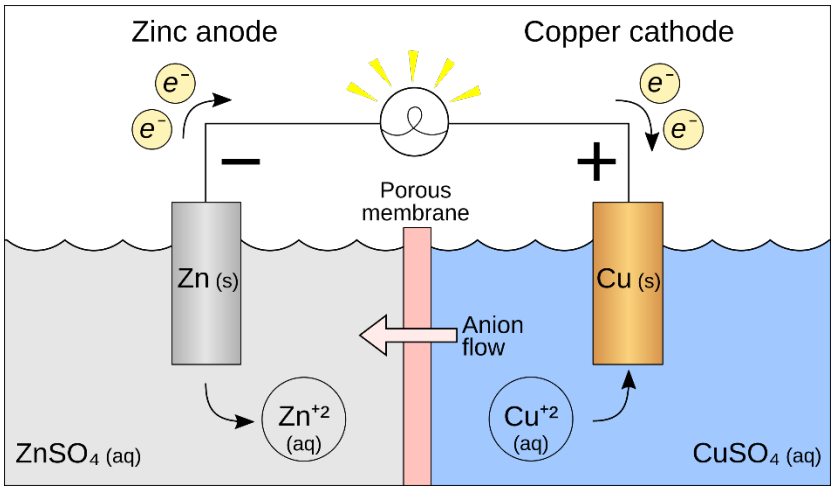

ภาพที่ 2.1.1 แสดงกลไกการเกิดสนิมแบบกัลวานิก

ปฏิกิริยารวมของการเกิดสนิมสามารถเขียนเป็นสมการทางเคมีได้ดังนี้

$$4Fe + 3O_2 + 2H_2O \rightarrow 2Fe_2O_3 \cdot H_2O \text{ (Rust)}$$

ผลลัพธ์จากปฏิกิริยานี้คือคราบของแข็งที่มีสีน้ำตาลแดง (Reddish-brown) เกาะอยู่บนผิวหน้าของโลหะ ซึ่งลักษณะทางกายภาพที่เปลี่ยนแปลงไปอย่างชัดเจนนี้ (Color and Texture Transformation) เป็นคุณลักษณะสำคัญ (Feature) ที่ระบบ Computer Vision นำมาใช้ในการจำแนกความแตกต่างระหว่างพื้นที่ที่เป็นโลหะปกติและพื้นที่ที่เป็นสนิมผ่านกระบวนการ Image Processing และ Deep Learning

2.1.2. ความสำคัญของการบำรุงรักษาโครงสร้าง (Structural Health Monitoring)

การติดตามตรวจสอบสุขภาพโครงสร้าง หรือ Structural Health Monitoring (SHM) คือกระบวนการตรวจวัดและวิเคราะห์ข้อมูลทางกายภาพของโครงสร้างทางวิศวกรรม (เช่น อาคาร สะพาน ท่อส่งก๊าซ หรือเครื่องจักรขนาดใหญ่) อย่างต่อเนื่องหรือเป็นระยะ เพื่อระบุความเปลี่ยนแปลงที่บ่งชี้ถึงความเสียหาย (Damage Detection) และประเมินอายุการใช้งานที่เหลืออยู่ (Remaining Useful Life) โดยมีวัตถุประสงค์หลักและรายละเอียดสำคัญดังนี้

1. ความปลอดภัยต่อชีวิตและทรัพย์สิน (Public Safety and Asset Security) โครงสร้างที่ใช้งานมาเป็นระยะเวลานานย่อมเกิดการเสื่อมสภาพ (Deterioration) โดยเฉพาะจาก "สนิม" หรือการกัดกร่อน (Corrosion) ซึ่งเป็นปัจจัยหลักที่ทำให้พื้นที่หน้าตัดของเหล็ก (Cross-sectional Area) ลดลง ส่งผลให้ความสามารถในการรับน้ำหนัก (Load-bearing Capacity) ของโครงสร้างลดต่ำกว่าค่าที่ออกแบบไว้ หากไม่มีระบบการตรวจสอบที่มีประสิทธิภาพ ความเสียหายนี้อาจสะสมจนถึงจุดวิกฤตและนำไปสู่การวิบัติ (Structural Failure) หรือการพังถล่มโดยไม่คาดฝัน ซึ่งก่อให้เกิดความสูญเสียต่อชีวิตและทรัพย์สินมหาศาล
2. การเปลี่ยนผ่านสู่การบำรุงรักษาตามสภาพ (Condition-Based Maintenance) ในอดีตการดูแลรักษาโครงสร้างมักเป็นรูปแบบ Breakdown Maintenance (ซ่อมเมื่อพัง) หรือ Time-Based Maintenance (ซ่อมตามรอบเวลา) ซึ่งอาจไม่มีประสิทธิภาพเพียงพอหรือสิ้นเปลืองงบประมาณโดยไม่จำเป็น การนำกระบวนการ SHM มาใช้ ช่วยยกระดับไปสู่ Condition-Based Maintenance (CBM) คือการซ่อมบำรุงเมื่อ "ตรวจพบความผิดปกติจริง" ระบบ RustVision AI ที่ผู้จัดทำพัฒนาขึ้น จัดอยู่ในกลุ่มเครื่องมือสนับสนุน CBM นี้ โดยทำหน้าที่ตรวจจับสนิมในระยะเริ่มต้นและประเมินระดับความรุนแรงตามข้อเท็จจริง เพื่อให้วิศวกรสามารถตัดสินใจซ่อมแซมได้ตรงจุดและทันเวลา

3. การลดต้นทุนในระยะยาว (Long-term Cost Reduction) การตรวจพบความเสียหายตั้งแต่ระยะเริ่มต้น (Early Detection) มีค่าใช้จ่ายในการซ่อมแซมต่ำกว่าการปล่อยให้ความเสียหายลุกลามมาก ตัวอย่างเช่น การขัดและทาสีกันสนิมใหม่ในจุดเล็กๆ ย่อมประหยัดกว่าการต้องรื้อถอนและเปลี่ยนชิ้นส่วนโครงสร้างเหล็กทั้งท่อน การมีระบบตรวจสอบที่แม่นยำจึงช่วยให้องค์กรสามารถบริหารจัดการงบประมาณการซ่อมบำรุงได้อย่างมีประสิทธิภาพสูงสุด
4. การยืดอายุการใช้งานของโครงสร้าง (Life Extension) ข้อมูลจากการตรวจสอบ SHM ช่วยให้วิศวกรสามารถพยากรณ์แนวโน้มการเสื่อมสภาพและวางแผนเสริมความแข็งแรง (Retrofitting) ได้อย่างเหมาะสม ซึ่งช่วยยืดอายุการใช้งานของโครงสร้างให้ยาวนานขึ้นกว่าที่ออกแบบไว้ ลดความจำเป็นในการก่อสร้างใหม่ และส่งเสริมความยั่งยืนในการใช้ทรัพยากร

สรุปได้ว่า การบำรุงรักษาโครงสร้างไม่ได้เป็นเพียงแค่การซ่อมแซม แต่เป็นการบริหารความเสี่ยงทางวิศวกรรม ซึ่งระบบตรวจจับสนิมอัตโนมัติที่พัฒนาขึ้นในงานวิจัยนี้ จะเข้ามาเป็นกลไกสำคัญในการเพิ่มความรวดเร็วและความแม่นยำให้กับกระบวนการดังกล่าว

2.1.3. มาตรฐาน ASTM D610 สำหรับการประเมินระดับสนิม

มาตรฐาน ASTM D610 (Standard Practice for Evaluating Degree of Rusting on Painted Steel Surfaces) เป็นมาตรฐานสากลที่กำหนดโดย ASTM International (American Society for Testing and Materials) เพื่อใช้เป็นเกณฑ์กลางในการประเมินระดับความเสื่อมสภาพของผิวเคลือบโลหะหรือสีกันสนิม โดยพิจารณาจาก "ปริมาณพื้นที่" ที่เกิดสนิมขึ้นบนพื้นผิวตัวอย่าง

หลักการสำคัญของมาตรฐานนี้คือการแปลง "ข้อมูลเชิงคุณภาพ" (ภาพที่ตามองเห็น) ให้กลายเป็น "ข้อมูลเชิงปริมาณ" (ตัวเลขเกรด 0-10) เพื่อให้วิศวกรสามารถตัดสินใจวางแผนซ่อมบำรุงได้อย่างถูกต้อง โดยมีรายละเอียดดังนี้

1. ระบบการให้คะแนน (Rating System) ระบบการให้คะแนนของ ASTM D610 จะเป็นแบบแปรผกผัน (Inverse Scale) กล่าวคือ คะแนนจะลดลงเมื่อปริมาณสนิมเพิ่มขึ้น โดยมีสเกลตั้งแต่ 10 ถึง 0 ดังนี้
   - เกรด 10: สภาพสมบูรณ์ พื้นผิวไม่มีสนิม หรือมีสนิมน้อยกว่า 0.01%
   - เกรด 6: จุดเริ่มวิกฤตที่มักใช้เป็นเกณฑ์ในการตัดสินใจเริ่มซ่อมบำรุง (Maintenance Threshold) มีพื้นที่สนิมประมาณ 1%
   - เกรด 0: สภาพเสียหายรุนแรง มีพื้นที่สนิมมากกว่า 50% ของพื้นที่ทั้งหมด
2. ตารางเกณฑ์การประเมิน (Evaluation Criteria Table) ในโครงการ RustVision AI ได้นำเกณฑ์มาตรฐานนี้มาเขียนเป็นเงื่อนไข (Logic) ในฟังก์ชัน get_astm_rating ภายในโมดูล

utils.py เพื่อให้ระบบสามารถคำนวณเกรดได้อัตโนมัติจากการนับจำนวนพิกเซล โดยมีรายละเอียดการแบ่งเกรดตามเปอร์เซ็นต์พื้นที่เสียหายดังตารางต่อไปนี้

เกรด (Rust Grade)	พื้นที่การเกิดสนิม (Rust Area %)	คำอธิบายสภาพ (Description)
10	$\leq 0.01\%$	ไม่พบสนิม หรือพบน้อยมากจนแทบมองไม่เห็น
9	$> 0.01\% - 0.03\%$	สนิมเกิดขึ้นเล็กน้อยมาก (Minute)
8	$> 0.03\% - 0.1\%$	สนิมเกิดขึ้นเล็กน้อย (Few)
7	$> 0.1\% - 0.3\%$	สนิมเริ่มกระจายตัว (Scattered)
6	$> 0.3\% - 1.0\%$	สนิมปรากฏชัดเจน เป็นเกณฑ์เริ่มพิจารณาซ่อมแซม
5	$> 1.0\% - 3.0\%$	สนิมลุกลามค่อนข้างมาก
4	$> 3.0\% - 10.0\%$	สนิมกินพื้นที่มาก (Severe)
3	$> 10.0\% - 16.0\%$	เสียหายรุนแรงประมาณ 1 ใน 6 ของพื้นที่
2	$> 16.0\% - 33.0\%$	เสียหายรุนแรงประมาณ 1 ใน 3 ของพื้นที่
1	$> 33.0\% - 50.0\%$	เสียหายรุนแรงเกือบครึ่งหนึ่ง
0	$> 50.0\%$	เสียหายวิกฤต เกินกว่าครึ่งหนึ่งของพื้นที่ (Critical)

3. ความท้าทายและการแก้ปัญหาด้วย AI ในทางปฏิบัติแบบดั้งเดิม การประเมินตามมาตรฐาน ASTM D610 จะใช้วิธี Visual Comparison คือการนำภาพถ่ายมาตรฐาน (Standard Photographs) มาเทียบกับผิวโลหะจริงด้วยสายตา ซึ่งมักเกิดความคลาดเคลื่อน (Human Error) โดยเฉพาะในช่วงรอยต่อของเกรด (เช่น ระหว่างเกรด 5 และ 6)

ระบบ RustVision AI เข้ามาแก้ปัญหานี้โดยใช้โมเดล Instance Segmentation (YOLO26-Seg) ซึ่งสามารถจำแนกพื้นที่สนิมได้ในระดับพิกเซล (Pixel-level) ระบบจะคำนวณหาค่าเปอร์เซ็นต์ที่แท้จริงจากสูตร

$$\text{Percentage} = \frac{\text{Total Rust Pixels}}{\text{Total Image Pixels}} \times 100$$

จากนั้นนำค่าที่ได้ไปเทียบกับตารางข้างต้น ทำให้ผลลัพธ์ที่ได้มีความแม่นยำ เป็นกลาง และสอดคล้องตามมาตรฐาน ASTM D610 อย่างแท้จริง

2.1.4. เกณฑ์การแบ่งระดับความรุนแรง (Degree of Rusting)

นอกเหนือจากการประเมินด้วยปริมาณพื้นที่ (Area Percentage) แล้ว การระบุ "เกณฑ์ระดับความรุนแรง" (Degree of Rusting) ยังต้องพิจารณาถึงลักษณะทางกายภาพและการกระจายตัวของสนิมร่วมด้วย เพื่อให้วิศวกรสามารถประเมินผลกระทบที่มีต่อความแข็งแรงของโครงสร้างได้อย่างรอบด้าน โดยทั่วไปตามมาตรฐานสากลและหลักการทางวิศวกรรม การแบ่งระดับความรุนแรงจะพิจารณาจาก 2 ปัจจัยหลัก ดังนี้

1. ลักษณะการกระจายตัว (Distribution Patterns) มาตรฐาน ASTM D610 ไม่ได้ระบุเพียงแค่เกรดคะแนน แต่ยังจำแนกลักษณะการเกิดสนิมออกเป็น 3 รูปแบบหลัก ซึ่งมีผลต่อแนวทางการซ่อมแซม ได้แก่

   - Spot Rusting (S): สนิมที่เกิดขึ้นเป็นจุดใหญ่ๆ กระจายตัวห่างกัน มักเกิดจากการกระแทกหรือความเสียหายเฉพาะจุดของสีเคลือบ

   - General Rusting (G): สนิมที่เกิดขึ้นกระจายทั่วพื้นที่ ทั้งจุดเล็กและใหญ่ปะปนกัน แสดงถึงการเสื่อมสภาพของระบบสีเคลือบทั้งระบบ

   - Pinpoint Rusting (P): สนิมจุดเล็กๆ จำนวนมากกระจายตัวอย่างหนาแน่น มักเกิดจากรูพรุนของสี (Porosity) หรือการเตรียมพื้นผิวที่ไม่ดีพอ

   ในระบบ RustVision AI ได้นำหลักการนี้มาประยุกต์ใช้ผ่านการคำนวณ "Region Density Penalty" หรือค่าปรับตามความหนาแน่นของกลุ่มสนิม เพื่อสะท้อนความจริงที่ว่าสนิมที่กระจุกตัวหนาแน่นอาจส่งผลเสียต่อโครงสร้างมากกว่าสนิมที่กระจายตัวบางๆ แม้จะมีพื้นที่รวมเท่ากันก็ตาม

2. การจัดกลุ่มความรุนแรงเพื่อการตัดสินใจ (Severity Classification for Decision Making) เพื่อให้ผลลัพธ์จากการวิเคราะห์สามารถนำไปใช้งานได้จริง (Actionable Insights) โครงการนี้จึงได้กำหนดเกณฑ์การแบ่งระดับความรุนแรงออกเป็น 3 กลุ่มหลัก ตามค่าดัชนีความเสี่ยงทางโครงสร้าง (Structural Risk Index) และเกรด ASTM เพื่อใช้เป็นแนวทางในการวางแผนซ่อมบำรุง ดังนี้

1. ระดับต่ำ (Minor / Cosmetic):
    - เกรด ASTM: 8 - 10
    - ความเสี่ยง: ต่ำมาก ผลกระทบส่วนใหญ่เป็นเรื่องความสวยงาม (Aesthetic) ยังไม่มีผลต่อความแข็งแรงของโครงสร้าง
    - การดำเนินการ: เฝ้าระวังในการตรวจสอบรอบถัดไป ไม่จำเป็นต้องซ่อมแซมทันที
2. ระดับปานกลาง (Moderate / Warning):
    - เกรด ASTM: 5 - 7
    - ความเสี่ยง: ปานกลาง เริ่มมีการกัดกร่อนเข้าสู่เนื้อเหล็ก ผิวเคลือบเสียหายอย่างเห็นได้ชัด
    - การดำเนินการ: ควรวางแผนซ่อมบำรุงหรือทาสีใหม่ (Repainting) ภายในระยะเวลาที่กำหนด เพื่อป้องกันการลุกลาม
3. ระดับวิกฤต (Severe / Critical):
    - เกรด ASTM: 0 - 4
    - ความเสี่ยง: สูงมาก พื้นที่หน้าตัดของเหล็กอาจลดลงจนส่งผลต่อความสามารถในการรับน้ำหนัก (Load Bearing)
    - การดำเนินการ: ต้องดำเนินการตรวจสอบเชิงลึกทันที (Immediate Inspection) และซ่อมแซมโครงสร้างหรือเปลี่ยนชิ้นส่วนโดยเร่งด่วน

2.1.5. การคำนวณดัชนีความเสี่ยงทางโครงสร้าง (Structural Risk Index)

แม้ว่ามาตรฐาน ASTM D610 จะให้ค่าเกรดความเสียหาย (0-10) ที่เป็นประโยชน์ แต่ในทางวิศวกรรมการบำรุงรักษา ค่าเกรดเพียงอย่างเดียวอาจไม่เพียงพอต่อการจัดลำดับความเร่งด่วน (Prioritization) ในกรณีที่มีจุดเสียหายหลายจุดที่มีเกรดเท่ากัน โครงการ RustVision AI จึงได้พัฒนาดัชนีชี้วัดเพิ่มเติมที่เรียกว่า "ดัชนีความเสี่ยงทางโครงสร้าง" (Structural Risk Index - SRI) ซึ่งเป็นค่าคะแนนเชิงประกอบ (Composite Score) ในช่วง 0 ถึง 100 เพื่อสะท้อนระดับอันตรายที่แท้จริง

หลักการคำนวณดัชนีนี้ อาศัยการประมวลผลร่วมกันของ 2 ปัจจัยหลัก คือ ปริมาณพื้นที่ความเสียหาย (Coverage Impact) และลักษณะการกระจายตัว (Density Penalty) โดยมีรายละเอียดดังนี้

1. องค์ประกอบของดัชนีความเสี่ยง

   - คะแนนจากพื้นที่ความเสียหาย $(CoverageScore - S_{cov})$ คำนวณโดยตรงจากเปอร์เซ็นต์พื้นที่สนิม (P_{rust}) ที่ได้จากการประมวลผลภาพ หากมีพื้นที่สนิมมาก ค่าความเสี่ยงจะสูงขึ้นแบบไม่เป็นเชิงเส้น (Non-linear) เนื่องจากความเสียหายทางโครงสร้างมักจะทวีความรุนแรงขึ้นอย่างรวดเร็วเมื่อพื้นที่หน้าตัดเหล็กลดลง

   - ค่าปรับตามความหนาแน่น $(DensityPenalty - P_{den})$ คำนวณจากจำนวนกลุ่มก้อนของสนิม (Number of Blobs/Contours) ที่ตรวจจับได้ สนิมที่กระจุกตัวเป็นก้อนใหญ่หรือมีจำนวนจุดที่หนาแน่น (Dense Pitting) จะมีโอกาสทำให้เกิดความเค้น (Stress Concentration) มากกว่าสนิมที่กระจายตัวบางๆ จึงต้องมีการบวกค่าความเสี่ยงเพิ่ม

2. สมการจำลองการคำนวณ (Mathematical Model)

   เพื่อให้สามารถคำนวณค่าดัชนีออกมาเป็นตัวเลขที่ชัดเจน ระบบได้ประยุกต์ใช้สมการความสัมพันธ์ในรูปแบบทั่วไปดังนี้

$$SRI = \min\left(100, \alpha \cdot f(P_{rust}) + \beta \cdot g(N_{blobs})\right)$$

   โดยที่

   - SRI คือ ดัชนีความเสี่ยงทางโครงสร้าง (0 - 100)
   - P_{rust} คือ เปอร์เซ็นต์พื้นที่สนิมทั้งหมดในภาพ
   - N_{blobs} คือ จำนวนกลุ่มสนิมอิสระที่ตรวจจับได้ (Independent Rust Spots)
   - α, β คือ ค่าน้ำหนักความสำคัญ (Weighting Factors) ที่กำหนดจากการทดลอง
   - $f(\cdot), g(\cdot)$ คือ ฟังก์ชันการแปลงค่าคะแนน

3. การแปลผลดัชนี (Interpretation)

   ค่า SRI ที่คำนวณได้จะถูกนำมาจัดแบ่งช่วงเพื่อออกคำแนะนำทางวิศวกรรมโดยอัตโนมัติดังนี้

   - SRI 0 - 20 (ความเสี่ยงต่ำ): สนิมผิวเผิน ไม่ส่งผลกระทบต่อโครงสร้าง → แนะนำให้ตรวจสอบตามรอบปกติ

   - SRI 21 - 60 (ความเสี่ยงปานกลาง): เริ่มมีการกัดกร่อนที่เห็นได้ชัด → แนะนำให้วางแผนซ่อมแซมสีหรือขัดสนิมภายใน 6-12 เดือน

   - SRI 61 - 100 (ความเสี่ยงสูง): สนิมกัดกร่อนรุนแรงหรือมีความหนาแน่นสูง → แนะนำให้วิศวกรเข้าตรวจสอบทันทีและดำเนินการซ่อมแซมเร่งด่วน

2.2. แนวคิดเกี่ยวกับปัญญาประดิษฐ์และการเรียนรู้เชิงลึก (Deep Learning)

2.2.1. ความหมายและหลักการทำงานของ Computer Vision

คอมพิวเตอร์วิทัศน์ (Computer Vision) คือสาขาหนึ่งของปัญญาประดิษฐ์ (Artificial Intelligence) และวิทยาการคอมพิวเตอร์ ที่มุ่งเน้นการพัฒนาให้ระบบคอมพิวเตอร์มีความสามารถในการ "มองเห็น" และ "ทำความเข้าใจ" ภาพดิจิทัลหรือวิดีโอในลักษณะเดียวกับระบบการมองเห็นของมนุษย์ เป้าหมายหลักคือการทำให้คอมพิวเตอร์สามารถดึงข้อมูลที่มีความหมาย (Meaningful Information) ออกจากสิ่งที่รับรู้ทางสายตา และนำข้อมูลนั้นไปใช้ในการตัดสินใจหรือควบคุมกระบวนการอื่นๆ โดยอัตโนมัติ ในบริบทของงานวิศวกรรม Computer Vision ถูกนำมาใช้แทนสายตามนุษย์ในงานที่ต้องการความละเอียดแม่นยำสูง งานที่ต้องทำซ้ำๆ หรือในสภาพแวดล้อมที่เป็นอันตราย เช่น การตรวจสอบรอยสนิมบนโครงสร้างขนาดใหญ่

หลักการทำงานของ Computer Vision เริ่มต้นจากการเข้าใจว่าคอมพิวเตอร์ "มองเห็น" ภาพแตกต่างจากมนุษย์ ในขณะที่มนุษย์เห็นวัตถุเป็นรูปร่างและสีสัน คอมพิวเตอร์จะมองเห็นภาพเป็นเพียง "อาเรย์ของตัวเลข" (Array of Numbers) หรือเมทริกซ์ (Matrix) กระบวนการทำงานจึงประกอบด้วยขั้นตอนสำคัญดังนี้

1. การรับภาพ (Image Acquisition) ขั้นตอนแรกคือการแปลงภาพจากโลกจริงให้เป็นข้อมูลดิจิทัลผ่านเซ็นเซอร์กล้อง ข้อมูลที่ได้จะถูกจัดเก็บในรูปแบบตารางพิกเซล (Pixels) โดยแต่ละพิกเซลจะระบุค่าความเข้มแสง (Intensity) หากเป็นภาพสีจะมีการจัดเก็บแยกเป็นช่องสัญญาณ (Channels) เช่น แดง เขียว และน้ำเงิน (RGB) ซึ่งเป็นข้อมูลดิบที่พร้อมสำหรับการประมวลผล
2. การประมวลผลเบื้องต้น (Image Pre-processing) ก่อนที่จะนำภาพไปวิเคราะห์ จำเป็นต้องมีการเตรียมข้อมูลเพื่อลดสัญญาณรบกวน (Noise) และปรับปรุงคุณภาพของภาพให้เด่นชัดขึ้น เทคนิคที่นิยมใช้ ได้แก่ การปรับความคมชัด (Contrast Enhancement) หรือการแปลงภาพเป็นสีเทา (Grayscale Conversion) เพื่อลดความซับซ้อนของข้อมูล ซึ่งในโครงการนี้ได้เลือกใช้เทคนิค CLAHE เพื่อแก้ปัญหาแสงเงาบนผิวโลหะ
3. การสกัดคุณลักษณะ (Feature Extraction) เป็นขั้นตอนหัวใจสำคัญที่ระบบจะทำการค้นหาจุดเด่นหรือแพทเทิร์นภายในภาพ เช่น เส้นขอบ (Edges), มุม (Corners), หรือลวดลายพื้นผิว (Texture) ในยุคปัจจุบันขั้นตอนนี้มักถูกดำเนินการโดยอัตโนมัติผ่านโครงข่ายประสาทเทียมแบบคอนโวลูชัน (CNN) ซึ่งมีความสามารถในการเรียนรู้คุณลักษณะที่ซับซ้อนของสนิมได้ดีกว่าการเขียนโปรแกรมระบุเงื่อนไขด้วยมือ

4. การตีความและวิเคราะห์ผล (Image Interpretation) ขั้นตอนสุดท้ายคือการนำคุณลักษณะที่สกัดได้มาประมวลผลเพื่อระบุว่าวัตถุในภาพคืออะไร (Classification), อยู่ตรงไหน (Detection), หรือมีขอบเขตอย่างไร (Segmentation) ผลลัพธ์ที่ได้จะเป็นข้อมูลระดับสูง เช่น การระบุว่าเป็น "สนิม" พร้อมพิกัดตำแหน่ง ซึ่งระบบสามารถนำไปคำนวณพื้นที่และประเมินเกรดความเสียหายต่อไป

100	100	0	0	0	0	255	255
50	0	50	50	50	50	255	255
50	0	50	255	255	255	255	255
50	0	50	255	255	255	255	255
50	0	50	255	255	255	255	255
50	0	50	50	50	50	255	255
100	100	0	0	0	0	255	255
100	100	50	50	50	50	255	255

(a)

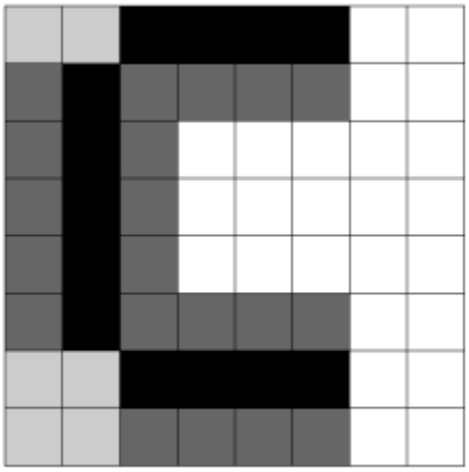

(b)

ภาพที่ 2.2.1 การมองเห็นของคอมพิวเตอร์

2.2.2. สถาปัตยกรรมโครงข่ายประสาทเทียมแบบคอนโวลูชัน (CNN)

โครงข่ายประสาทเทียมแบบคอนโวลูชัน หรือ CNN เป็นสถาปัตยกรรมของ Deep Learning ที่ได้รับการออกแบบมาโดยเฉพาะสำหรับการประมวลผลข้อมูลที่มีลักษณะเป็นโครงข่ายหรือตาราง (Grid Topology) เช่น ข้อมูลภาพดิจิทัล ซึ่งประกอบด้วยพิกเซลเรียงตัวกันเป็นตาราง 2 มิติ หรือ 3 มิติ (กรณีภาพสี) หลักการทำงานของ CNN ได้รับแรงบันดาลใจมาจากกระบวนการทางชีววิทยาของการมองเห็นในสัตว์ โดยเลียนแบบการทำงานของ Visual Cortex ในสมอง ซึ่งเซลล์ประสาทแต่ละกลุ่มจะตอบสนองต่อพื้นที่รับภาพเฉพาะส่วน (Receptive Field) เท่านั้น ทำให้ CNN มีความสามารถที่โดดเด่นเหนือกว่าโครงข่ายประสาทเทียมแบบดั้งเดิม (Fully Connected Networks) ในแง่ของการรักษาความสัมพันธ์เชิงพื้นที่ (Spatial Relationship) ของวัตถุในภาพ และสามารถเรียนรู้คุณลักษณะ (Feature Learning) ได้ด้วยตนเองโดยไม่ต้องอาศัยมนุษย์กำหนดคุณลักษณะให้โครงสร้างการทำงานของ CNN ประกอบด้วยชั้นการประมวลผล (Layers) หลัก 3 ประเภท ที่ทำงานเรียงต่อกันเป็นลำดับลึก ดังนี้

ชั้นคอนโวลูชัน (Convolutional Layer) ชั้นคอนโวลูชันถือเป็นหัวใจสำคัญของสถาปัตยกรรมนี้ ทำหน้าที่เป็นตัวสกัดคุณลักษณะ (Feature Extractor) ออกจากภาพขาเข้า โดยอาศัยอุปกรณ์ทางคณิตศาสตร์ที่เรียกว่า "ตัวกรอง" (Filter) หรือ "เคอร์เนล" (Kernel) ซึ่งมีลักษณะเป็นเมทริกซ์ขนาดเล็ก (เช่น 3x3 หรือ 5x5) ที่บรรจุค่าตัวเลขน้ำหนัก (Weights) เอาไว้

1. ชั้นคอนโวลูชัน (Convolutional Layer) ชั้นคอนโวลูชันถือเป็นหัวใจสำคัญของสถาปัตยกรรมนี้ ทำหน้าที่เป็นตัวสกัดคุณลักษณะ (Feature Extractor) ออกจากภาพขาเข้า โดยอาศัยอุปกรณ์ทางคณิตศาสตร์ที่เรียกว่า "ตัวกรอง" (Filter) หรือ "เคอร์เนล" (Kernel) ซึ่งมีลักษณะเป็นเมทริกซ์ขนาดเล็ก (เช่น 3x3 หรือ 5x5) ที่บรรจุค่าตัวเลขน้ำหนัก (Weights) เอาไว้
   กระบวนการทำงานเริ่มจากการนำตัวกรองนี้ไปวางทาบบนมุมซ้ายบนของภาพต้นฉบับ แล้วทำการคำนวณทางคณิตศาสตร์ที่เรียกว่า "Convolution" ซึ่งคือการคูณค่าในตัวกรองกับค่าพิกเซลในตำแหน่งที่ตรงกันแบบตำแหน่งต่อตำแหน่ง (Element-wise multiplication) แล้วนำผลลัพธ์ทั้งหมดมารวมกันเป็นค่าเดียว จากนั้นตัวกรองจะเลื่อน (Slide) ไปยังตำแหน่งถัดไปตามระยะที่กำหนด (Stride) จนทั่วทั้งภาพ ผลลัพธ์ที่ได้เรียกว่า "แผนที่ลักษณะ" (Feature Map) ซึ่งจะทำหน้าที่บ่งบอกว่ามีคุณลักษณะที่ต้องการ (เช่น เส้นแนวตั้ง เส้นแนวนอน หรือส่วนโค้ง) ปรากฏอยู่ในตำแหน่งใดของภาพบ้าง
   ในชั้นนี้มักจะมีการใช้งานร่วมกับฟังก์ชันกระตุ้น (Activation Function) แบบ ReLU (Rectified Linear Unit) โดยการเปลี่ยนค่าตัวเลขที่เป็นลบให้กลายเป็นศูนย์ เพื่อเพิ่มความเป็นไม่เชิงเส้น (Non-linearity) ให้กับระบบ ซึ่งช่วยให้โมเดลสามารถเรียนรู้รูปแบบที่ซับซ้อนของภาพได้ดียิ่งขึ้น
2. ชั้นพูลลิง (Pooling Layer) หลังจากผ่านชั้นคอนโวลูชัน ข้อมูลที่ได้มักจะมีขนาดใหญ่และมีความละเอียดสูงเกินความจำเป็น ชั้นพูลลิงจึงเข้ามาทำหน้าที่ในการลดขนาดมิติของภาพ (Downsampling) เพื่อย่อขนาดข้อมูลให้เล็กลง ซึ่งช่วยลดจำนวนพารามิเตอร์และการคำนวณในระบบลง ป้องกันปัญหาการเรียนรู้เกิน (Overfitting) และช่วยให้โมเดลมีความทนทานต่อการเปลี่ยนแปลงตำแหน่งของวัตถุเพียงเล็กน้อย (Translation Invariance)
   กระบวนการพูลลิงที่นิยมใช้มากที่สุดคือ "Max Pooling" ซึ่งทำงานโดยการแบ่ง Feature Map ออกเป็นส่วนย่อยๆ (เช่น ขนาด 2x2) แล้วเลือกเฉพาะค่าตัวเลขที่ "มากที่สุด" ในส่วนนั้นมาเป็นตัวแทนของพื้นที่ การทำเช่นนี้เปรียบเสมือนการคัดเลือกเฉพาะคุณลักษณะที่เด่นชัดที่สุดของสนิมเอาไว้ และตัดรายละเอียดรบกวนที่ไม่จำเป็นทิ้งไป

3. ชั้นฟูลลีคอนเน็กเต็ด (Fully Connected Layer) เป็นชั้นสุดท้ายของโครงข่าย ทำหน้าที่เป็น "ตัวจำแนกประเภท" (Classifier) ข้อมูลภาพที่ผ่านการสกัดคุณลักษณะและย่อขนาดจากชั้นก่อนหน้า จะถูกนำมาปรับรูปแบบจากเมทริกซ์ 2 มิติ หรือ 3 มิติ ให้กลายเป็นเวกเตอร์แถวเดียว (Flattening) เพื่อป้อนเข้าสู่โครงข่ายประสาทเทียมแบบมาตรฐาน (Neural Network) ซึ่งเซลล์ประสาททุกตัวในชั้นนี้จะเชื่อมโยงกันอย่างสมบูรณ์ เพื่อประมวลผลความสัมพันธ์ของฟีเจอร์ระดับสูงทั้งหมด แล้วทำการทำนายผลลัพธ์ออกมาเป็นค่าความน่าจะเป็น (Probability) ว่าภาพที่เห็นนั้นคือ "สนิม" ในระดับความรุนแรงใด

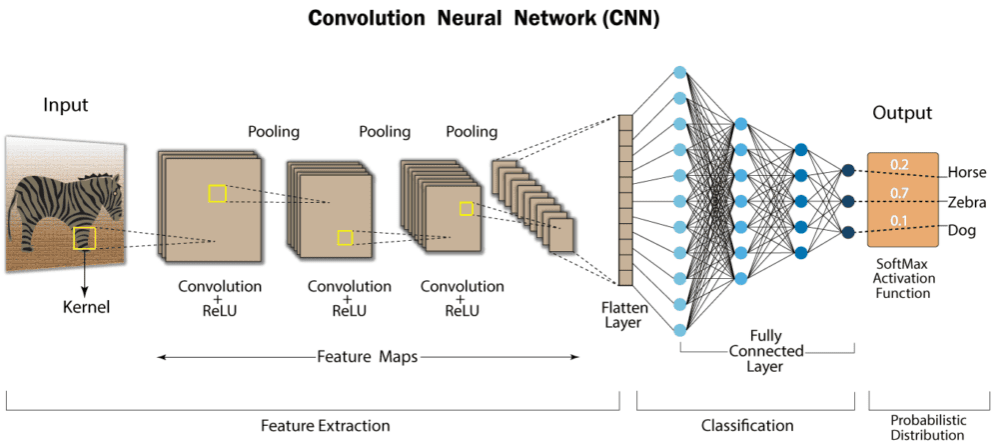

ภาพที่ 2.2.2 โครงข่ายประสาทเทียมแบบคอนโวลูชัน

สำหรับในงานวิจัยนี้ การทำความเข้าใจโครงสร้างพื้นฐานของ CNN มีความสำคัญอย่างยิ่ง เนื่องจากโมเดล YOLO26-Seg ที่เลือกใช้ในการทดลอง เป็นสถาปัตยกรรมขั้นสูงที่พัฒนาต่อยอดมาจากพื้นฐานของ CNN โดยมีการปรับปรุงโครงสร้างให้สามารถทำนายทั้งตำแหน่ง (Bounding Box) และรูปร่าง (Mask) ของวัตถุได้พร้อมกันในขั้นตอนเดียว ซึ่งช่วยเพิ่มความเร็วในการประมวลผลให้เหมาะสมกับการใช้งานแบบ Real-time หรือ Offline Application บนเครื่องคอมพิวเตอร์ทั่วไป

2.2.3. อัลกอริทึม YOLO (You Only Look Once) สำหรับการตรวจจับวัตถุ

YOLO หรือ "You Only Look Once" เป็นอัลกอริทึมสำหรับตรวจจับวัตถุ (Object Detection) ที่ปฏิวัติวงการ Computer Vision ด้วยแนวคิดที่แตกต่างจากวิธีการดั้งเดิมอย่างสิ้นเชิง ในขณะที่อัลกอริทึมยุคก่อนหน้า เช่น R-CNN จะใช้วิธีการแบ่งขั้นตอนการทำงานออกเป็นสองส่วน (Two-Stage Detector) ได้แก่ การสร้างกรอบพื้นที่ที่น่าจะเป็นวัตถุ (Region Proposal) แล้วค่อยส่งแต่ละกรอบไปจำแนกประเภททีละกรอบ ซึ่งทำให้กระบวนการทำงานล่าช้าและใช้ทรัพยากรการประมวลผลสูง แต่ YOLO ได้เปลี่ยนกระบวนการทั้งหมดให้เป็น "ปัญหาการถดถอยเพียงหนึ่งเดียว"

(Single Regression Problem) โดยใช้โครงข่ายประสาทเทียมเพียงเครือข่ายเดียวในการทำนายทั้งตำแหน่งกรอบสี่เหลี่ยม (Bounding Box) และความน่าจะเป็นของวัตถุ (Class Probability) ไปพร้อมกันจากการมองภาพเพียงครั้งเดียว ซึ่งเป็นที่มาของชื่อ "You Only Look Once"

หลักการทำงานของ YOLO สามารถแบ่งออกเป็นขั้นตอนสำคัญได้ดังนี้

1. การแบ่งภาพเป็นตาราง (Grid Division) YOLO จะเริ่มต้นด้วยการแบ่งภาพอินพุตออกเป็นตาราง (Grid) ขนาด S x S (เช่น 7x7 หรือ 13x13) โดยแต่ละช่องตาราง (Grid Cell) จะทำหน้าที่รับผิดชอบในการตรวจจับวัตถุที่มี "จุดศูนย์กลาง" ตกอยู่ในช่องนั้นๆ
2. การทำนายกรอบและค่าความเชื่อมั่น (Bounding Box Prediction & Confidence Score) ในแต่ละช่องตาราง จะทำการทำนายกรอบสี่เหลี่ยมจำนวน B กรอบ (Bounding Boxes) โดยแต่ละกรอบจะประกอบด้วยค่าพารามิเตอร์ 5 ตัว ได้แก่
   - พิกัดแกน x และ y: จุดศูนย์กลางของวัตถุเทียบกับขอบเขตของช่องตาราง
   - ความกว้าง (w) และความสูง (h): ขนาดของกรอบเทียบกับขนาดของภาพทั้งหมด
   - ค่าความเชื่อมั่น (Confidence Score): ค่าที่บ่งบอกว่าโมเดลมั่นใจแค่ไหนว่ามีวัตถุอยู่ในกรอบนั้น และกรอบที่ตีมีความแม่นยำเพียงใด ซึ่งคำนวณจากสูตร: Confidence = Pr(Object) * IoU โดยที่ IoU (Intersection over Union) คืออัตราส่วนพื้นที่ทับซ้อนระหว่างกรอบที่ทำนายได้กับกรอบความจริง (Ground Truth)
3. การทำนายประเภทวัตถุ (Class Probability Map) นอกจากพิกัดกรอบแล้ว แต่ละช่องตารางยังทำหน้าที่ทำนาย "ความน่าจะเป็นของประเภทวัตถุ" (Conditional Class Probabilities) ว่าหากมีวัตถุอยู่ในช่องนี้ มันคือวัตถุชนิดใด (เช่น สนิมเกรด 1, สนิมเกรด 2)
4. การคัดกรองผลลัพธ์ (Non-Maximum Suppression - NMS) เนื่องจากหนึ่งวัตถุอาจถูกตรวจจับโดยหลายช่องตารางพร้อมกัน ทำให้เกิดกรอบซ้ำซ้อนจำนวนมาก YOLO จึงใช้กระบวนการ NMS เพื่อคัดกรองกรอบที่มีค่าความเชื่อมั่นต่ำออก และรวมกรอบที่ทับซ้อนกันสูงให้เหลือเพียงกรอบที่มีคะแนนสูงสุดเพียงกรอบเดียวต่อหนึ่งวัตถุ

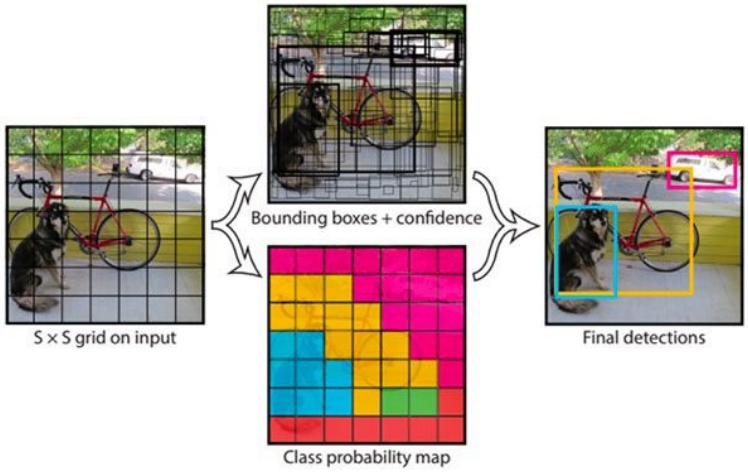

ภาพที่ 2.2.3 อัลกอริทึม YOLO (You Only Look Once)

จุดเด่นสำคัญที่ทำให้ YOLO เหมาะสำหรับโครงการ RustVision AI คือ "ความเร็ว" (Speed) เนื่องจากการประมวลผลเกิดขึ้นแบบขนาน (Parallel Processing) ทั้งภาพในครั้งเดียว ทำให้สามารถรันบนคอมพิวเตอร์ทั่วไปได้แบบ Real-time ซึ่งสอดคล้องกับวัตถุประสงค์ของโครงการที่ต้องการระบบ Desktop Application ที่ตอบสนองรวดเร็ว นอกจากนี้ YOLO ยังมองเห็นบริบทของภาพโดยรวม (Global Context) ทำให้ลดความผิดพลาดในการระบุวัตถุในส่วนพื้นหลัง (Background Errors) ได้ดีกว่าอัลกอริทึมแบบเก่า

2.2.4. เทคนิค Instance Segmentation กับการจำแนกพื้นที่ระดับพิกเซล

Instance Segmentation คือเทคนิคขั้นสูงในสาขา Computer Vision ที่ผสมผสานความสามารถของสองกระบวนการหลักเข้าด้วยกัน ได้แก่ "การตรวจจับวัตถุ" (Object Detection) และ "การจำแนกประเภทระดับพิกเซล" (Semantic Segmentation) เป้าหมายสำคัญของเทคนิคนี้คือการระบุตำแหน่งของวัตถุแต่ละชิ้นในภาพ พร้อมกับบ่งบอกขอบเขตรูปร่างที่แท้จริงของวัตถุนั้นๆ ในระดับความละเอียดพิกเซล (Pixel-level Accuracy) ซึ่งมีความซับซ้อนและให้ผลลัพธ์ที่ละเอียดกว่าวิธีการแบบดั้งเดิม

เพื่อให้เข้าใจความสำคัญของเทคนิคนี้ จำเป็นต้องเปรียบเทียบความแตกต่างกับวิธีการอื่นๆ ดังนี้

1. การจำแนกประเภทภาพ (Image Classification) บอกได้เพียงว่า "ในภาพมีสนิมหรือไม่" แต่ไม่สามารถระบุได้ว่าอยู่ตรงไหน หรือมีกี่จุด
2. การตรวจจับวัตถุ (Object Detection) บอกตำแหน่งได้โดยการตี "กรอบสี่เหลี่ยม" (Bounding Box) ล้อมรอบบริเวณที่เป็นสนิม แต่วิธีนี้มีข้อจำกัดสำคัญคือ กรอบสี่เหลี่ยมมักจะครอบคลุมพื้นที่ส่วนเกินที่เป็นพื้นหลังหรือผิวโลหะปกติเข้ามาด้วย (Background

Noise) ทำให้เมื่อนำพื้นที่ของกรอบสี่เหลี่ยมมาคำนวณ ความเสียหายจะดูมากกว่าความเป็นจริงเสมอ

3. การจำแนกพื้นที่ระดับพิกเซล (Instance Segmentation) เป็นวิธีที่งานวิจัยนี้เลือกใช้ เพราะสามารถสร้าง "หน้ากาก" (Mask) หรือโพลีกอนที่ระบายทับลงไปบนพื้นที่ที่เป็นสนิมจริงๆ ได้แบบพิกเซลต่อพิกเซล โดยกระบวนการทำงานจะเริ่มจากการที่โมเดลทำการทำนายค่าความน่าจะเป็น (Probability Score) ให้กับ "ทุกๆ จุดพิกเซล" ภายในกรอบที่สนใจ (Region of Interest) ว่าพิกเซลนั้นเป็นส่วนหนึ่งของเนื้อสนิม (Foreground) หรือเป็นเพียงพื้นหลัง (Background)

ภาพที่ 2.2.4 เทคนิค Instance Segmentation

ผลลัพธ์ที่ได้คือ Binary Mask ที่มีรูปร่างบิดเบี้ยวและซับซ้อนตรงตามรอยสนิมจริงที่ปรากฏ ซึ่งในบริบทของโครงการ RustVision AI เทคนิคนี้คือกุญแจสำคัญที่ทำให้ระบบสามารถคำนวณ "พื้นที่ความเสียหายจริง" (Actual Damaged Area) ได้อย่างแม่นยำ ต่างจากการใช้กรอบสี่เหลี่ยมที่อาจมีความคลาดเคลื่อนสูง การนับจำนวนพิกเซลที่เป็นสนิมจริงๆ (Rust Pixels) เทียบกับพิกเซลทั้งหมดของภาพช่วยให้ค่าเปอร์เซ็นต์ความเสียหายที่คำนวณได้มีความถูกต้องและสอดคล้องกับมาตรฐาน ASTM D610 มากที่สุด

2.2.5. ความแตกต่างระหว่าง Object Detection และ Instance Segmentation

ในกระบวนการวิเคราะห์ภาพด้วยคอมพิวเตอร์ (Computer Vision) การเลือกใช้วิธีการตรวจจับวัตถุมีผลโดยตรงต่อความแม่นยำของผลลัพธ์ โดยเฉพาะอย่างยิ่งในงานวิศวกรรมที่ต้องการการวัดค่าเชิงปริมาณ (Quantitative Measurement) งานวิจัยนี้จึงจำเป็นต้องแยกแยะความแตกต่างระหว่างสองเทคนิคหลัก คือ Object Detection และ Instance Segmentation เพื่อแสดงเหตุผลในการเลือกใช้เทคนิคที่เหมาะสมที่สุดสำหรับโจทย์การตรวจจับสนิม

1. การตรวจจับวัตถุ (Object Detection)

   Object Detection เป็นเทคนิคที่ยกระดับขึ้นมาจากการจำแนกภาพ (Image Classification) โดยมีความสามารถในการระบุตำแหน่งของวัตถุหลายชิ้นในภาพเดียวกันได้ ผลลัพธ์ที่ได้จาก Object Detection จะอยู่ในรูปแบบของ "กรอบสี่เหลี่ยม" (Bounding Box) ที่ล้อมรอบวัตถุ พร้อมระบุพิกัด (x, y) ของจุดศูนย์กลาง ความกว้าง และความสูงของกรอบ รวมถึงประเภทของวัตถุ (Class Label)

   ข้อจำกัดสำคัญของ Object Detection ในงานตรวจสอบสนิมคือ "ความหยาบของพื้นที่" เนื่องจากสนิมมักมีรูปร่างที่บิดเบี้ยว ไม่สม่ำเสมอ และไม่มีรูปทรงเรขาคณิตที่แน่นอน (Irregular Shapes) การใช้กรอบสี่เหลี่ยมตีล้อมรอบสนิมจะทำให้พื้นที่ภายในกรอบครอบคลุมส่วนที่เป็นพื้นผิวโลหะปกติหรือพื้นหลัง (Background) เข้ามาด้วยเสมอ พื้นที่ส่วนเกินนี้เรียกว่า "Dead Space" ซึ่งหากนำพื้นที่ของกรอบสี่เหลี่ยมไปคำนวณหาเปอร์เซ็นต์ความเสียหาย จะทำให้ได้ค่าที่สูงกว่าความเป็นจริง (Overestimation) และส่งผลให้การประเมินเกรดตามมาตรฐาน ASTM ผิดพลาดได้

2. การจำแนกพื้นที่ระดับพิกเซล (Instance Segmentation)

   Instance Segmentation เป็นเทคนิคที่มีความละเอียดสูงสุดในปัจจุบัน โดยรวมคุณสมบัติของ Object Detection (การระบุตำแหน่งและนับจำนวนวัตถุ) เข้ากับ Semantic Segmentation (การระบุประเภทของแต่ละพิกเซล) ผลลัพธ์ที่ได้จะไม่ใช่เพียงแค่กรอบสี่เหลี่ยม แต่เป็น "หน้ากาก" (Mask) หรือโพลีกอนที่ระบายทับลงไปบนตัววัตถุจริงๆ ในระดับพิกเซล (Pixel-perfect precision)

   ความสามารถที่โดดเด่นของ Instance Segmentation คือการแยกแยะ "วัตถุแต่ละชิ้น" (Instances) ออกจากกันได้อย่างชัดเจน แม้ว่าวัตถุเหล่านั้นจะเป็นประเภทเดียวกันและวางซ้อนทับกันอยู่ (Overlapping) เช่น หากมีรอยสนิมสองจุดอยู่ติดกัน ระบบจะสามารถระบุได้ว่าเป็น "Rust Spot #1" และ "Rust Spot #2" ซึ่งต่างจาก Semantic Segmentation แบบดั้งเดิมที่จะมองเห็นสนิมทั้งสองจุดเป็นก้อนเนื้อเดียวกัน

3. การเปรียบเทียบเชิงวิเคราะห์

   เพื่อให้เห็นภาพความแตกต่างชัดเจน สามารถเปรียบเทียบปัจจัยสำคัญได้ดังนี้

   - ระดับของผลลัพธ์ (Granularity): Object Detection ให้ผลลัพธ์ระดับวัตถุ (Box-level) ในขณะที่ Instance Segmentation ให้ผลลัพธ์ระดับพิกเซล (Pixel-level)

- ข้อมูลรูปร่าง (Shape Information): Object Detection จะสูญเสียข้อมูลรูปร่างที่แท้จริงของวัตถุไป เหลือเพียงกรอบสี่เหลี่ยม ในขณะที่ Instance Segmentation สามารถรักษาข้อมูลรูปร่าง ขอบเขต และความโค้งเว้าของสนิมไว้ได้อย่างครบถ้วน
- ความแม่นยำในการคำนวณพื้นที่ (Area Calculation Accuracy): Object Detection มีความแม่นยำต่ำสำหรับวัตถุรูปทรงอิสระ เนื่องจากรวมพื้นที่ว่างในกรอบ ส่วน Instance Segmentation มีความแม่นยำสูงมาก เพราะนับเฉพาะพิกเซลที่เป็นสนิมจริงๆ

4. เหตุผลในการเลือกใช้ Instance Segmentation ในงานวิจัยนี้

สำหรับโครงการ RustVision AI เป้าหมายหลักคือการประเมินระดับความเสียหายตามมาตรฐาน ASTM D610 ซึ่งต้องอาศัยการคำนวณสัดส่วนพื้นที่ (Area Percentage) อย่างละเอียด การใช้ Object Detection จะทำให้เกิดความคลาดเคลื่อนสูงเนื่องจากสนิมมักมีลักษณะเป็นเส้นยาวหรือกระจายตัวเป็นจุดเล็กๆ ซึ่งการตีกรอบสี่เหลี่ยมจะกินพื้นที่ปกติเข้ามามากเกินไป ดังนั้น การเลือกใช้เทคนิค Instance Segmentation จึงเป็นสิ่งจำเป็น (Necessity) เพื่อให้ระบบสามารถ "Mask" เฉพาะเนื้อสนิม และนำจำนวนพิกเซลเหล่านั้นมาคำนวณหาค่าเปอร์เซ็นต์ความเสียหายที่ถูกต้องและน่าเชื่อถือทางวิศวกรรมได้

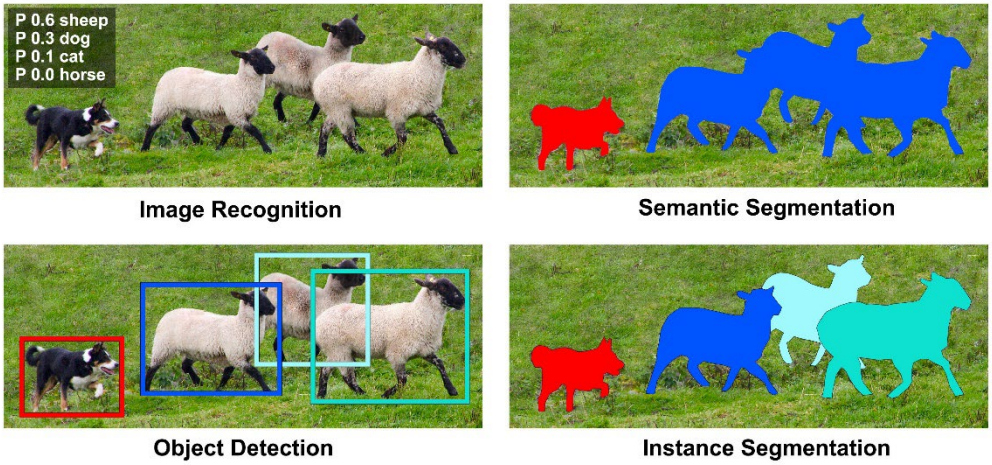

ภาพที่ 2.2.5 ความแตกต่างระหว่าง Object Detection และ Instance Segmentation

2.2.6. สถาปัตยกรรมโมเดล YOLO26-Seg และประสิทธิภาพการทำงาน

ในโครงการ RustVision AI ผู้จัดทำได้เลือกใช้โมเดล "YOLO26-Seg" ซึ่งเป็นโมเดลปัญญาประดิษฐ์ที่ได้รับการปรับแต่งและพัฒนาต่อยอดมาจากสถาปัตยกรรมตระกูล YOLO (You Only Look Once) รุ่นล่าสุด เพื่อให้รองรับงานจำแนกพื้นที่ระดับพิกเซล (Instance Segmentation) โดยเฉพาะ โครงสร้างสถาปัตยกรรมของโมเดลนี้มีความซับซ้อนและได้รับการออกแบบมาให้มีความสมดุลระหว่างความแม่นยำ (Precision) และความเร็วในการประมวลผล (Inference Speed) ซึ่งประกอบด้วยส่วนประกอบหลัก 3 ส่วน ดังนี้

1. สถาปัตยกรรมหลัก (Architecture Overview)
    - ส่วนรับข้อมูลและสกัดคุณลักษณะ (Backbone): ทำหน้าที่เปรียบเสมือน "ดวงตา" ของระบบ โดยใช้โครงข่ายประสาทเทียมแบบคอนโวลูชัน (CSPDarknet) ที่มีความลึกหลายชั้นในการสกัดคุณลักษณะของภาพ (Feature Extraction) ตั้งแต่ระดับต่ำ เช่น เส้นขอบของสนิม ไปจนถึงระดับสูง เช่น ลวดลายพื้นผิว (Texture) และรูปทรงที่ซับซ้อน Backbone ของ YOLO26-Seg ถูกออกแบบมาให้ลดภาระการคำนวณที่ไม่จำเป็น ทำให้สามารถประมวลผลภาพความละเอียดสูงได้อย่างรวดเร็ว
    - ส่วนผสมผสานคุณลักษณะ (Neck): ทำหน้าที่เชื่อมต่อระหว่าง Backbone และส่วนทำนายผล โดยใช้เทคนิค PANet (Path Aggregation Network) หรือ FPN (Feature Pyramid Network) ในการรวมข้อมูลจากเลเยอร์ที่มีความละเอียดต่างกันเข้าด้วยกัน สิ่งนี้สำคัญมากสำหรับงานตรวจจับสนิม เพราะช่วยให้โมเดลสามารถมองเห็นสนิมได้ทุกขนาด ไม่ว่าจะเป็นสนิมจุดเล็กๆ (Small Objects) หรือสนิมแผ่นใหญ่ (Large Objects) ในภาพเดียวกันได้อย่างแม่นยำ
    - ส่วนทำนายผลและสร้างหน้ากาก (Segmentation Head): เป็นส่วนที่มีความแตกต่างจาก YOLO รุ่นปกติ (Detection Only) อย่างสิ้นเชิง โดยในรุ่น YOLO26-Seg นี้ ส่วน Head จะถูกแยกออกเป็น 2 กิ่งงาน (Decoupled Head) ได้แก่

    1. Detection Branch: ทำหน้าที่ทำนายกรอบสี่เหลี่ยม (Bounding Box) และประเภทของวัตถุ (Class)
    2. Segmentation Branch: ทำหน้าที่สร้าง "หน้ากากต้นแบบ" (Prototype Masks) และทำนาย "ค่าสัมประสิทธิ์หน้ากาก" (Mask Coefficients) สำหรับแต่ละวัตถุที่ตรวจพบ

กระบวนการสร้างภาพผลลัพธ์ (Mask Assembly) เกิดจากการนำหน้ากากต้นแบบมาผสมผสานกับค่าสัมประสิทธิ์ที่ทำนายได้ ทำให้ได้ออกมาเป็นรูปทรงของสนิมที่แท้จริงตามพิกเซลของภาพต้นฉบับ

2. ประสิทธิภาพการทำงาน (Performance and Efficiency)
จากการทดสอบและใช้งานจริงในสภาพแวดล้อมการพัฒนาที่มีทรัพยากรจำกัด (เช่น การรันบน GPU รุ่น RTX 4060) โมเดล YOLO26-Seg แสดงให้เห็นถึงประสิทธิภาพที่โดดเด่นในด้านต่างๆ ดังนี้
    - ความเร็วในการประมวลผล (Real-time Inference): ด้วยโครงสร้างที่ลดความซับซ้อนของเลเยอร์ที่ไม่จำเป็น ทำให้ YOLO26-Seg สามารถประมวลผลภาพได้ด้วยความเร็วสูง (High FPS) ซึ่งเพียงพอต่อการใช้งานในลักษณะ Desktop Application ที่ต้องการผลลัพธ์ทันทีโดยไม่ต้องรอนาน
    - ความแม่นยำในการจำแนกขอบเขต (Segmentation Accuracy): โมเดลมีความสามารถในการ "กันขอบ" (Edge Segmentation) ได้อย่างคมชัด สามารถแยกแยะรอยต่อระหว่างเนื้อสนิมและสีเคลือบเดิมได้ดี แม้ในกรณีที่สนิมมีรูปร่างบิดเบี้ยวหรือกระจายตัวแบบ Filiform (เส้นใย) ซึ่งช่วยลดความผิดพลาดในการคำนวณพื้นที่ความเสียหายเมื่อเทียบกับการใช้กรอบสี่เหลี่ยมแบบดั้งเดิม
    - การจัดการกับวัตถุซ้อนทับ (Occlusion Handling): ในกรณีที่มีรอยสนิมเกิดขึ้นใกล้กันหรือซ้อนทับกัน ระบบสามารถแยกแยะได้ว่าเป็นสนิมคนละจุด (Instance Separation) ทำให้การนับจำนวนจุดและการวิเคราะห์การกระจายตัวมีความถูกต้องแม่นยำตามหลักวิศวกรรม

สรุปได้ว่า สถาปัตยกรรมของ YOLO26-Seg เป็นการผสมผสานเทคโนโลยี Computer Vision ขั้นสูงที่ตอบโจทย์งานตรวจสอบโครงสร้างได้อย่างลงตัว ทั้งในแง่ของความละเอียดในการวัดค่าความเสียหายและความคล่องตัวในการใช้งานจริง

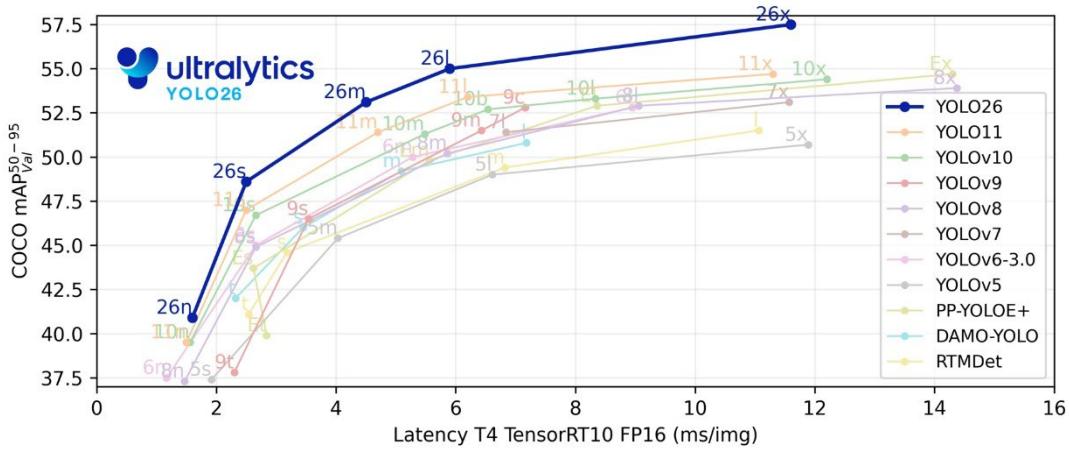

ภาพที่ 2.2.6 โมเดล YOLO26-Seg

2.3. ทฤษฎีการประมวลผลภาพดิจิทัล (Digital Image Processing)

2.3.1. หลักการปรับปรุงคุณภาพของภาพ (Image Enhancement)

การปรับปรุงคุณภาพของภาพ หรือ Image Enhancement คือกระบวนการทางวิศวกรรมคอมพิวเตอร์ที่มุ่งเน้นการปรับเปลี่ยนคุณสมบัติของภาพดิจิทัลเพื่อให้ผลลัพธ์ที่ได้มีความเหมาะสมต่อการนำไปใช้งานในวัตถุประสงค์เฉพาะทางมากยิ่งขึ้น ไม่ว่าจะเป็นการปรับเพื่อให้เหมาะสมต่อการมองเห็นของมนุษย์ (Visual Perception) หรือการปรับเพื่อให้เหมาะสมต่อการประมวลผลของเครื่องจักร (Machine Perception) เช่น การเตรียมภาพสำหรับป้อนเข้าสู่โมเดลปัญญาประดิษฐ์

หลักการพื้นฐานของการปรับปรุงคุณภาพภาพไม่ได้เป็นการเพิ่มข้อมูลใหม่เข้าไปในภาพ แต่เป็นการ "ดึง" หรือ "เน้น" ข้อมูลที่มีอยู่แล้วให้เด่นชัดขึ้น โดยสามารถแบ่งวิธีการออกเป็น 2 กลุ่มหลักตามโดเมนของการประมวลผล ดังนี้

1. การประมวลผลในโดเมนพื้นที่ (Spatial Domain Processing) เป็นวิธีการที่กระทำกับค่าความเข้มแสงของพิกเซล (Pixel Intensity) โดยตรงบนระนาบของภาพ วิธีนี้เป็นที่นิยมและมีความซับซ้อนน้อยกว่า โดยการนำค่าของพิกเซลในตำแหน่งหนึ่งๆ หรือกลุ่มพิกเซลข้างเคียง มาผ่านฟังก์ชันทางคณิตศาสตร์เพื่อเปลี่ยนค่าใหม่ เช่น การปรับความสว่าง (Brightness Adjustment), การปรับความเปรียบต่าง (Contrast Stretching), หรือการใช้ตัวกรอง (Filter) เพื่อลดสัญญาณรบกวน ซึ่งในงานวิจัยนี้ได้เลือกใช้วิธีการในกลุ่มนี้เป็นหลัก เนื่องจากต้องการรักษาข้อมูลเชิงพื้นที่ของรอยสนิมไว้ให้ครบถ้วน

2. การประมวลผลในโดเมนความถี่ (Frequency Domain Processing) เป็นวิธีการที่ซับซ้อนขึ้นโดยการแปลงภาพจากโดเมนพื้นที่ไปสู่โดเมนความถี่ (เช่น การใช้ Fourier Transform) ก่อนที่จะทำการปรับแต่งค่าสัมประสิทธิ์ความถี่ แล้วจึงแปลงกลับมาเป็นภาพอีกครั้ง วิธีนี้มักใช้ในการลบลายเส้นรบกวนที่เป็นคาบหรือการทำภาพให้คมชัด (Sharpening)

ภาพที่ 2.3.1 การปรับปรุงคุณภาพของภาพ (Image Enhancement)

สำหรับในโครงการ RustVision AI วัตถุประสงค์หลักของการปรับปรุงคุณภาพภาพคือการแก้ปัญหา "ความไม่สม่ำเสมอของแสง" (Non-uniform Illumination) และการลด "สัญญาณรบกวน" (Noise) ที่เกิดจากสภาพแวดล้อมหน้างานจริง เนื่องจากภาพถ่ายโครงสร้างโลหะมักจะมีเงามืด เงาสะท้อน หรือความเบลอจากการถ่ายภาพ ซึ่งปัจจัยเหล่านี้ถือเป็นอุปสรรคสำคัญที่ทำให้โมเดล Deep Learning เกิดความผิดพลาดในการตรวจจับหรือแบ่งแยกพื้นที่สนิม ดังนั้น การประยุกต์ใช้เทคนิค Image Enhancement ที่เหมาะสมจึงเปรียบเสมือนการเตรียมข้อมูล (Data Preprocessing) ขั้นต้นที่ช่วยยกระดับความแม่นยำของระบบให้สูงขึ้นอย่างมีนัยสำคัญ

2.3.2. เทคนิค Histogram Equalization

ในเชิงคณิตศาสตร์และทฤษฎีการประมวลผลภาพ Histogram Equalization ไม่ใช่เพียงการยืดกราฟธรรมดา แต่เป็นการแปลงความหนาแน่นของความน่าจะเป็น (Probability Density Function: PDF) ของระดับสีเดิม ให้กลายเป็นการแจกแจงแบบสม่ำเสมอ (Uniform Distribution) เพื่อให้ทุกระดับความสว่างมีโอกาสปรากฏขึ้นในภาพเท่าๆ กัน

กระบวนการทำงานสามารถอธิบายเป็นลำดับขั้นตอนทางอัลกอริทึมได้ดังนี้

1. การคำนวณฮิสโตแกรม (Histogram Computation) ระบบจะเริ่มต้นด้วยการนับจำนวนพิกเซลในแต่ละระดับความเข้มแสง (0 ถึง 255) ของภาพต้นฉบับ สมมติให้ r_k เป็นระดับความเข้มแสงที่ k และ n_k เป็นจำนวนพิกเซลที่มีความเข้มแสงนั้น

ความน่าจะเป็นของแต่ละระดับความเข้มแสง p_r จะคำนวณได้จากสูตร

$$p_r(r_k) = \frac{n_k}{(MN)}$$

โดยที่ M และ N คือความกว้างและความสูงของภาพ (จำนวนพิกเซลทั้งหมด)

2. การสร้างฟังก์ชันการแจกแจงสะสม (Cumulative Distribution Function - CDF) ขั้นตอนที่เป็นหัวใจสำคัญคือการเปลี่ยนจากความน่าจะเป็นรายตัว (PDF) ให้เป็นความน่าจะเป็นสะสม (CDF) โดยการนำค่าความน่าจะเป็นของระดับความเข้มแสงปัจจุบันมารวมกับผลรวมของระดับก่อนหน้าทั้งหมด ตามสมการ

$$S_k = T(r_k) = (L-1)\sum_{j=0}^{k} p_r(r_j)$$

โดยที่ L คือจำนวนระดับความเข้มแสงที่เป็นไปได้ทั้งหมด (ปกติคือ 256 ระดับ)

3. การแปลงค่าความสว่าง (Mapping) ค่า S_k ที่คำนวณได้จากขั้นตอนก่อนหน้า จะเป็นตัวเลขทศนิยมในช่วง 0 ถึง 1 เมื่อนำมาคูณด้วยค่าสูงสุดของระดับสี (L-1 หรือ 255) และปัดเศษให้เป็นจำนวนเต็มที่ใกล้ที่สุด เราจะได้ "ค่าความสว่างใหม่" สำหรับพิกเซลนั้นๆ การทำเช่นนี้จะส่งผลให้กราฟฮิสโตแกรมที่เคยกระจุกตัวอยู่ช่วงใดช่วงหนึ่ง ถูก "คลี่" หรือ "เกลี่ย" ออกไปจนเต็มแกนความสว่าง

ข้อดีและข้อจำกัดในบริบทงานตรวจจับสนิม ข้อดีที่ชัดเจนที่สุดของเทคนิคนี้คือความสามารถในการกู้คืนรายละเอียดในภาพที่ถ่ายย้อนแสงหรือภาพที่มืดจนมองไม่เห็นรายละเอียดของสนิม ให้กลับมาปรากฏชัดเจนขึ้นโดยไม่ต้องปรับแต่งค่าด้วยมือ แต่ข้อจำกัดที่ร้ายแรงสำหรับงานวิศวกรรมคือ "การดำเนินการแบบเหมารวมทั้งภาพ" (Global Processing) หากภาพมีส่วนที่เป็นเงาเพียงเล็กน้อยและส่วนที่เหลือสว่างอยู่แล้ว การพยายามเกลี่ยแสงทั้งภาพอาจทำให้ส่วนที่สว่างอยู่แล้วขาวโพลนจนรายละเอียดหายไป (Saturation) หรืออาจไปขยายสัญญาณรบกวน (Noise) ในเงามืดให้กลายเป็นเม็ดสีที่รบกวนการทำงานของ AI ได้ ซึ่งเป็นเหตุผลที่นำไปสู่ความจำเป็นในการใช้เทคนิคขั้นสูงกว่าอย่าง CLAHE ที่จะกล่าวถึงในหัวข้อถัดไป

2.3.3. อัลกอริทึม CLAHE (Contrast Limited Adaptive Histogram Equalization) เพื่อลดผลกระทบจากแสงเงา

CLAHE คือเทคนิคการปรับปรุงภาพขั้นสูงที่ถูกพัฒนาขึ้นเพื่อแก้ไขข้อบกพร่องของ Adaptive Histogram Equalization (AHE) แบบดั้งเดิม โดยเฉพาะปัญหาการขยายสัญญาณรบกวน (Noise Amplification) ในบริเวณพื้นที่ภาพที่มีความสม่ำเสมอ (Homogeneous Areas)

หลักการทำงานของ CLAHE อาศัยกระบวนการทางคณิตศาสตร์ที่ละเอียดซับซ้อนกว่าการปรับกราฟแสงทั่วไป โดยสามารถอธิบายขั้นตอนการทำงานเชิงลึกได้ 4 ขั้นตอนสำคัญ ดังนี้

1. การแบ่งส่วนภาพและการคำนวณเฉพาะส่วน (Image Partitioning) ในขณะที่ Histogram Equalization (HE) ทั่วไปใช้ฟังก์ชันการแปลงค่าความเข้มแสง (Transformation Function) เดียวกับทั้งภาพ CLAHE เริ่มต้นด้วยการแบ่งภาพอินพุตออกเป็นตารางย่อยๆ ที่เรียกว่า "Contextual Regions" หรือ "Tiles" (โดยทั่วไปนิยมใช้ขนาด 8x8 หรือ 16x16 พิกเซล)
   เหตุผลทางคณิตศาสตร์: การแบ่งภาพเป็นส่วนย่อยช่วยให้ระบบสามารถสร้างฟังก์ชันการกระจายความน่าจะเป็น (PDF) ของระดับความเข้มแสงที่เป็น "อิสระ" ต่อกันในแต่ละพื้นที่ ทำให้สามารถแก้ปัญหาภาพที่มี Dynamic Range กว้าง เช่น ภาพที่มีทั้งเงามืดสนิทและแสงแดดจ้าในเฟรมเดียวกัน ซึ่งวิธีการแบบ Global HE ไม่สามารถจัดการได้
2. กลไกการจำกัดความเปรียบต่าง (Contrast Limiting Procedure) นี่คือขั้นตอนที่เป็นหัวใจสำคัญที่สุดที่แยก CLAHE ออกจาก AHE ปกติ ในทางทฤษฎี ความชัน (Slope) ของฟังก์ชันการแจกแจงสะสม (CDF) ในขั้นตอนการทำ Equalization จะแปรผันตรงกับความสูงของกราฟฮิสโตแกรม หากพื้นที่ใดของภาพมีสีที่ราบเรียบ (เช่น ผิวเหล็กที่ยังไม่เป็นสนิม) ฮิสโตแกรมจะมีลักษณะเป็นแท่งโด่งสูง (High Peak) ซึ่งจะส่งผลให้ฟังก์ชันการแปลงค่ามีความชันสูงมาก และนำไปสู่การขยายสัญญาณรบกวน (Noise) ในบริเวณนั้นจนผิดเพี้ยน
   CLAHE แก้ปัญหานี้โดยการกำหนดค่าพารามิเตอร์ที่เรียกว่า "Clip Limit" (β) เพื่อจำกัดความสูงของฮิสโตแกรมในแต่ละ Tile ไม่ให้เกินค่าที่กำหนด โดยมีสมการความสัมพันธ์เบื้องต้นคือ
   $$L_{clip} = \frac{M \times N}{L} \times \left(1 + \frac{\alpha}{100} \times S_{max}\right)$$
   (หมายเหตุ: ในทางปฏิบัติมักกำหนดเป็นค่าคงที่ เช่น 2.0 หรือ 4.0 เท่าของค่าเฉลี่ย) หากความถี่ของระดับสีใดสูงเกินขีดจำกัด L_{clip} ส่วนเกินนั้นจะถูกตัดออก (Clipping)
3. การกระจายคืนค่าส่วนเกิน (Redistribution) พิกเซลส่วนเกินที่ถูกตัดออกจากยอดกราฟในขั้นตอนที่แล้ว จะไม่ถูกทิ้งไปเฉยๆ เพื่อรักษาสมดุลของจำนวนพิกเซลรวมในภาพ (Total Histogram Count) ระบบจะนำส่วนเกินนี้มา "เกลี่ย" หรือกระจายคืนกลับเข้าไปยังทุกระดับความเข้มแสงในฮิสโตแกรมของ Tile นั้นๆ อย่างเท่าเทียมกัน

(Uniform Redistribution) ผลลัพธ์ที่ได้คือฮิสโตแกรมที่มีความสูงไม่เกินลิมิต แต่มีฐานที่กว้างขึ้น ซึ่งหมายถึงการเพิ่มรายละเอียดในส่วนอื่นๆ ของภาพแทนที่จะไปเน้นย้ำจุดรบกวนเพียงจุดเดียว

4. การประมาณค่าในช่วงแบบไบลิเนียร์ (Bilinear Interpolation) หากนำ Tile ที่ปรับปรุงแสงเสร็จแล้วมาวางต่อกันตรงๆ จะเกิดปรากฏการณ์ที่เรียกว่า "Blocking Artifacts" หรือรอยต่อระหว่างบล็อกที่ดูไม่เป็นธรรมชาติ เพื่อให้ภาพมีความต่อเนื่องเรียบเนียน CLAHE จึงใช้วิธีการคำนวณค่าพิกเซลใหม่โดยอ้างอิงจากจุดศูนย์กลางของ Tile รอบข้าง 4 ทิศทาง

สำหรับพิกเซลใดๆ ที่ตำแหน่ง (x, y) ค่าความเข้มแสงใหม่จะถูกคำนวณจากการถ่วงน้ำหนัก (Weighted Average) ของค่าฟังก์ชันการแปลงจาก Tile ทั้ง 4 ที่อยู่ล้อมรอบ ตามระยะห่างจริง ทำให้การเปลี่ยนแปลงของแสงเงาเป็นไปอย่างนุ่มนวล (Smooth Transition) ทั่วทั้งภาพ

Original Image

Histogram Equalized Image

ภาพที่ 2.3.3 อัลกอริทึม CLAHE

บทสรุปและการประยุกต์ใช้ในงานวิจัย ในบริบทของการตรวจจับสนิม การตั้งค่า "Clip Limit" ถือเป็นปัจจัยวิกฤต หากตั้งค่าต่ำเกินไป ภาพจะดูแบนและไม่เห็นรายละเอียดของพื้นผิวสนิม แต่หากตั้งค่าสูงเกินไป จะทำให้เม็ดเกรนของภาพ (Image Grain) ถูกมองว่าเป็นจุดสนิม (False Positive) จากการทดลองพบว่าการใช้ค่า Clip Limit ในช่วง 2.0 ถึง 4.0 ร่วมกับ Grid Size ขนาด 8x8 ให้ผลลัพธ์ที่ดีที่สุดในการเผยให้เห็น Texture ของสนิมที่ซ่อนอยู่ในเงามืด โดยไม่สูญเสียข้อมูลสำคัญทางวิศวกรรม

2.3.4. การแปลงปริภูมิสี (Color Space Conversion)

ในกระบวนการวิเคราะห์ภาพดิจิทัล (Digital Image Processing) การเลือกใช้ "ปริภูมิสี" หรือ Color Space ที่เหมาะสมถือเป็นปัจจัยวิกฤตที่มีผลต่อความแม่นยำของอัลกอริทึม โดยเฉพาะอย่างยิ่งในงานตรวจจับสนิมที่ต้องเผชิญกับสภาวะแสงที่ไม่สามารถควบคุมได้ (Uncontrolled Illumination) ปริภูมิสีคือโมเดลทางคณิตศาสตร์ที่ใช้อธิบายลักษณะของสีในรูปแบบของตัวเลขพิกัด (Coordinates) ซึ่งในงานวิจัยนี้ได้มีการศึกษาและประยุกต์ใช้โมเดลสีต่างๆ เพื่อดึงคุณลักษณะของสนิมออกมาให้ชัดเจนที่สุด ดังรายละเอียดต่อไปนี้

1. ปริภูมิสี RGB (Red, Green, Blue) และข้อจำกัด

   โดยพื้นฐานแล้ว ภาพดิจิทัลที่ได้รับจากเซนเซอร์กล้อง (Image Acquisition) จะถูกบันทึกในรูปแบบ RGB ซึ่งเป็นโมเดลแบบบวก (Additive Color Model) ที่ประกอบด้วยแม่สีแสง 3 สี ได้แก่ แดง (R), เขียว (G) และน้ำเงิน (B) ผสมกันเพื่อสร้างเฉดสีต่างๆ

   อย่างไรก็ตาม ในทางวิศวกรรมคอมพิวเตอร์วิทัศน์ ปริภูมิสี RGB มีข้อจำกัดร้ายแรงที่เรียกว่า "ความสัมพันธ์ระหว่างสีและความสว่างสูง" (High Correlation between Color and Intensity) กล่าวคือ ค่าของ R, G และ B ไม่ได้บอกแค่ "สีอะไร" แต่แฝงค่า "ความสว่าง" ไว้ในตัวด้วย หากมีการเปลี่ยนแปลงของแสงเพียงเล็กน้อย (เช่น เงาพาดผ่าน หรือแสงแดดจ้า) ค่าตัวเลขของทั้ง 3 ช่องสัญญาณจะเปลี่ยนแปลงไปพร้อมกันทั้งหมด ทำให้การกำหนดค่าขีดจำกัด (Threshold) เพื่อคัดแยกสีสนิม (ซึ่งมักเป็นสีน้ำตาลแดง) ทำได้ยากและไม่มีความเสถียร

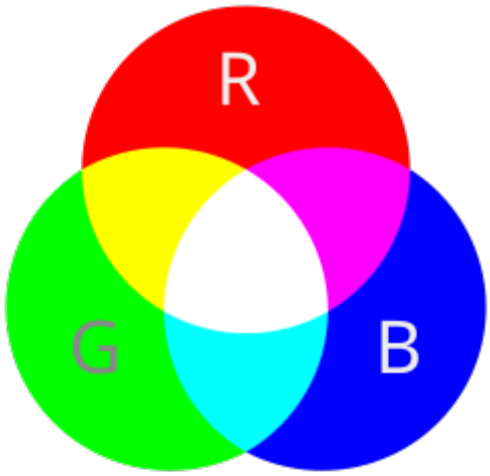

ภาพที่ 2.3.4.1 ปริภูมิสี RGB

2. การแปลงเป็นภาพระดับเทา (Grayscale Transformation)

เพื่อลดความซับซ้อนของข้อมูลและเตรียมภาพสำหรับขั้นตอนการปรับปรุงคุณภาพ (เช่น CLAHE) หรือการตรวจจับขอบ (Edge Detection) ระบบจำเป็นต้องแยกข้อมูล "ความเข้มแสง" (Luminance) ออกจากข้อมูลสี โดยการแปลงภาพสี RGB ให้เป็นภาพระดับเทา (Grayscale) ซึ่งมีขนาดข้อมูลเพียง 8 บิตต่อพิกเซล (ค่า 0-255) สมการทางคณิตศาสตร์ที่ใช้ในงานวิจัยนี้อ้างอิงตามมาตรฐาน ITU-R BT.601 ซึ่งคำนึงถึงการตอบสนองของดวงตามนุษย์ที่มีความไวต่อแสงสีเขียวมากที่สุด ดังนี้

$$Gray = 0.299 * R + 0.587 * G + 0.114 * B$$

การแปลงนี้ช่วยลดปริมาณข้อมูลที่ต้องประมวลผลลงถึง 3 เท่า (Dimensionality Reduction) และทำให้โมเดลสามารถโฟกัสไปที่ลวดลายพื้นผิว (Texture) และรูปร่างของการกัดกร่อนได้โดยไม่ถูกรบกวนจากความผันผวนของสี

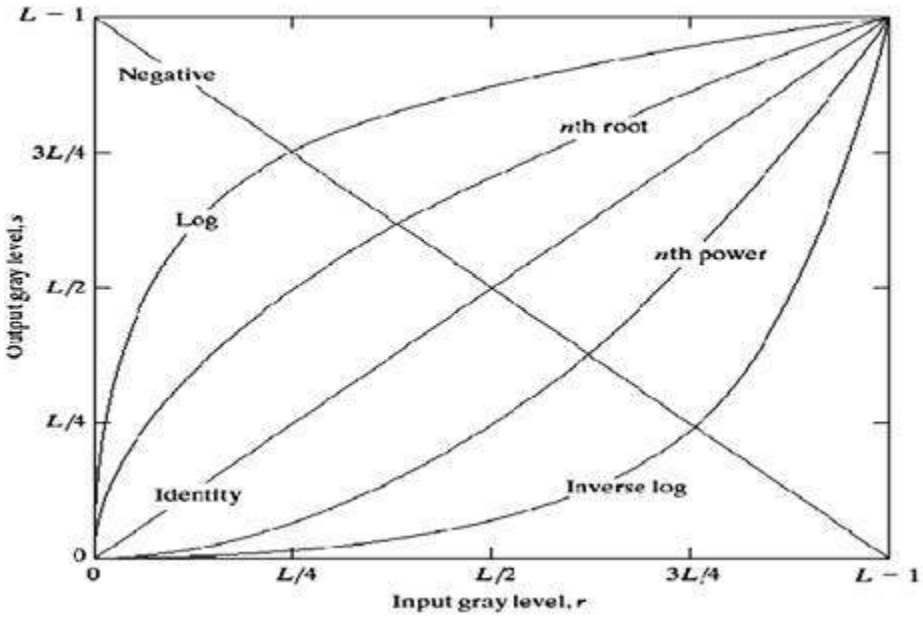

ภาพที่ 2.3.4.2 Gray Level

3. ปริภูมิสี HSV (Hue, Saturation, Value)

ปริภูมิสี HSV ถือเป็นหัวใจสำคัญในการ "ระบุชนิดของวัตถุ" ในงานวิจัยนี้ เนื่องจากเป็นโมเดลที่แยกองค์ประกอบของ "สี" ออกจาก "แสง" อย่างเด็ดขาด (Decoupling Chromaticity and Intensity) ประกอบด้วย 3 องค์ประกอบคือ

- Hue (H): ค่าเนื้อสี ระบุเป็นองศาในวงกลมสี (0-360 องศา) เช่น สีแดงอยู่ที่ 0 องศา, สีเขียว 120 องศา สนิมเหล็กส่วนใหญ่จะมีค่า Hue อยู่ในช่วงสีส้ม-

แดง (ประมาณ 10-30 องศา) ซึ่งเป็นคุณสมบัติคงที่ที่ไม่เปลี่ยนแปลงแม้แสงจะมืดหรือสว่าง

- Saturation (S): ค่าความอิ่มตัวของสี (0-100%) บ่งบอกความบริสุทธิ์ของสี สนิมมักมีความอิ่มตัวของสีที่ต่างจากคราบน้ำมันหรือฝุ่นละออง
- Value (V): ค่าความสว่างของแสง (0-100%)

ประโยชน์ทางวิศวกรรม: การแปลงภาพเป็น HSV ช่วยให้ระบบสามารถสร้าง "เงื่อนไขการตรวจจับที่ทนทานต่อแสง" (Illumination Invariant) ได้ โดยการสั่งให้ระบบตรวจสอบเฉพาะค่า H และ S เพื่อหาพื้นที่ที่เป็นสนิม และ "ละเลย" ค่า V ไป ทำให้แม้ว่าภาพจะมืดหรือมีเงาตกกระทบ ระบบก็ยังสามารถระบุได้ว่าวัตถุนั้นคือสนิม เพราะค่าเนื้อสี (Hue) ของสนิมไม่ได้เปลี่ยนไปตามความมืด

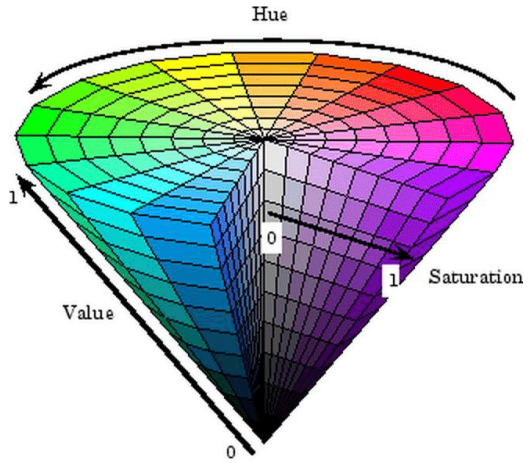

ภาพที่ 2.3.4.3 ปริภูมิสี HSV

4. ปริภูมิสี CIELAB (L*a*b)

ในขั้นตอนการวิเคราะห์ขั้นสูง งานวิจัยนี้ยังพิจารณาใช้ปริภูมิสี CIELAB ซึ่งเป็นมาตรฐานสากลที่ถูกออกแบบมาให้มีความ "สม่ำเสมอทางสายตา" (Perceptually Uniform) ซึ่งหมายความว่าระยะห่างระหว่างตัวเลขสีในระบบนี้ จะเท่ากับความแตกต่างของสีที่ตามนุษย์มองเห็นจริง

1. L*: ค่าความสว่าง (Lightness)
2. a*: แกนสีเขียว-แดง (Green-Red Axis)
3. b*: แกนสีน้ำเงิน-เหลือง (Blue-Yellow Axis)

การใช้ CIELAB มีประโยชน์อย่างยิ่งในการคำนวณ "ระดับความรุนแรงของสนิม" โดยการวัดระยะห่างของสี (Color Difference - Delta E) ระหว่างจุดที่สงสัยกับค่าสี

อ้างอิงของสนิมมาตรฐาน ช่วยให้สามารถแยกแยะสนิมใหม่ (สีส้มสด) ออกจากสนิมเก่า (สีน้ำตาลเข้ม) ได้แม่นยำกว่าการใช้ RGB ทั่วไป

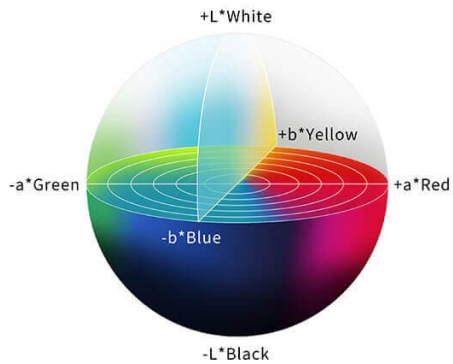

ภาพที่ 2.3.4.4 ปริภูมิสี CIELAB

2.3.5. การคำนวณสัดส่วนพื้นที่จากพิกเซลภาพ (Pixel-to-Area Calculation)

ในทางวิศวกรรมคอมพิวเตอร์วิทัศน์ การวัดขนาดพื้นที่ของวัตถุไม่ได้กระทำผ่านการวัดระยะทางกายภาพโดยตรง แต่กระทำผ่านกระบวนการ "นับจำนวนหน่วยย่อยที่สุดของภาพ" หรือที่เรียกว่า พิกเซล (Pixel) หลักการนี้ตั้งอยู่บนสมมติฐานของการแปลงสัญญาณอนาล็อกเป็นดิจิทัล (Quantization) โดยถือว่าภาพหนึ่งภาพคือเมทริกซ์ 2 มิติขนาดใหญ่ที่มีความกว้าง M และความสูง N $(M \times N)$ กระบวนการคำนวณสัดส่วนพื้นที่ความเสียหายจากสนิม เพื่อนำไปสู่การประเมินเกรดตามมาตรฐาน ASTM D610 มีลำดับขั้นตอนการทำงานทางคณิตศาสตร์ที่ละเอียดซับซ้อนกว่าการนับจำนวนธรรมดา โดยสามารถจำแนกออกเป็น 4 ขั้นตอนหลัก ดังนี้

1. การสร้างและแปลงแผนที่ความน่าจะเป็น (Probability Map Generation) เมื่อภาพผ่านกระบวนการประมวลผลด้วยโมเดล YOLO26-Seg ผลลัพธ์ขั้นต้นที่ได้จะไม่ใช่ภาพขาวดำทันที แต่จะเป็น "แผนที่ความน่าจะเป็น" (Probability Map) ซึ่งเป็นเมทริกซ์ที่มีขนาดเท่ากับภาพต้นฉบับ โดยแต่ละช่องของเมทริกซ์จะบรรจุค่าทศนิยมระหว่าง 0.0 ถึง 1.0 ที่บ่งบอกความมั่นใจของโมเดลว่า "พิกเซลนี้คือสนิมหรือไม่"
2. การกำหนดค่าขีดจำกัดเพื่อสร้างหน้ากากไบนารี (Binary Thresholding)เพื่อให้สามารถนับจำนวนได้ ระบบต้องทำการแปลงค่าความน่าจะเป็นแบบต่อเนื่อง (Continuous) ให้เป็นค่าแบบดิสครีต (Discrete) หรือค่าไบนารี โดยการกำหนดค่าขีดจำกัด (Thresholding value, T) ซึ่งโดยทั่วไปมักตั้งค่าไว้ที่ 0.5
    - หากพิกเซลใดมีค่าความน่าจะเป็นมากกว่า T จะถูกกำหนดค่าเป็น 1 (เป็นสนิม)

- หากพิกเซลใดมีค่าน้อยกว่าหรือเท่ากับ T จะถูกกำหนดค่าเป็น 0 (ไม่เป็นสนิม)

กระบวนการนี้จะทำให้ได้ "หน้ากากไบนารี" (Binary Mask) ที่แบ่งแยกพื้นที่สนิมออกจากพื้นหลังอย่างเด็ดขาด

3. การคำนวณสัดส่วนพื้นที่สัมพัทธ์ (Relative Area Calculation) ขั้นตอนที่เป็นหัวใจสำคัญคือการหาอัตราส่วนร้อยละของพื้นที่สนิมเทียบกับพื้นที่หน้าตัดทั้งหมด ซึ่งเป็นไปตามข้อกำหนดของมาตรฐาน ASTM D610 การคำนวณนี้ใช้หลักการหาผลรวมของสมาชิกในเมทริกซ์หน้ากากไบนารี หารด้วยจำนวนพิกเซลทั้งหมด แล้วคูณด้วย 100

โค้ดสำหรับวางในกล่องสมการ Word (สมการสัดส่วนร้อยละ)

$$P_{rust} = \left(\sum (i = 1)^{N} \sum (j = 1)^{M} B(i,j)\right) / (M \times N) \times 100$$

โดยที่

- P_{rust} คือ เปอร์เซ็นต์พื้นที่ความเสียหายจากสนิม
- $B(i,j)$ คือ ค่าของพิกเซลในตำแหน่งแถวที่ i และหลักที่ j ของหน้ากากไบนารี (มีค่าเป็น 0 หรือ 1)
- M, N คือ ความกว้างและความสูงของภาพ (จำนวนพิกเซลรวม)

4. การแปลงสู่พื้นที่ทางกายภาพจริง (Physical Area Estimation) ในงานวิศวกรรมขั้นสูงที่ต้องการทราบพื้นที่ความเสียหายในหน่วยตารางเซนติเมตร (cm^2) ระบบจำเป็นต้องทราบค่า "ความละเอียดเชิงพื้นที่" (Spatial Resolution) หรือสเกลของภาพ ซึ่งหาได้จากการเทียบกับวัตถุอ้างอิง (Reference Object) ที่ทราบขนาดจริงในภาพ เช่น การวางแผ่นเทียบสีที่มีขนาด 5x5 ซม.

โค้ดสำหรับวางในกล่องสมการ Word (สมการพื้นที่จริง): $Area_{real} = N_{rust} \frac{A_{ref}}{(N_{ref})}$

โดยที่

- $Area_{real}$ คือ พื้นที่สนิมจริง (หน่วย cm^2)
- N_{rust} คือ จำนวนพิกเซลสนิมที่นับได้
- A_{ref} คือ พื้นที่จริงของวัตถุอ้างอิง (เช่น 25 cm^2)
- N_{ref} คือ จำนวนพิกเซลของวัตถุอ้างอิงที่นับได้ในภาพ

นัยสำคัญทางวิศวกรรม การใช้วิธีคำนวณแบบ Pixel-to-Area นี้ช่วยขจัด "ความผิดพลาดจากอคติทางสายตา" (Subjective Error) ของมนุษย์ได้อย่างสมบูรณ์ โดยเฉพาะในกรณีของสนิมประเภทจุดกระจาย (Pinpoint Rusting) ที่ตามนุษย์มักประเมินความรุนแรงสูงกว่าความเป็นจริง เนื่องจากสีที่ตัดกันอย่างรุนแรง แต่คอมพิวเตอร์จะนับเฉพาะพื้นที่เม็ดสีที่เป็นสนิมจริงๆ เท่านั้น ทำให้การจัดลำดับเกรดความเสียหายมีความเที่ยงตรง (Accuracy) และแม่นยำ (Precision) สูงสุด

2.4 เครื่องมือและเทคโนโลยีในการพัฒนาระบบ

2.4.1. ภาษา Python และไลบรารีสำหรับงาน Data Science (NumPy, Pandas)

การพัฒนาระบบปัญญาประดิษฐ์และคอมพิวเตอร์วิทัศน์ในปัจจุบัน จำเป็นต้องอาศัยเครื่องมือที่มีประสิทธิภาพในการจัดการกับข้อมูลที่มีความซับซ้อนสูง ในโครงงานนี้ ผู้จัดทำได้เลือกใช้ภาษา Python เป็นภาษาหลักในการพัฒนา ร่วมกับไลบรารีมาตรฐานทางด้านวิทยาศาสตร์ข้อมูล ได้แก่ NumPy และ Pandas โดยมีรายละเอียดและทฤษฎีที่เกี่ยวข้องดังนี้

2.4.1.1 ภาษา Python (Python Programming Language)

ภาพที่ 2.4.1.1 ภาษา Python

Python คือภาษาระดับสูง (High-level Programming Language) ชนิดอินเทอร์พรีเตอร์ (Interpreter) ที่ได้รับความนิยมสูงสุดในงานด้านปัญญาประดิษฐ์ (Artificial Intelligence) และการเรียนรู้ของเครื่อง (Machine Learning) จุดเด่นที่ทำให้ Python เหมาะสมสำหรับงานวิจัยนี้ประกอบด้วย

1. ไวยากรณ์ที่อ่านง่ายและกระชับ (Readability and Conciseness) โครงสร้างภาษา Python ออกแบบมาให้ใกล้เคียงกับภาษาอังกฤษและลดความซับซ้อนของเครื่องหมายทางไวยากรณ์ (Syntax) ช่วยให้ผู้พัฒนาสามารถโฟกัสไปที่ตรรกะของการแก้ปัญหา (Algorithm Logic) มากกว่าการจัดการกับรายละเอียดปลีกย่อยของภาษา ซึ่งเอื้อต่อการทำ Prototyping และการแก้ไขบั๊กในอัลกอริทึมซับซ้อนอย่าง Deep Learning
2. ระบบนิเวศของไลบรารี (Rich Ecosystem) Python มีคลังไลบรารีแบบ Open Source จำนวนมหาศาลที่ถูกพัฒนาและตรวจสอบโดยชุมชนนักวิจัยทั่วโลก สำหรับงานวิจัยนี้ Python ทำหน้าที่เป็น "กาว" (Glue Language) ที่เชื่อมต่อการทำงานของส่วนประกอบต่างๆ เข้าด้วยกัน ตั้งแต่ไลบรารีประมวลผลภาพ (OpenCV), เฟรมเวิร์ก Deep Learning (PyTorch/YOLO), ไปจนถึงส่วนติดต่อผู้ใช้ (GUI Frameworks)
3. การจัดการหน่วยความจำอัตโนมัติ (Automatic Memory Management) Python มีระบบ Garbage Collection ที่คอยจัดการคืนหน่วยความจำที่ไม่ได้ใช้งานกลับสู่ระบบโดยอัตโนมัติ ช่วยลดความเสี่ยงของปัญหา Memory Leak ซึ่งเป็นเรื่องสำคัญเมื่อต้องประมวลผลภาพจำนวนมากต่อเนื่องเป็นเวลานาน

2.4.1.3 ไลบรารี NumPy (Numerical Python)

ภาพที่ 2.4.1.2 ไลบรารี NumPy (Numerical Python)

NumPy เป็นไลบรารีพื้นฐานที่สุดสำหรับการคำนวณทางวิทยาศาสตร์ใน Python และเปรียบเสมือนกระดูกสันหลังของระบบ Computer Vision เกือบทั้งหมด เนื่องจากภาพดิจิทัลใน

มุมมองของคอมพิวเตอร์คือ "เมทริกซ์ของตัวเลข" (Matrix of Numbers)

หลักการทำงานและความสำคัญของ NumPy มีดังนี้

1. โครงสร้างข้อมูล ndarray (N-dimensional Array) หัวใจสำคัญของ NumPy คือออบเจกต์ที่เรียกว่า ndarray ซึ่งเป็นอาร์เรย์หลายมิติที่มีประสิทธิภาพสูง ความแตกต่างสำคัญระหว่าง ndarray กับ List ปกติของ Python คือการจัดเก็บข้อมูลในหน่วยความจำแบบต่อเนื่อง (Contiguous Memory Block) และต้องเป็นข้อมูลชนิดเดียวกันทั้งหมด (Homogeneous Data Type) ทำให้ CPU สามารถอ่านและประมวลผลข้อมูลได้รวดเร็วกว่า List ปกติถึง 10-100 เท่า
2. การคำนวณแบบ Vectorization ในงานประมวลผลภาพ หากต้องการปรับความสว่างของภาพขนาด 1920x1080 พิกเซล การใช้ Loop วนรอบเพื่อบวกเลขทีละพิกเซลจะใช้เวลานานมาก NumPy แก้ปัญหานี้ด้วยเทคนิค Vectorization ซึ่งอนุญาตให้ประมวลผลข้อมูลทั้งอาร์เรย์ได้พร้อมกันในคำสั่งเดียว (SIMD - Single Instruction, Multiple Data) เช่น การนำเมทริกซ์ภาพมาบวกด้วยค่าคงที่ หรือการคูณกันของเมทริกซ์ (Matrix Multiplication) ซึ่งเป็นพื้นฐานของการทำงานในโครงข่ายประสาทเทียม
3. การจัดการมิติของข้อมูล (Broadcasting & Reshaping) NumPy มีฟังก์ชันสำหรับการเปลี่ยนรูปร่างของข้อมูล (Reshape) เช่น การเปลี่ยนภาพจาก 2 มิติ เป็นเวกเตอร์ 1 มิติเพื่อป้อนเข้าสู่ Model หรือการขยายขนาดของตัวกรอง (Filter) ให้มีขนาดเท่ากับภาพเพื่อทำการคำนวณ ความสามารถในการจัดการมิตินี้ (Broadcasting) ช่วยให้การเขียนอัลกอริทึมซับซ้อนสั้นและกระชับลง

2.4.1.3 ไลบรารี Pandas (Python Data Analysis Library)

ภาพที่ 2.4.1.3 ไลบรารี Pandas (Python Data Analysis Library)

ในขณะที่ NumPy เชี่ยวชาญด้านการคำนวณตัวเลข Pandas ถูกออกแบบมาเพื่อจัดการกับ "ข้อมูลที่มีโครงสร้าง" (Structured Data) หรือข้อมูลรูปแบบตาราง (Tabular Data) ซึ่งในโครงงานนี้ Pandas เข้ามามีบทบาทสำคัญในส่วนของการจัดการข้อมูลผลลัพธ์ (Post-processing Data Management)

องค์ประกอบและหน้าที่หลักของ Pandas ในโครงงาน

1. DataFrame และ Series
    - Series: คือโครงสร้างข้อมูลแบบ 1 มิติ (คล้ายคอลัมน์ใน Excel)
    - DataFrame: คือโครงสร้างข้อมูลแบบ 2 มิติ ที่เกิดจากการนำ Series หลายๆ ตัวมาประกอบกัน มีทั้งแถว (Index) และคอลัมน์ (Columns) ในระบบ RustVision AI ข้อมูลผลลัพธ์จากการตรวจจับ เช่น รหัสภาพ, จำนวนจุดสนิม, พื้นที่ความเสียหาย, และเกรดความรุนแรง จะถูกจัดเก็บในรูปแบบ DataFrame เพื่อให้ง่ายต่อการเรียกดูและแก้ไข
2. การวิเคราะห์ทางสถิติ (Statistical Analysis) Pandas มีฟังก์ชันสำเร็จรูปสำหรับการคำนวณค่าทางสถิติ เช่น การหาค่าเฉลี่ยพื้นที่ความเสียหาย ($\bar{x}$), การหาค่าสูงสุด/ต่ำสุด, หรือการจัดกลุ่มข้อมูล (Grouping) เพื่อสรุปผลการตรวจสอบประจำวัน ซึ่งช่วยให้ระบบสามารถสร้างรายงานสรุปผลที่มีความหมายทางวิศวกรรมได้ทันที
3. การจัดการไฟล์ข้อมูล (File I/O) จุดเด่นของ Pandas คือความสามารถในการอ่านและเขียนไฟล์ข้อมูลมาตรฐานได้หลากหลายรูปแบบ โดยเฉพาะไฟล์ CSV (Comma-Separated Values) และ Excel (.xlsx) ซึ่งช่วยให้ระบบสามารถส่งออกรายงานผลการตรวจสอบ (Inspection Report) เพื่อให้ผู้ใช้งานนำไปประมวลผลต่อในโปรแกรมสำนักงานทั่วไปได้อย่างสะดวกและรวดเร็ว

2.4.2 ไลบรารี OpenCV สำหรับการจัดการรูปภาพ

ภาพที่ 2.4.2 ไลบรารี OpenCV สำหรับการจัดการรูปภาพ

OpenCV คือไลบรารีฟังก์ชันการเขียนโปรแกรมแบบโอเพนซอร์ส (Open Source) ที่ถูกพัฒนาขึ้นโดยมุ่งเน้นที่งานด้านคอมพิวเตอร์วิทัศน์แบบเรียลไทม์ (Real-time Computer Vision) เดิมทีถูกพัฒนาด้วยภาษา C/C++ เพื่อให้มีประสิทธิภาพในการคำนวณสูงสุด แต่ในปัจจุบันได้มีการพัฒนา Python Wrapper เพื่อให้สามารถเรียกใช้งานฟังก์ชันต่างๆ ผ่านภาษา Python ได้อย่างสะดวก ซึ่งเป็นการผสมผสานระหว่างความง่ายในการเขียนโค้ดของ Python และความเร็วในการประมวลผลของ C++

สำหรับโครงงานนี้ OpenCV เปรียบเสมือน "เครื่องยนต์หลัก" ในการจัดการไฟล์ภาพและเตรียมข้อมูล (Preprocessing) ก่อนส่งต่อให้โมเดลปัญญาประดิษฐ์ โดยมีฟังก์ชันและหลักการทำงานที่สำคัญดังนี้

1. การอ่านและจัดการโครงสร้างภาพ (Image I/O & Structure) เมื่อ OpenCV อ่านไฟล์รูปภาพ (เช่น .jpg หรือ .png) เข้าสู่หน่วยความจำ ข้อมูลภาพจะถูกแปลงให้อยู่ในรูปแบบของ NumPy Array โดยอัตโนมัติ อย่างไรก็ตาม ข้อแตกต่างสำคัญทางเทคนิคที่วิศวกรต้องตระหนักคือ OpenCV จะเรียงลำดับช่องสัญญาณสีในรูปแบบ BGR (Blue-Green-Red) ซึ่งสลับกันกับมาตรฐาน RGB ที่ใช้ในจอภาพหรือไลบรารีอื่น
    - Channel 0: สีน้ำเงิน (Blue)
    - Channel 1: สีเขียว (Green)

- Channel 2: สีแดง (Red) การเข้าใจโครงสร้างนี้มีความจำเป็นอย่างยิ่งเมื่อต้องทำการแปลงสีหรือวิเคราะห์ค่าสีของสนิม หากไม่ทำการกลับลำดับสี (Color Conversion) ให้ถูกต้อง การวิเคราะห์ผลลัพธ์จะผิดพลาดทันที

2. อัลกอริทึมการแปลงภาพและปรับปรุงคุณภาพ (Transformation & Enhancement) OpenCV บรรจุชุดคำสั่งทางคณิตศาสตร์สำหรับประมวลผลภาพไว้จำนวนมาก ซึ่งถูกนำมาใช้ในขั้นตอน Preprocessing ของโครงงาน ได้แก่
    - cv2.cvtColor(): ใช้สำหรับแปลงปริภูมิสีตามทฤษฎีที่ได้กล่าวไว้ในหัวข้อ 2.3.4 เช่น การแปลงจาก BGR เป็น Grayscale หรือ BGR เป็น HSV เพื่อคัดแยกคุณลักษณะของสนิม
    - cv2.createCLAHE(): เป็นฟังก์ชันสำหรับทำ Histogram Equalization แบบปรับตัว (CLAHE) ซึ่งช่วยแก้ปัญหาแสงเงาบนผิวโลหะ ทำให้รายละเอียดของสนิมชัดเจนขึ้น
    - cv2.resize(): ใช้สำหรับปรับขนาดภาพให้เหมาะสมกับ Input Layer ของโมเดล YOLO (เช่น 640x640 พิกเซล) โดยใช้วิธีการประมาณค่า (Interpolation) แบบต่างๆ เพื่อลดการสูญเสียรายละเอียด

3. การวาดผลลัพธ์และแสดงผล (Drawing & Visualization) หลังจากที่โมเดลทำการตรวจจับและส่งค่าพิกัดกลับมา OpenCV จะทำหน้าที่ในการ "วาด" ข้อมูลเหล่านั้นทับลงไปบนภาพต้นฉบับเพื่อให้มนุษย์เข้าใจได้ง่าย (Human-readable Visualization)
    - cv2.rectangle(): ใช้สำหรับวาดกรอบสี่เหลี่ยม (Bounding Box) ล้อมรอบบริเวณที่ตรวจพบ
    - cv2.putText(): ใช้สำหรับเขียนข้อความระบุประเภทเกรดสนิมและค่าความเชื่อมั่น (Confidence Score) ลงบนภาพ
    - cv2.addWeighted(): ใช้สำหรับผสมสี (Alpha Blending) ระหว่างภาพต้นฉบับกับหน้ากากสี (Mask) เพื่อทำไฮไลต์พื้นที่สนิมแบบโปร่งใส ให้เห็นขอบเขตการกัดกร่อนชัดเจนโดยไม่บดบังเนื้อหาเดิม

4. ประสิทธิภาพการทำงาน (Performance) เหตุผลสำคัญที่เลือกใช้ OpenCV แทนไลบรารีจัดการภาพอื่นๆ (เช่น PIL) คือ "ความเร็ว" เนื่องจากฟังก์ชันพื้นฐานของ OpenCV ถูกเขียนด้วยภาษา C++ และมีการปรับแต่งให้รองรับการทำงานแบบขนาน (Multi-threading) และชุดคำสั่งพิเศษของ CPU (เช่น SIMD) ทำให้สามารถประมวลผลภาพความละเอียดสูงได้ในเวลาเพียงเสี้ยววินาที ซึ่งสอดคล้องกับความต้องการของระบบที่ต้องทำงานตอบสนองผู้ใช้ได้ทันที

2.4.3 Framework Flet สำหรับการพัฒนา Desktop Application

ภาพที่ 2.4.3 ไลบรารี OpenCV สำหรับการจัดการรูปภาพ

ในการพัฒนาซอฟต์แวร์สำหรับผู้ใช้งานทั่วไป (End-user Application) ส่วนติดต่อผู้ใช้ (User Interface - UI) ถือเป็นองค์ประกอบสำคัญที่มีผลต่อประสบการณ์การใช้งาน งานวิจัยนี้ได้เลือกใช้ Flet ซึ่งเป็นเฟรมเวิร์กสมัยใหม่สำหรับการสร้างแอปพลิเคชันแบบข้ามแพลตฟอร์ม (Cross-platform) ด้วยภาษา Python โดยมีรายละเอียดทางเทคนิคและเหตุผลในการเลือกใช้ดังนี้

2.4.3.1 ความเป็นมาและหลักการทำงาน (Overview & Architecture)

Flet เป็นเฟรมเวิร์กที่ช่วยให้นักพัฒนาสามารถสร้างแอปพลิเคชันที่มีส่วนติดต่อผู้ใช้สวยงามและตอบสนองได้ดี (Interactive UI) โดยไม่ต้องมีความรู้เกี่ยวกับภาษา Frontend เช่น HTML, CSS หรือ JavaScript และไม่ต้องเรียนรู้ภาษา Dart สิ่งที่ทำให้ Flet แตกต่างจาก GUI Framework ดั้งเดิมของ Python (เช่น Tkinter หรือ PyQt) คือการทำงานอยู่บนพื้นฐานของ Flutter ซึ่งเป็น UI Toolkit ประสิทธิภาพสูงของ

Google

สถาปัตยกรรมของ Flet มีการทำงานแบบ Server-Driven UI ซึ่งแบ่งออกเป็น 2 ส่วนหลัก คือ

1. Flet Python Client: เป็นส่วนที่รันโค้ดภาษา Python ซึ่งประกอบด้วยตรรกะของโปรแกรม (Business Logic) การเรียกใช้โมเดล AI และการจัดการข้อมูล
2. Flet Server/View: เป็นส่วนที่ทำหน้าที่แสดงผลหน้าจอโดยใช้ Flutter Engine เมื่อมีการเปลี่ยนแปลงสถานะในโค้ด Python (เช่น เมื่อตรวจจับสนิมเสร็จและต้องการแสดงภาพผลลัพธ์) ระบบจะส่งคำสั่งผ่านโปรโตคอลภายในเพื่อสั่งให้ Flutter วาดหน้าจอใหม่ทันที

2.4.3.2 คุณสมบัติเด่นที่สนับสนุนงานวิจัย (Key Features)

การเลือกใช้ Flet ในโครงการ RustVision AI มีข้อได้เปรียบทางวิศวกรรมซอฟต์แวร์ที่สำคัญ ดังนี้

1. การพัฒนาด้วย Python 100% (Pythonic Development) เนื่องจากระบบวิเคราะห์ภาพหลักถูกพัฒนาด้วย Python (NumPy, OpenCV, YOLO) การใช้ Flet ช่วยให้การเชื่อมต่อระหว่าง "ส่วนสมอง" (AI Logic) และ "ส่วนหน้าตา" (UI) เป็นไปอย่างราบรื่นในภาษาเดียวกัน ไม่ต้องมีการแปลงข้อมูลข้ามภาษา ลดความซับซ้อนและลดโอกาสเกิดข้อผิดพลาด (Bugs)
2. ส่วนติดต่อผู้ใช้ที่ทันสมัย (Modern Material Design) Flet มาพร้อมกับไลบรารี Controls (Wigdets) ที่อิงตามมาตรฐาน Material Design 3 ของ Google ทำให้แอปพลิเคชันมีรูปลักษณ์ที่สวยงาม ทันสมัย และเป็นมิตรกับผู้ใช้ (User-friendly) โดยไม่ต้องเสียเวลาออกแบบกราฟิกพื้นฐานเอง เช่น ปุ่มกด แถบสถานะ หรือตารางแสดงข้อมูล
3. การรองรับการทำงานแบบ Asynchronous (Asyncio Support) นี่คือคุณสมบัติที่สำคัญที่สุดสำหรับแอปพลิเคชัน AI ในขณะที่โมเดลกำลังประมวลผลภาพขนาดใหญ่ซึ่งใช้เวลานาน (Blocking Operation) Flet รองรับการทำงานแบบ Asynchronous ทำให้หน้าจอไม่ "ค้าง" (Freeze) ผู้ใช้ยังสามารถเห็นแถบความคืบหน้า (Progress Bar) หรือกดปุ่มยกเลิกได้ ซึ่งต่างจาก GUI แบบเก่าที่จะหยุดการทำงานทั้งหมดจนกว่าการคำนวณจะเสร็จสิ้น
4. ความสามารถข้ามแพลตฟอร์ม (Cross-Platform Capabilities) แม้เป้าหมายหลักจะเป็น Desktop Application แต่โค้ดที่เขียนด้วย Flet สามารถนำไปรันบน Web

Browser หรือ Mobile ได้โดยแทบไม่ต้องแก้ไขโค้ด (Single Codebase) ซึ่งเพิ่มความยืดหยุ่นในการต่อยอดโครงการในอนาคต

2.4.3.3 การจัดการสถานะ (State Management)

ในระบบที่มีการโต้ตอบซับซ้อน เช่น การอัปโหลดภาพ -> แสดงภาพตัวอย่าง -> กดประมวลผล -> แสดงผลลัพธ์ การจัดการสถานะของตัวแปร (State Management) เป็นเรื่องท้าทาย Flet ใช้แนวคิด Reactive UI กล่าวคือ การแสดงผลของหน้าจอจะผูกติดกับตัวแปรข้อมูล (Data Binding) เมื่อค่าของตัวแปรเปลี่ยน (เช่น ตัวแปร is_processing เปลี่ยนจาก False เป็น True) หน้าจอจะทำการอัปเดตตัวเองอัตโนมัติ (เช่น เปลี่ยนปุ่ม "Start" เป็น "Loading...") วิธีการนี้ช่วยลดความซับซ้อนของโค้ดในการสั่งวาดหน้าจอใหม่ด้วยมือ และทำให้สถานะของแอปพลิเคชันมีความถูกต้องเสมอ

2.4.4 ไลบรารี FPDF สำหรับการสร้างรายงานอัตโนมัติ

ในการพัฒนาระบบตรวจสอบทางวิศวกรรม นอกเหนือจากการประมวลผลข้อมูลที่แม่นยำแล้ว การนำเสนอผลลัพธ์ในรูปแบบเอกสารที่เป็นทางการ (Formal Documentation) ถือเป็นขั้นตอนสุดท้ายที่สำคัญ เพื่อให้ผู้ใช้งานสามารถนำข้อมูลไปใช้ประกอบการตัดสินใจหรือเก็บเป็นหลักฐานอ้างอิงได้ โครงงานนี้เลือกใช้ไลบรารี FPDF (Free PDF) เวอร์ชันสำหรับภาษา Python ในการพัฒนาระบบออกรายงานผลการตรวจสอบ (Inspection Report Generator) โดยมีรายละเอียดทางเทคนิคดังนี้

2.4.4.1 คุณลักษณะและหลักการทำงาน (Overview & Mechanism)

FPDF เป็นไลบรารีที่ช่วยให้นักพัฒนาสามารถสร้างไฟล์เอกสาร PDF ได้โดยตรงจากคำสั่งโปรแกรม (Code-driven Generation) โดยไม่จำเป็นต้องพึ่งพาซอฟต์แวร์ภายนอก (เช่น Adobe Acrobat) หรือ API สำเร็จรูป หลักการทำงานของ FPDF แตกต่างจากโปรแกรมประมวลผลคำทั่วไป (Word Processor) ตรงที่ใช้ระบบ "การระบุตำแหน่งแบบพิกัด" (Coordinate-based Layout)

- ระบบพิกัด (X, Y): การวางองค์ประกอบทุกอย่างในหน้ากระดาษ ไม่ว่าจะเป็นข้อความ รูปภาพ หรือเส้นตาราง จะต้องระบุตำแหน่งพิกัด X (แนวนอน) และ Y (แนวตั้ง) อย่างชัดเจน โดยมีจุดกำเนิด (0,0) อยู่ที่มุมซ้ายบนของกระดาษ วิธีการนี้ทำให้รายงานที่ได้มีความแม่นยำสูง (Pixel-perfect) และมีรูปแบบคงที่ (Fixed Layout) ไม่ผิดเพี้ยนเมื่อนำไปเปิดในอุปกรณ์ที่แตกต่างกัน

2.4.4.2 ความสามารถในการจัดการสื่อผสม (Multimedia Handling)

สำหรับรายงานการตรวจสอบสนิม ความท้าทายสำคัญคือการนำเสนอข้อมูลหลายประเภทรวมกันในหน้าเดียว ซึ่ง FPDF มีฟังก์ชันที่ตอบโจทย์งานวิจัยนี้อย่างครบถ้วน

1. การแทรกรูปภาพ (Image Embedding): ระบบสามารถดึงภาพผลลัพธ์จากการประมวลผลด้วย OpenCV (เช่น ภาพต้นฉบับและภาพที่ผ่านการทำ Masking แล้ว) มาวางเปรียบเทียบกันในรายงานได้ทันที รองรับไฟล์มาตรฐานทั้ง JPEG และ PNG พร้อมทั้งสามารถปรับขนาด (Scaling) ให้พอดีกับกรอบที่กำหนดไว้อัตโนมัติ
2. การสร้างตารางข้อมูล (Data Tables): FPDF รองรับการสร้างตาราง (Cell & MultiCell) เพื่อแสดงข้อมูลเชิงตัวเลข เช่น รหัสภาพ (Image ID), เปอร์เซ็นต์ความเสียหาย (Rust Percentage), และเกรดตามมาตรฐาน ASTM D610 ได้อย่างเป็นระเบียบ
3. การวาดกราฟิกพื้นฐาน (Basic Graphics): สามารถใช้คำสั่งวาดเส้นตรง (Line) หรือกรอบสี่เหลี่ยม (Rect) เพื่อสร้างส่วนหัวกระดาษ (Header) ท้ายกระดาษ (Footer) หรือเส้นแบ่งเนื้อหา เพื่อให้เอกสารมีความเป็นระเบียบเรียบร้อยและดูเป็นมืออาชีพ

2.4.5 ระบบจัดการฐานข้อมูลและสภาพแวดล้อมจำลอง (Database & Containerization)

เพื่อให้ระบบสามารถจัดเก็บประวัติการตรวจสอบ เรียกดูข้อมูลย้อนหลัง และออกรายงานสรุปผลได้อย่างมีประสิทธิภาพ โครงงานนี้จึงเลือกใช้ระบบจัดการฐานข้อมูลเชิงสัมพันธ์ (RDBMS) ที่มีความเสถียรสูง ทำงานภายใต้สภาพแวดล้อมจำลอง (Container) เพื่อลดปัญหาความเข้ากันได้ของซอฟต์แวร์ โดยมีรายละเอียดดังนี้

2.4.5.1 ระบบจัดการฐานข้อมูล PostgreSQL

ภาพที่ 2.4.5.1 ระบบจัดการฐานข้อมูล PostgreSQL

PostgreSQL เป็นระบบจัดการฐานข้อมูลเชิงวัตถุ-สัมพันธ์ (Object-Relational Database System - ORDBMS) ระดับ Enterprise ที่เป็นโอเพนซอร์ส การเลือกใช้ PostgreSQL แทนการบันทึกข้อมูลลงไฟล์ข้อความธรรมดา (เช่น JSON หรือ CSV) มีเหตุผลทางวิศวกรรมที่สำคัญคือ

1. ความสมบูรณ์ของข้อมูล (Data Integrity): PostgreSQL รองรับคุณสมบัติ ACID (Atomicity, Consistency, Isolation, Durability) อย่างครบถ้วน ทำให้มั่นใจได้ว่าข้อมูลผลการตรวจสอบสนิมจะไม่สูญหายหรือผิดเพี้ยนแม้เกิดเหตุขัดข้องระหว่างบันทึกข้อมูล ซึ่งสำคัญมากสำหรับงานตรวจสอบทางวิศวกรรม
2. ประสิทธิภาพในการสืบค้น (Query Performance): ระบบอนุญาตให้ใช้ภาษา SQL (Structured Query Language) ในการคัดกรองข้อมูลที่ซับซ้อน เช่น "แสดงรายการตรวจสอบเฉพาะสนิมเกรด 8 ที่เกิดขึ้นในเดือนมกราคม" ซึ่งการทำเช่นนี้ด้วยระบบไฟล์ปกติจะต้องใช้ทรัพยากรการประมวลผลสูง
3. โครงสร้างข้อมูลแบบมีโครงสร้าง (Structured Schema): การจัดเก็บข้อมูลในรูปแบบตาราง (Table) ที่มีความสัมพันธ์กัน (Relation) ช่วยลดความซ้ำซ้อนของข้อมูล (Normalization) เช่น การแยกตารางข้อมูลผู้ใช้งาน (Users) ออกจากตารางประวัติการตรวจสอบ (Inspection Logs)

2.4.5.2 การจำลองสภาพแวดล้อมด้วย Docker

ในการพัฒนาระบบที่มีส่วนประกอบซับซ้อน (Database, Python Libraries) ปัญหาที่พบบ่อยคือ "Environment Inconsistency" หรือการที่โปรแกรมทำงานได้บนเครื่องผู้พัฒนาแต่ไม่สามารถทำงานได้บนเครื่องอื่น โครงงานนี้จึงนำ Docker มาใช้ในการจัดการ Database Server

1. หลักการของ Containerization: Docker ช่วยบรรจุ PostgreSQL และการตั้งค่าทั้งหมด (Configuration) ลงใน "Container" ซึ่งเป็นกล่องจำลองสภาพแวดล้อมที่แยกเป็นอิสระจากระบบปฏิบัติการหลัก (Host OS) ทำให้ไม่ต้องกังวลเรื่องเวอร์ชันของซอฟต์แวร์ที่ขัดแย้งกัน
2. ความสะดวกในการติดตั้ง (Deployment): การใช้ Docker Compose ช่วยให้สามารถรันระบบฐานข้อมูลขึ้นมาได้ด้วยคำสั่งเดียว (Single Command) โดยไม่ต้องไล่ติดตั้งซอฟต์แวร์ PostgreSQL ทีละขั้นตอน ทำให้ระบบมีความยืดหยุ่นสูง สามารถนำไปรันบนคอมพิวเตอร์เครื่องใดก็ได้ที่มี Docker ติดตั้งอยู่
3. การแยกส่วนการทำงาน (Isolation): การรัน Database ใน Container ช่วยรักษาความสะอาดของเครื่องคอมพิวเตอร์หลัก ไม่ทิ้งไฟล์ขยะหรือเปิดพอร์ตค้างไว้เมื่อเลิกใช้งาน ซึ่งเหมาะสมอย่างยิ่งสำหรับการพัฒนาโปรเจกต์บนเครื่องส่วนตัว (Local Machine)

2.5 งานวิจัยที่เกี่ยวข้อง

2.5.1 งานวิจัยในประเทศ

ตะวันชัช ผิวงาม (2564) ได้ศึกษาเรื่อง การตรวจจับสนิมบนคลิปยึดรางตัวอีในระบบยึดเหนี่ยวรางรถไฟ โดยมีวัตถุประสงค์เพื่อพัฒนาระบบอัตโนมัติในการตรวจสอบอุปกรณ์ยึดเหนี่ยวราง (Rail Clips) ซึ่งเป็นชิ้นส่วนสำคัญที่มักเกิดปัญหาการสูญหายหรือเป็นสนิมได้ง่าย คณะผู้วิจัยได้นำเทคโนโลยีการเรียนรู้เชิงลึก (Deep Learning) มาประยุกต์ใช้ร่วมกับภาพถ่ายจากหน้างานจริงบนรางรถไฟ ซึ่งมีความท้าทายสูงจากสภาพแวดล้อมที่ซับซ้อน เช่น หินโรยทางที่มีสีใกล้เคียงกับสนิม และคราบน้ำมันเครื่องจักร โดยทำการฝึกสอนโมเดลให้สามารถจำแนกสถานะของอุปกรณ์ออกเป็น 3 กลุ่มหลัก ได้แก่ สภาพปกติ สภาพเป็นสนิม และสภาพสูญหาย ผลการวิจัยพบว่า ระบบที่พัฒนาขึ้นสามารถระบุตำแหน่งและความผิดปกติของคลิปยึดรางได้อย่างแม่นยำและรวดเร็ว ซึ่งช่วยลดความเสี่ยงอันตรายของเจ้าหน้าที่ในการเดินสำรวจทางรางด้วยเท้า และเพิ่มประสิทธิภาพในการวางแผนบำรุงรักษาเชิงป้องกันก่อนที่จะเกิดอุบัติเหตุ

ณิศวรา ศรีแก้ว (2567) ได้ศึกษาเรื่อง การประยุกต์ใช้การเรียนรู้ของเครื่องเพื่อตรวจจับภาพชิ้นส่วนที่มีสนิมของโครงสร้างเหล็กอาคารโกดังสินค้า โดยมุ่งเน้นการยกระดับมาตรฐานการตรวจสอบความปลอดภัยของอาคารเก่า คณะผู้วิจัยได้รวบรวมชุดข้อมูลภาพจำนวน 1,155 ภาพ และนำมาผ่านกระบวนการวิเคราะห์ค่าสี (RGB Analysis) เพื่อป้อนเข้าสู่โมเดลโครงข่ายประสาทเทียมแบบคอนโวลูชัน (Convolutional Neural Networks - CNN) จุดเด่นของงานวิจัยนี้คือการผสานมาตรฐานทางวิศวกรรม ASTM D610 เข้ากับระบบ AI โดยให้โมเดลเรียนรู้การจัดเกรดความรุนแรงของสนิมตามมาตรฐานจริงที่แบ่งระดับความเสียหายเป็น 11 ระดับ (เกรด 0-10) ผลการวิจัยพบว่า แบบจำลองสามารถทำนายระดับความรุนแรงของสนิมได้ถูกต้องแม่นยำถึงร้อยละ 79.48 ซึ่งเพียงพอสำหรับการนำไปใช้เป็นเครื่องมือช่วยวิศวกรในการคัดกรองและประเมินสภาพความปลอดภัยของโครงสร้างอาคารในเบื้องต้นได้อย่างมีประสิทธิภาพ

จิรทีปต์ ชัยสิงห์ (2566) ได้ศึกษาเรื่อง การตรวจสอบความเสียหายโดยใช้ปัญญาประดิษฐ์สำหรับการประเมินพื้นสะพาน โดยเสนอแนวทางการใช้เทคโนโลยีอากาศยานไร้คนขับ (UAV) หรือโดรนบินถ่ายภาพใต้ท้องสะพานคอนกรีตเพื่อเก็บข้อมูลในจุดอับสายตาหรือจุดที่มนุษย์เข้าถึงได้ยาก คณะผู้วิจัยเลือกใช้โมเดล Region-based Convolutional Neural Networks (R-CNN) ในการประมวลผลภาพเพื่อตรวจจับ "เหล็กเสริมที่โผล่ออกมา (Exposed Rebar)" และรอยสนิมที่กัดกร่อนคอนกรีต ผลการวิจัยเปรียบเทียบพบว่า การกำหนดกรอบการตรวจจับแบบ "พื้นที่" (Area-based) ให้ผลลัพธ์ที่แม่นยำและสามารถนำไปใช้งานต่อในการคำนวณปริมาณวัสดุสำหรับซ่อมบำรุงได้ดีกว่าการระบุเป็นจุดเล็กๆ (Point-

based) ช่วยลดข้อผิดพลาดจากการตรวจสอบด้วยสายตา (Visual Inspection) และลดความเสี่ยงในการทำงานบนที่สูง

Youkachen S. (2562) ได้ศึกษาเรื่อง การแบ่งส่วนรอยบกพร่องของผิวเหล็กแผ่นรีดร้อนโดยใช้ Convolutional Auto-Encoder งานวิจัยนี้มุ่งเน้นการควบคุมคุณภาพในกระบวนการผลิตอุตสาหกรรมเหล็ก โดยเสนอการใช้โครงข่ายประสาทเทียมแบบการเรียนรู้โดยไม่มีผู้สอน (Unsupervised Learning) ที่เรียกว่า Convolutional Auto-Encoder (CAE) ร่วมกับเทคนิคการทำภาพให้คมชัด (Sharpening) เพื่อแก้ปัญหาความไม่สม่ำเสมอของแสงในโรงงาน หลักการคือให้โมเดลเรียนรู้ลักษณะของ "พื้นผิวปกติ" จนชำนาญ และเมื่อเจอส่วนที่เป็นรอยบกพร่องหรือสนิม โมเดลจะสามารถแยกแยะความแตกต่างนั้นออกมาได้ (Anomaly Detection) ผลการวิจัยพบว่า อัลกอริทึมสามารถแบ่งส่วนพื้นที่เสียหาย (Segmentation) ออกจากผิวเหล็กดีได้อย่างมีประสิทธิภาพ แม้ในสภาพแวดล้อมที่มีสัญญาณรบกวนสูง ช่วยลดของเสียในกระบวนการผลิต

Nutchanon Suvittawat (2568) ได้ศึกษาเรื่อง ความก้าวหน้าในการตรวจจับรอยบกพร่องของผิวเครื่องบินโดยใช้คอมพิวเตอร์วิทัศน์ งานวิจัยนี้มีความสำคัญอย่างยิ่งต่อความปลอดภัยในการบิน โดยผู้วิจัยได้ใช้โดรนบินเก็บภาพผิวเครื่องบินโดยสาร Boeing 747 ที่ปลดระวางแล้ว เพื่อสร้างชุดข้อมูล (Dataset) ของสนิมและรอยแตกร้าวบนวัสดุอลูมิเนียมอัลลอยด์ การศึกษาได้ทำการเปรียบเทียบประสิทธิภาพระหว่างโมเดลตรวจจับวัตถุยอดนิยมสองตัว คือ YOLOv9 และ RT-DETR (Real-Time DEtection TRansformer) ผลการวิจัยพบว่า โมเดลทั้งสองให้ค่าความแม่นยำเฉลี่ย (mAP50) อยู่ในช่วง 0.70–0.75 ซึ่งใกล้เคียงกัน แต่ YOLOv9 มีความโดดเด่นในด้านความเร็วในการประมวลผลที่เหนือกว่า จึงเหมาะสมกว่าสำหรับการนำไปใช้ในระบบตรวจสอบด่วน (Rapid Inspection) ในลานจอดเครื่องบินที่มีข้อจำกัดด้านเวลา

Chaiwat Punyammaree และ Somyot Kaitwanidvilai (2568) ได้ศึกษาเรื่อง การใช้ Deep Learning ที่ปรับให้เหมาะสมด้วย PSO สำหรับการตรวจจับการกัดกร่อนบนหัวอ่าน/เขียนฮาร์ดดิสก์ งานวิจัยนี้เจาะลึกไปที่การตรวจจับสนิมในระดับจุลภาค (Micro-scale) บนชิ้นส่วนอิเล็กทรอนิกส์ที่มีความละเอียดสูง โดยพัฒนาโมเดล U-Net เพื่อวิเคราะห์ภาพจากกล้องจุลทรรศน์อิเล็กตรอน (SEM) ความน่าสนใจอยู่ที่การนำอัลกอริทึมหาค่าเหมาะสมแบบกลุ่มอนุภาค หรือ Particle Swarm Optimization (PSO) มาช่วยค้นหาค่าพารามิเตอร์ที่ดีที่สุดให้โมเดลโดยอัตโนมัติ ผลการวิจัยพบว่า โมเดลที่ผ่านการปรับจูนด้วย PSO สามารถตรวจจับหลุมสนิมขนาดไมครอนได้ด้วยค่า F1-score สูงถึง 79.60% และมีความแม่นยำในการนับจำนวนจุดสนิมสูงกว่าผู้เชี่ยวชาญที่เป็นมนุษย์ (86.9% เทียบ

กับ 72.7%) ซึ่งช่วยลดความผิดพลาดจากความเหนื่อยล้าของสายตาในการตรวจสอบผ่านกล้องจุลทรรศน์เป็นเวลานาน

อังคณา เมืองใจ (2566) ได้ศึกษาเรื่อง การตรวจจับสนิมโดยวิธีเรขาคณิต โดยนำเสนออัลกอริทึมทางเลือกที่ไม่ได้พึ่งพาเทคโนโลยี Deep Learning ที่ซับซ้อน แต่เน้นการวิเคราะห์คุณลักษณะทาง "เรขาคณิต" และ "พื้นผิว" (Texture Analysis) ของรอยสนิมแทน เพื่อแก้ปัญหาคลาสสิกของ Computer Vision คือความผิดพลาดเมื่อสีของสนิมกลมกลืนไปกับสีของพื้นหลัง (Camouflage) คณะผู้วิจัยได้พัฒนาอัลกอริทึมที่ตรวจจับความขรุขระและความไม่สม่ำเสมอของรูปร่างสนิม ผลการวิจัยพบว่า วิธีการนี้ช่วยเพิ่มความทนทาน (Robustness) ให้กับระบบตรวจจับ ทำให้สามารถแยกแยะรอยสนิมจริงออกจากคราบสกปรก เงา หรือสีเพี้ยนที่มีลักษณะคล้ายกันได้อย่างแม่นยำ เป็นทางเลือกที่ใช้ทรัพยากรประมวลผลน้อยแต่ได้ผลลัพธ์ที่มีประสิทธิภาพ

K. Sodsai (2562) ได้ศึกษาเรื่อง การตรวจจับการกัดกร่อนภายใต้พื้นผิวเคลือบโดยวิธีการทดสอบกระแสไหลวน งานวิจัยนี้แตกต่างจากงานด้าน Image Processing ทั่วไป เพราะมุ่งเน้นการตรวจหา "สนิมที่มองไม่เห็น" ซึ่งซ่อนอยู่ใต้ชั้นสี (Corrosion Under Insulation/Coating) โดยใช้เทคนิคการทดสอบแบบไม่ทำลาย (Non-Destructive Testing - NDT) ประเภท Eddy Current มาตรวจวัดการเปลี่ยนแปลงของสนามแม่เหล็กที่เกิดจากการกัดกร่อนของเนื้อเหล็ก และนำสัญญาณที่ได้มาสร้างเป็นภาพจำลอง (Image Reconstruction) ผลการวิจัยพบว่า ระบบสามารถระบุตำแหน่งและประเมินความลึกของการกัดกร่อนที่ซ่อนอยู่ได้อย่างชัดเจน ซึ่งเป็นสิ่งที่กล้องถ่ายภาพทั่วไปไม่สามารถทำได้ ช่วยให้สามารถซ่อมบำรุงท่อส่งก๊าซหรือถังเก็บสารเคมีได้ก่อนที่จะเกิดการรั่วไหล

Jirasak Ji และ Warut Pannakkong (2566) ได้ศึกษาเรื่อง ระบบนับจำนวนแผ่นเหล็กเมทัลชีทโดยใช้คอมพิวเตอร์วิทัศน์ งานวิจัยนี้เป็นการประยุกต์ใช้ในสายการผลิตจริงเพื่อควบคุมคุณภาพสินค้าโดยพัฒนาระบบประมวลผลภาพ (Image Processing) เพื่อตรวจจับ "ขอบ" ของแผ่นเหล็กเมทัลชีทที่วางซ้อนกันและทำการนับจำนวนแบบ Real-time แม้จุดประสงค์หลักคือการนับจำนวน แต่ผลการวิจัยพบว่าเทคนิคการตรวจจับขอบ (Edge Detection) ที่พัฒนาขึ้นมีความแม่นยำสูง และสามารถนำไปประยุกต์ใช้ในการตรวจสอบ "สนิมบริเวณขอบตัด" (Cut Edge Corrosion) ซึ่งเป็นจุดอ่อนสำคัญที่มักเกิดสนิมได้ง่ายที่สุดของแผ่นเมทัลชีท ช่วยให้โรงงานสามารถคัดแยกแผ่นที่มีตำหนิบริเวณขอบออกได้ทันทีก่อนส่งมอบลูกค้า

เนตรชนก ทองดอนเหมือน (2564) ได้ศึกษาเรื่อง การจัดการมาตรฐานกระบวนการงานเชื่อมของรั้วเหล็กและการตรวจจับสนิม งานวิจัยนี้มุ่งเน้นการควบคุมคุณภาพผลิตภัณฑ์รั้วท่อเหล็กสำเร็จรูป

โดยพัฒนาระบบประมวลผลภาพเพื่อตรวจสอบคุณภาพของแนวเชื่อม (Welding Seams) ว่ามีความสมบูรณ์หรือไม่ และตรวจหาร่องรอยสนิมเริ่มต้นที่มักเกิดขึ้นบริเวณรอยเชื่อมเนื่องจากความร้อนทำลายชั้นเคลือบกันสนิม ผลการวิจัยพบว่า ระบบอัตโนมัตินี้สามารถคัดกรองชิ้นงานที่ไม่ได้มาตรฐาน (Defect Detection) ออกจากสายการผลิตได้ก่อนขั้นตอนการบรรจุภัณฑ์และส่งมอบ ซึ่งช่วยลดค่าใช้จ่ายในการเคลมสินค้า ลดการซ่อมแซมภายหลัง และสร้างความมั่นใจในการรับประกันคุณภาพสินค้าให้กับผู้บริโภค

2.5.2 งานวิจัยต่างประเทศ

Pierclaudio Savino (2025) ได้ศึกษาเรื่อง การหาปริมาณพื้นที่การกัดกร่อนอัตโนมัติบนเสาส่งสัญญาณเหล็กโดยใช้เทคนิคโฟโตแกรมเมตรีจากอากาศยานไร้คนขับและโครงข่ายประสาทเทียมเชิงลึก (Automated corrosion surface quantification in steel transmission towers) โดยนำเสนอแนวทางการใช้โมเดล DeepLabv3+ ร่วมกับโครงสร้างพื้นฐานแบบ MobileNetV2 ในการแบ่งส่วนภาพทางความหมาย (Semantic Segmentation) เพื่อตรวจจับและระบุตำแหน่งของสนิมบนโครงสร้างเสาไฟฟ้าแรงสูง โดยใช้ชุดข้อมูลภาพถ่ายจากโดรนจำนวน 999 ภาพ ที่มีความละเอียดหลากหลายมาทำการฝึกสอนโมเดล และนำผลลัพธ์การตรวจจับไปซ้อนทับกับแผนที่ภาพถ่ายทางอากาศ (Orthomosaics) เพื่อคำนวณพื้นที่เสียหายจริง ผลการวิจัยพบว่า โมเดลสามารถแยกแยะบริเวณที่เป็นสนิมออกจากพื้นหลังที่ซับซ้อนได้อย่างมีประสิทธิภาพ โดยมีค่าความถูกต้อง (Validation Accuracy) สูงถึง 90.8% และค่าความสูญเสีย (Validation Loss) ต่ำเพียง 0.23 ซึ่งแสดงให้เห็นว่าการบูรณาการระหว่างโดรนและ AI สามารถยกระดับการตรวจสอบโครงสร้างพื้นฐานขนาดใหญ่ให้รวดเร็วและปลอดภัยยิ่งขึ้น

Zoha Ameli และ Eric Landis (2024) ได้ศึกษาเรื่อง Deep Learning-Based Steel Bridge Corrosion Segmentation and Condition Rating Using Mask RCNN and YOLOv8 โดยมีวัตถุประสงค์เพื่อแก้ปัญหาความท้าทายในการตรวจสอบโครงสร้างสะพานเหล็กขนาดใหญ่ที่เข้าถึงยากและมีความซับซ้อนของโครงสร้าง คณะผู้วิจัยได้ดำเนินการเปรียบเทียบประสิทธิภาพระหว่างโมเดลการเรียนรู้เชิงลึกสองประเภทที่มีจุดเด่นต่างกัน คือ Mask Region-based Convolutional Neural Networks (Mask R-CNN) ซึ่งเน้นความละเอียดในการแบ่งส่วนภาพ และ You Only Look Once Version 8 (YOLOv8) ซึ่งเน้นความรวดเร็วในการตรวจจับวัตถุ การทดลองกระทำโดยใช้ชุดข้อมูลภาพถ่ายความละเอียดสูงจากโดรน (UAV) ที่บินสำรวจสะพานจริงและนำมาฝึกสอนโมเดลให้สามารถจำแนกสภาพความเสียหายของสนิมออกเป็นระดับต่างๆ ตามมาตรฐานความปลอดภัยทางวิศวกรรม ผลการวิจัยพบว่า แม้ Mask R-CNN จะให้รายละเอียดขอบเขตของสนิมที่คมชัดกว่าเล็กน้อย แต่โมเดล YOLOv8 กลับมีประสิทธิภาพโดยรวมที่เหมาะสมกว่าสำหรับการใช้งานในภาคสนามจริง เนื่องจากมีความเร็วในการประมวลผล (Inference Speed) ที่สูงกว่ามาก ซึ่งเอื้อต่อการนำไปใช้ในระบบตรวจสอบ

แบบเรียลไทม์หรือการประมวลผลวิดีโอสตรีมมิ่ง ในขณะที่ยังคงรักษาค่าความแม่นยำในการระบุตำแหน่งและความรุนแรงของสนิมไว้ได้ในระดับที่น่าพึงพอใจและเพียงพอต่อการตัดสินใจซ่อมบำรุง

Mingjiao Fu (2024) ได้ศึกษาเรื่อง Detection and recognition of metal surface corrosion based on CBG-YOLOv5s โดยมุ่งเน้นการแก้ปัญหาความผิดพลาดในการตรวจจับสนิมที่เกิดขึ้นในสภาพแวดล้อมทางทะเล (Marine Environment) ซึ่งมักมีปัจจัยรบกวนสูง เช่น แสงสะท้อนจากผิวน้ำ เงา และพื้นหลังที่เคลื่อนไหวได้ คณะผู้วิจัยได้นำเสนอสถาปัตยกรรมโครงข่ายประสาทเทียมที่ปรับปรุงใหม่ในชื่อ CBG-YOLOv5s ซึ่งพัฒนาต่อยอดมาจากโมเดล You Only Look Once Version 5 Small (YOLOv5s) โดยหัวใจสำคัญคือการผนวกโมดูล Convolutional Block Attention Module (CBAM) เข้าไปในโครงสร้างหลักของโมเดล เพื่อทำหน้าที่เสมือนกลไกการคัดกรองที่ช่วยให้โมเดลสามารถ "เพ่งความสนใจ" ไปยังคุณลักษณะสำคัญของสนิม เช่น พื้นผิวที่ขรุขระและการเปลี่ยนแปลงของสี ได้ดียิ่งขึ้น พร้อมทั้งลดความสนใจต่อสัญญาณรบกวนจากพื้นหลัง ผลการทดสอบเชิงประจักษ์แสดงให้เห็นว่าโมเดล CBG-YOLOv5s มีค่าความแม่นยำเฉลี่ย (mAP) สูงกว่าโมเดลต้นฉบับอย่างมีนัยสำคัญ และมีความเสถียรสูงในการจำแนกเกรดความรุนแรงของสนิม แม้ในภาพถ่ายที่มีสภาพแสงไม่เอื้ออำนวย ซึ่งช่วยเพิ่มประสิทธิภาพให้กับการตรวจสอบแท่นขุดเจาะหรือเรือเดินสมุทร

Hoang Nguyen (2025) ได้ศึกษาเรื่อง Semi-Supervised Learning Approach for Image-Based Corrosion Quantification on Water Resources Infrastructure โดยมีเป้าหมายเพื่อจัดการกับปัญหาคอขวดสำคัญในการพัฒนาระบบ AI สำหรับงานวิศวกรรมโยธา นั่นคือการขาดแคลนข้อมูลภาพที่มีการระบุฉลาก (Labeled Data) ซึ่งต้องใช้ผู้เชี่ยวชาญในการทำข้อมูลจำนวนมาก ผู้วิจัยจึงเสนอแนวทางการใช้เทคนิคการเรียนรู้แบบกึ่งมีผู้สอน (Semi-Supervised Learning - SSL) เข้ามาช่วย โดยกระบวนการวิจัยเริ่มจากการใช้ข้อมูลภาพที่มีฉลากเพียงจำนวนเล็กน้อยในการฝึกสอนโมเดลเบื้องต้น (Teacher Model) จากนั้นนำโมเดลไปทำนายผลบนข้อมูลดิบจำนวนมหาศาลเพื่อสร้างฉลากเทียม (Pseudo-labels) แล้วนำกลับมาฝึกสอนโมเดลหลัก (Student Model) ซ้ำอีกครั้ง ผลการวิจัยพบว่าวิธีการนี้ช่วยลดระยะเวลาและต้นทุนในการเตรียมข้อมูลลงได้มากกว่าร้อยละ 80 ในขณะที่โมเดลยังคงความสามารถในการแบ่งส่วนพื้นที่เสียหาย (Segmentation) และประเมินปริมาณพื้นที่การกัดกร่อนบนประตูระบายน้ำและโครงสร้างชลประทานได้แม่นยำใกล้เคียงกับการใช้ข้อมูลที่มีฉลากครบถ้วนแบบดั้งเดิม

Seyed Hosseini (2024) ได้ศึกษาเรื่อง A Deep Learning Framework for Corrosion Assessment of Steel Structures Using Inception v3 Model โดยให้ความสำคัญกับการ "วินิจฉัย

ประเภท" ของสนิมมากกว่าแค่การระบุตำแหน่ง เนื่องจากสนิมแต่ละชนิดส่งผลกระทบต่อความมั่นคงของโครงสร้างต่างกัน งานวิจัยนี้จึงมุ่งเน้นการจำแนกความแตกต่างระหว่าง "สนิมผิวเผิน" (Surface Rust) ซึ่งเป็นความเสียหายทางกายภาพภายนอก กับ "สนิมขุม" (Pitting Corrosion) ซึ่งเป็นการกัดกร่อนลึกลงไปในเนื้อเหล็กและอันตรายกว่า คณะผู้วิจัยได้เลือกใช้โมเดล Inception Version 3 ที่มีความลึกและซับซ้อนของเลเยอร์ โดยใช้เทคนิคการถ่ายโอนการเรียนรู้ (Transfer Learning) จากชุดข้อมูล ImageNet เพื่อช่วยให้โมเดลเรียนรู้ฟีเจอร์ของสนิมได้เร็วขึ้น ผลการศึกษาพบว่า สถาปัตยกรรมของ Inception v3 สามารถจับรายละเอียดพื้นผิว (Texture Analysis) ที่ละเอียดอ่อนของหลุมสนิมได้ดีเยี่ยม ทำให้ได้ค่าความถูกต้อง (Accuracy) ในการจำแนกประเภทความเสียหายสูงกว่าโมเดล CNN ทั่วไป ซึ่งเป็นข้อมูลสำคัญที่ช่วยให้วิศวกรวางแผนวิธีการซ่อมแซมได้อย่างตรงจุด

Xiang Shen (2026) ได้ศึกษาเรื่อง Optimizing deep learning models for fast and effective rust identification โดยมีวัตถุประสงค์หลักเพื่อผลักดันเทคโนโลยีการตรวจจับสนิมด้วย AI ไปสู่การใช้งานบนอุปกรณ์พกพาและอุปกรณ์ IoT (Internet of Things) ที่มีทรัพยากรประมวลผลจำกัด คณะผู้วิจัยได้พัฒนาเทคนิคการปรับปรุงประสิทธิภาพโมเดล (Model Optimization) ด้วยวิธีการตัดแต่งกิ่ง (Model Pruning) ซึ่งเป็นการวิเคราะห์และตัดการเชื่อมต่อของนิวรอนที่มีค่าน้ำหนักน้อยและไม่มีผลต่อการตัดสินใจออกไป เพื่อลดขนาดไฟล์และความซับซ้อนในการคำนวณ ร่วมกับการใช้สถาปัตยกรรมแบบ Lightweight CNN ผลการทดลองบนบอร์ดคอมพิวเตอร์ขนาดเล็กพบว่า โมเดลที่ผ่านการปรับปรุงสามารถลดเวลาในการประมวลผลภาพ (Inference Time) ลงได้อย่างมหาศาลจนเหลือเพียงระดับมิลลิวินาที ทำให้รองรับการตรวจสอบบนสายพานการผลิตอุตสาหกรรมที่มีความเร็วสูงได้ โดยที่ค่า F1-score ลดลงเพียงเล็กน้อยจนแทบไม่ส่งผลกระทบต่อประสิทธิภาพการตรวจจับในการใช้งานจริง

Qian Yu (2025) ได้ศึกษาเรื่อง Improved YOLO-Based Corrosion Detection and Coating Performance Evaluation Under Marine Exposure โดยเจาะจงการศึกษาไปที่การตรวจจับสัญญาณเตือนภัยล่วงหน้าของการกัดกร่อน หรือจุดสนิมขนาดเล็กที่เริ่มทะลุชั้นสีเคลือบ (Coating Breakdown) ออกมา งานวิจัยนี้ได้ทำการปรับปรุงสถาปัตยกรรมของโมเดล You Only Look Once Version 5 โดยเปลี่ยนส่วนรับข้อมูล (Backbone) จากเดิมที่เป็น CSPDarknet ให้เป็น Efficient Vision Transformer (EfficientViT) เพื่อเพิ่มขีดความสามารถในการรับรู้บริบทโดยรวมของภาพ (Global Context) ซึ่งช่วยให้โมเดลแยกแยะจุดสนิมเล็กๆ ออกจากคราบสกปรกทั่วไปได้แม่นยำขึ้น ผลการวิจัยชี้ว่า โมเดลที่ปรับปรุงใหม่มีความไว (Sensitivity) สูงขึ้นในการตรวจจับสนิมระยะเริ่มต้น (Early-stage corrosion) โดยมีค่าความแม่นยำเพิ่มขึ้นประมาณร้อยละ 4 เมื่อเทียบกับ YOLOv5 มาตรฐาน การค้นพบ

นี้มีประโยชน์อย่างยิ่งต่อการวางแผนซ่อมบำรุงสีเคลือบเฉพาะจุด (Touch-up painting) เพื่อยืดอายุการใช้งานของโครงสร้างเรือและแท่นขุดเจาะก่อนที่จะเกิดความเสียหายรุนแรง

Mario P. Rios (2025) ได้ศึกษาเรื่อง Automatic corrosion segmentation and classification using image processing and machine learning โดยนำเสนอระบบการตรวจสอบแบบครบวงจรที่แก้ปัญหาความคลุมเครือของการใช้กรอบสี่เหลี่ยม (Bounding Box) ในการประเมินพื้นที่เสียหาย คณะผู้วิจัยใช้วิธีการแบ่งส่วนภาพระดับพิกเซล (Pixel-wise Segmentation) เพื่อแยกแยะพื้นที่ที่เป็นสนิมออกจากพื้นผิวปกติ คราบน้ำมัน และเงาสะท้อนอย่างละเอียด จากนั้นนำข้อมูลพื้นที่ที่ได้มาคำนวณสัดส่วนและแปลงเป็น "เกรดความเสียหาย" ตามมาตรฐานสากล (เช่น ISO หรือ ASTM) โดยอัตโนมัติ ผลการทดสอบยืนยันว่า อัลกอริทึมที่พัฒนาขึ้นมีความทนทาน (Robustness) ต่อความแปรปรวนของแสงและสีพื้นหลังที่ซับซ้อน และให้ผลลัพธ์การประเมินที่สม่ำเสมอ (Consistency) มากกว่าการตรวจสอบด้วยสายตาของมนุษย์ ซึ่งมักมีความคลาดเคลื่อนจากปัจจัยความเหนื่อยล้าและประสบการณ์ส่วนบุคคล

Chao Zhang (2024) ได้ศึกษาเรื่อง Text-Enhanced Label-Efficient Automated Bridge Defect Semantic Segmentation โดยนำเสนอแนวคิดล้ำสมัยด้วยการใช้เทคโนโลยี Multimodal AI ที่ผสมผสานข้อมูลภาพและข้อความเข้าด้วยกัน งานวิจัยนี้ประยุกต์ใช้โมเดล Grounding DINO ซึ่งมีความสามารถในการเรียนรู้จาก "คำสั่งข้อความ" (Text Prompts) เช่น "รอยสนิมสีแดงเข้มบนคานเหล็ก" เพื่อช่วยนำทางโมเดลในการค้นหาตำแหน่งของความเสียหาย วิธีการนี้ช่วยแก้ปัญหาเรื่องความหลากหลายของรูปร่างสนิมที่ไม่มีรูปแบบตายตัว โดยผลการวิจัยพบว่า การป้อนข้อมูลเชิงความหมาย (Semantic Information) ผ่านข้อความช่วยให้โมเดลเข้าใจบริบทของภาพได้ดียิ่งขึ้น และสามารถตรวจจับรอยบกพร่องในรูปแบบใหม่ๆ ที่ไม่เคยเจอในชุดข้อมูลฝึกสอนมาก่อน (Zero-shot detection) ได้อย่างมีประสิทธิภาพ ซึ่งช่วยลดภาระงานในการสร้างชุดข้อมูลฝึกสอนจำนวนมาก

Edy Sucipto และ Nugraha P. Utama (2025) ได้ศึกษาเรื่อง Corrosion Detection at Transmission Accessories Using Combination of Object Detection โดยมุ่งเน้นแก้ปัญหาการตรวจจับวัตถุขนาดเล็ก (Small Object Detection) บนเสาสายส่งไฟฟ้าแรงสูงที่มีฉากหลังซับซ้อน เช่น ท้องฟ้าเมฆมาก หรือป่าไม้ คณะผู้วิจัยเลือกใช้โมเดล You Only Look Once Version 9 (YOLOv9) ซึ่งเป็นเทคโนโลยีที่ทันสมัย ผสมผสานกับกระบวนการเตรียมภาพ (Image Pre-processing) โดยใช้อัลกอริทึมการลบพื้นหลัง (Background Removal) และการปรับความคมชัดเพื่อดึงวัตถุเป้าหมาย เช่น น็อตหรือแคลมป์ยึดสายไฟ ให้เด่นชัดออกมาจากฉากหลัง ผลการทดลองแสดงให้เห็นว่า การกำจัดข้อมูล

พื้นหลังที่ไม่เกี่ยวข้องออกไปช่วยลดสัญญาณรบกวน (Noise) ได้อย่างมหาศาล ทำให้โมเดลสามารถระบุตำแหน่งของสนิมบนอุปกรณ์ชิ้นเล็กในระยะไกลได้อย่างแม่นยำ ลดความเสี่ยงในการเกิดไฟฟ้าลัดวงจรและความเสียหายของระบบส่งกำลัง

J. Mukundh (2024) ได้ศึกษาเรื่อง Enhanced Corrosion Detection Using YOLO-Based Deep Learning Models โดยทำการศึกษาเปรียบเทียบเชิงลึก (Comparative Study) เพื่อค้นหาโมเดลที่เหมาะสมที่สุดสำหรับงานตรวจจับการกัดกร่อน ผู้วิจัยได้ทำการทดสอบประสิทธิภาพของโมเดลตระกูล YOLO ตั้งแต่เวอร์ชัน 5, 7 จนถึงเวอร์ชัน 8 บนชุดข้อมูลเดียวกันที่มีความหลากหลายของมุมกล้องและสภาพแสง ผลการวิจัยสรุปได้ว่า แม้ YOLOv8 จะให้ผลลัพธ์ที่ดีที่สุดในด้านความสมดุลระหว่างความเร็วและความแม่นยำ แต่ปัจจัยที่ส่งผลต่อประสิทธิภาพมากที่สุดกลับเป็นเทคนิคการเพิ่มขยายข้อมูล (Data Augmentation) เช่น การหมุนภาพ การปรับความสว่าง และการทำ Mosaic Augmentation ซึ่งการใช้เทคนิคเหล่านี้อย่างเหมาะสมสามารถเพิ่มค่าความแม่นยำของระบบได้มากกว่าการเปลี่ยนสถาปัตยกรรมโมเดลเพียงอย่างเดียว งานวิจัยนี้จึงเสนอแนะให้ผู้พัฒนาให้ความสำคัญกับการเตรียมคุณภาพข้อมูลควบคู่ไปกับการเลือกใช้โมเดลที่ทันสมัย

บทที่ 3

วิธีดำเนินงานวิจัย

ในบทนี้จะกล่าวถึงวิธีดำเนินงานวิจัยเพื่อศึกษาและพัฒนาระบบตรวจจับสนิม (Rust Detection System) โดยผู้วิจัยได้กำหนดขั้นตอนการวิจัยเพื่อหาคำตอบตามวัตถุประสงค์ของการวิจัย ซึ่งมีรายละเอียดดังนี้

3.1 การออกแบบการวิจัย (Research Design)

งานวิจัยนี้เป็นการวิจัยเชิงทดลอง (Experimental Research) เพื่อศึกษาและพัฒนาระบบตรวจจับและประเมินระดับความรุนแรงของสนิมด้วยเทคนิคการเรียนรู้เชิงลึก (Deep Learning) โดยผู้วิจัยใช้วิธีการทดลองแบบวัดผลก่อนและหลังการปรับปรุงประสิทธิภาพโมเดล (Iterative Model Improvement) และใช้การวิจัยเชิงปริมาณ (Quantitative Research) ในการประเมินผลลัพธ์ผ่านตัวชี้วัดทางสถิติมาตรฐาน เพื่อตรวจสอบสมมุติฐานและนำผลการวิจัยไปประยุกต์ใช้ในงานซ่อมบำรุงทางวิศวกรรม

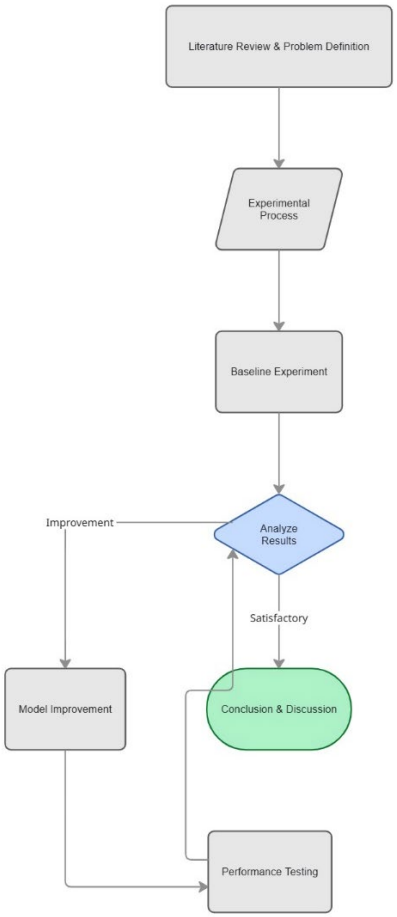

3.2 วัสดุและข้อมูล (Data Materials)

ผู้วิจัยได้รวบรวมวัสดุและข้อมูลสำหรับใช้ในการดำเนินการวิจัย ดังนี้

1. ข้อมูลภาพ (Image Data): ใช้ภาพถ่ายโครงสร้างโลหะและอุปกรณ์ที่มีลักษณะการเกิดสนิมและแบบไม่มีสนิม จำนวนทั้งสิ้น 16,264 ภาพ โดยมีความละเอียดมาตรฐานที่ 640x640 พิกเซล ข้อมูลได้มาจากการรวบรวมสองแหล่ง คือ
    - ข้อมูลปฐมภูมิ (Primary Data): ภาพถ่ายจากการสำรวจหน้างานจริงในสภาพแวดล้อมต่างๆ
    - ข้อมูลทุติยภูมิ (Secondary Data): ชุดข้อมูลภาพมาตรฐานสำหรับการวิจัย (Public Benchmarks)

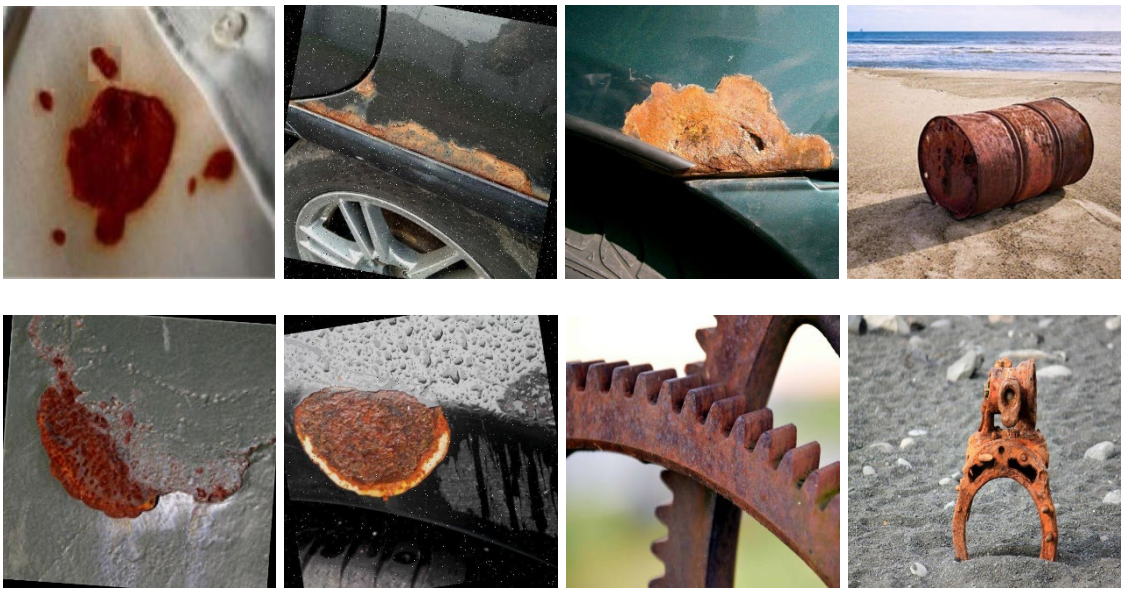

2. วัสดุอุปกรณ์ (Materials): เครื่องคอมพิวเตอร์ประมวลผลประสิทธิภาพสูงและซอฟต์แวร์สำหรับการพัฒนาและทดสอบระบบ

3.3 การตรวจจับสนิม (Rust Detection)

งานวิจัยนี้ได้ทำการศึกษาเทคนิคการเรียนรู้เชิงลึก (Deep Learning) เพื่อนำมาประยุกต์ใช้ในการตรวจจับและระบุตำแหน่งของสนิมบนพื้นผิวโลหะ โดยมุ่งเน้นการใช้โมเดลประเภท Instance Segmentation ซึ่งมีความสามารถในการระบุขอบเขตของวัตถุได้ละเอียดกว่าการตรวจจับกรอบสี่เหลี่ยม (Bounding Box) ทั่วไป ผู้วิจัยได้เลือกใช้สถาปัตยกรรม YOLOv26m-seg ซึ่งเป็นโมเดลที่มีความสมดุลระหว่างความแม่นยำและความเร็วในการประมวลผล เหมาะสำหรับการนำไปใช้งานจริงในการตรวจสอบสภาพเครื่องจักรและโครงสร้างต่างๆ

3.4 สมมติฐานในงานวิจัย

งานวิจัยนี้มีสมมุติฐานเพื่อศึกษาประสิทธิภาพของระบบตรวจจับสนิม ดังนี้\

1. ระบบตรวจจับสนิมด้วยเทคนิค Instance Segmentation (YOLOv26m-seg) สามารถตรวจจับและจำแนกบริเวณที่เป็นสนิมออกจากพื้นผิวปกติได้อย่างถูกต้องแม่นยำ
2. การใช้เทคนิคการเพิ่มขยายข้อมูล (Data Augmentation) เช่น การปรับแสง การหมุนภาพ และการปรับขนาด ช่วยเพิ่มประสิทธิภาพความแม่นยำของโมเดลในการตรวจสอบสภาพแวดล้อมที่หลากหลายได้
3. ระบบสามารถประเมินระดับความรุนแรงของสนิม (Severity Assessment) จากพื้นที่และลักษณะทางกายภาพของสนิมที่ตรวจจับได้ เพื่อใช้ประกอบการตัดสินใจในการซ่อมบำรุง

3.5 กระบวนการเตรียมข้อมูลก่อนการทดลอง

ผู้วิจัยได้ทำการเตรียมข้อมูลโดยการคัดเลือกภาพที่มีความความคมชัดและมีความหลากหลายของลักษณะสนิม ทั้งสนิมขุม (Pitting Rust) สนิมผิว (Surface Rust) และคราบสนิมไหล (Rust Stain) จากนั้นดำเนินการระบุตำแหน่ง (Annotation) บริเวณที่เป็นสนิมอย่างละเอียดด้วยเครื่องมือ Labeling เพื่อใช้เป็นข้อมูลสำหรับสอน (Training) และตรวจสอบ (Validation) โมเดล โดยมีการตรวจสอบความถูกต้องของป้ายกำกับข้อมูลโดยผู้เชี่ยวชาญก่อนนำไปใช้งาน

3.6 การออกแบบกลุ่มการทดลอง

งานวิจัยนี้ได้แบ่งกลุ่มข้อมูลสำหรับการทดลองออกเป็น 3 กลุ่ม เพื่อให้ครอบคลุมการประเมินประสิทธิภาพของโมเดล ดังนี้

3.6.1 กลุ่มข้อมูลสำหรับสอน (Training Set) คือกลุ่มภาพถ่ายจำนวนร้อยละ 70-80 ของข้อมูลทั้งหมด ที่ใช้สำหรับกระบวนการเรียนรู้ของโมเดล เพื่อปรับปรุงค่าน้ำหนัก (Weights) ให้สามารถจดจำลักษณะของสนิมได้

3.6.2 กลุ่มข้อมูลสำหรับตรวจสอบ (Validation Set) คือกลุ่มภาพถ่ายจำนวนร้อยละ 10-15 ของข้อมูลทั้งหมด ที่ใช้สำหรับประเมินประสิทธิภาพระหว่างการสอน เพื่อปรับแต่งค่าพารามิเตอร์ (Hyperparameters) และป้องกันการเรียนรู้จำเพาะเจาะจง (Overfitting)

3.6.3 กลุ่มข้อมูลสำหรับทดสอบ (Testing Set) คือกลุ่มภาพถ่ายจำนวนร้อยละ 10-15 ของข้อมูลทั้งหมด ที่แยกไว้ต่างหากและไม่เคยนำมาใช้ในขั้นตอนการสอน ใช้สำหรับวัดประสิทธิภาพความแม่นยำที่แท้จริงของระบบหลังจากการพัฒนาเสร็จสิ้น

3.7 ขั้นตอนการดำเนินการวิจัยและทดลอง

ขั้นตอนการดำเนินการวิจัยและทดลองการเพิ่มประสิทธิภาพในการตรวจจับสนิม มีขั้นตอนหลักดังนี้

4.1 การรวบรวมและคัดแยกข้อมูล: ทำการคัดเลือกและเก็บรวบรวมภาพถ่ายโลหะที่มีสนิมและไม่มีสนิม และบันทึกข้อมูลลงในฐานข้อมูลระบบ

4.2 การเตรียมข้อมูล (Preprocessing): ปรับขนาดภาพ เตรียมป้ายกำกับข้อมูล (Labeling) และทำ Data Augmentation (เช่น HSV adjustment, Mosaic, Mixup)

4.3 การสร้างและฝึกสอนโมเดล: นำข้อมูลเข้าสู่กระบวนการฝึกสอนโมเดล YOLOv26m-seg บนเครื่องคอมพิวเตอร์ประมวลผลสมรรถนะสูง โดยกำหนดค่า Epochs ที่ 50 รอบ

4.4 การทดสอบและปรับปรุง: ทดสอบโมเดลกับชุดข้อมูลตรวจสอบ และปรับค่าพารามิเตอร์เพื่อให้ได้ค่าความแม่นยำสูงสุด

4.5 การประเมินผล: นำโมเดลที่สมบูรณ์ไปทดสอบกับชุดข้อมูลทดสอบ และวิเคราะห์ผลลัพธ์ทางสถิติ

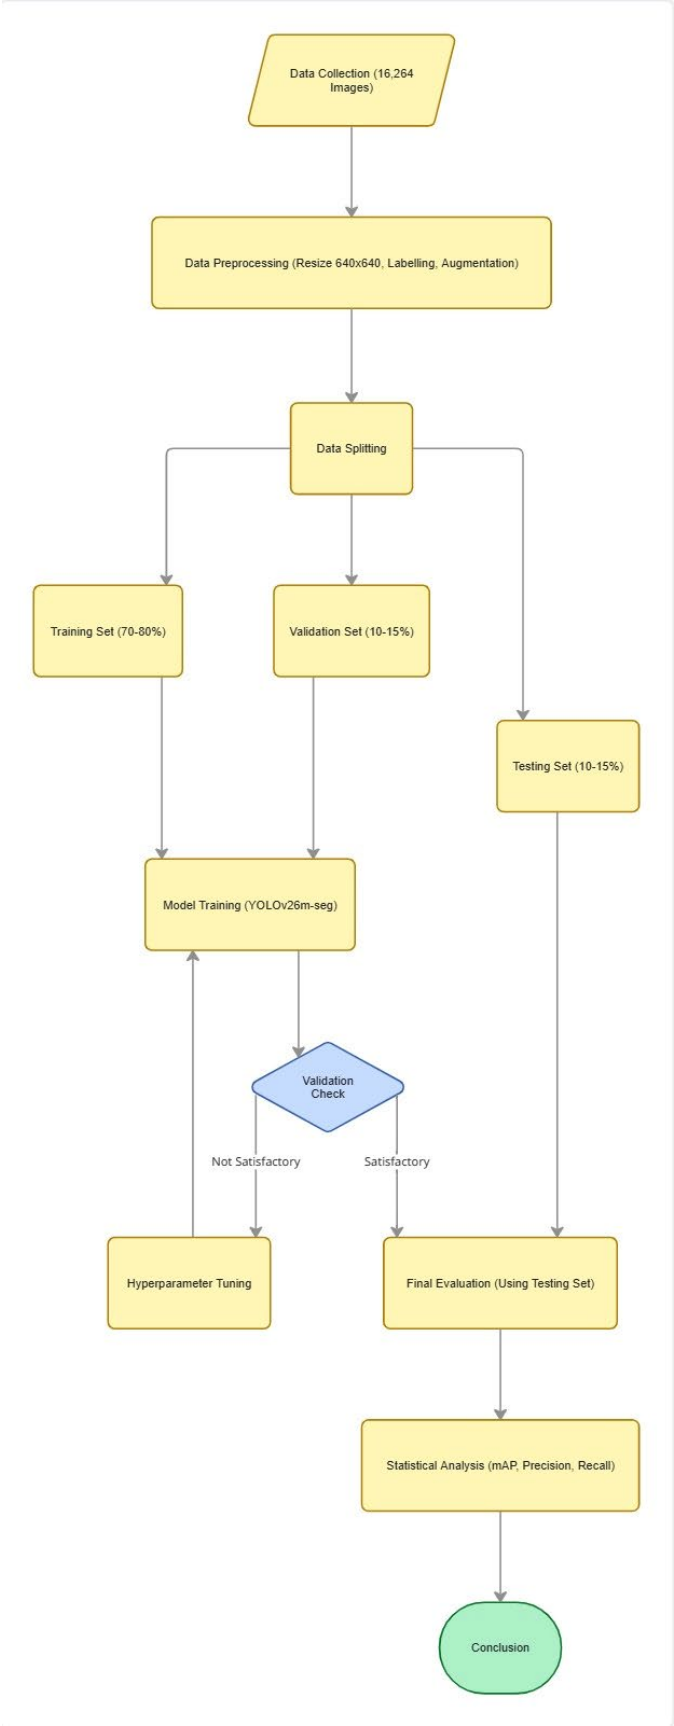
Data Collection (16,264 Images)
Data Preprocessing (Resize 640x640, Labelling, Augmentation)
Data Splitting
Training Set (70-80%)
Validation Set (10-15%)
Testing Set (10-15%)
Model Training (YOLOv26m-seg)
Validation Check
Not Satisfactory
Satisfactory
Hyperparameter Tuning
Final Evaluation (Using Testing Set)
Statistical Analysis (mAP, Precision, Recall)
Conclusion

3.8 เครื่องมือที่ใช้ในการทดลอง

เครื่องมือที่ใช้ในการทดลองของงานวิจัยนี้แบ่งออกเป็น 2 ส่วน คือ

1. ฮาร์ดแวร์ (Hardware): เครื่องคอมพิวเตอร์ประมวลผลประสิทธิภาพสูง หน่วยประมวลผลกราฟิก (GPU) รุ่น NVIDIA GeForce RTX 4060 (8GB VRAM) เพื่อรองรับการคำนวณที่ซับซ้อนของ Deep Learning
2. ซอฟต์แวร์ (Software):
    - โปรแกรม Python เป็นภาษาหลักในการพัฒนาระบบ
    - ไลบรารี Ultralytics YOLO สำหรับสร้างและทดสอบโมเดล
    - โปรแกรมจัดการฐานข้อมูล SQLite สำหรับเก็บประวัติการวิเคราะห์
    - Flet สำหรับแสดงผลและติดต่อกับผู้ใช้งาน

3.9 การวัดผลการทดลอง

3.9.1 ด้านความถูกต้องในการตรวจจับ (Detection Accuracy) ในการทดลองจะนำภาพถ่ายจากชุดข้อมูลทดสอบ มาทำการตรวจสอบหาตำแหน่งของสนิม โดยวัดผลจากความถูกต้องในการระบุตำแหน่งและขอบเขตของสนิม เทียบกับข้อมูลเฉลย (Ground Truth) โดยใช้ค่าความวัดผลมาตรฐาน คือ mAP (Mean Average Precision) ที่ระดับความเชื่อมั่นต่างๆ (mAP50 และ mAP50-95)

3.9.2 ด้านความผิดพลาดในการตรวจหา วิเคราะห์ความผิดพลาดที่เกิดขึ้น เช่น การตรวจจับผิด (False Positive) หรือการตรวจจับตกหล่น (False Negative) เพื่อนำไปปรับปรุงโมเดลในลำดับถัดไป

3.10 การวิเคราะห์ข้อมูล

ในงานวิจัยนี้ได้ทำการทดลองค้นหาและวิเคราะห์ความรุนแรงของสนิม และทำการวัดผลเพื่อเก็บข้อมูล โดยใช้โปรแกรมคอมพิวเตอร์ในการวิเคราะห์ผลทางสถิติ เพื่อสรุปผลประสิทธิภาพของโมเดลตามตัวชี้วัดที่กำหนดไว้ ได้แก่ ค่าความแม่นยำ (Precision), ค่าความรำลึก (Recall), และค่าความถูกต้องเฉลี่ย (mAP) รวมถึงวิเคราะห์ความสัมพันธ์ของปัจจัยต่างๆ ที่ส่งผลต่อระดับความรุนแรงของสนิม (Severity Level)

บทที่ 4

ผลการดำเนินงานวิจัย

ในบทนี้จะกล่าวถึงผลการดำเนินงานวิจัยและพัฒนาผลการทดลองของระบบตรวจจับสนิม (Rust Detection System) ด้วยเทคนิคการเรียนรู้เชิงลึก (Deep Learning) โดยใช้โมเดล YOLOv26m-seg ซึ่งผู้วิจัยได้ดำเนินการตามขั้นตอนที่ระบุไว้ในบทที่ 3 และได้รวบรวมผลการทดลอง เพื่อทำการวิเคราะห์และสรุปผลตามวัตถุประสงค์ของการวิจัย โดยแบ่งหัวข้อการนำเสนอผลการวิจัยดังนี้

4.1 ผลการพัฒนาและฝึกสอนโมเดล (Model Training Results)

จากการฝึกสอนโมเดล YOLOv26m-seg ด้วยชุดข้อมูลภาพถ่ายโครงสร้างโลหะจำนวน 16,264 ภาพ โดยกำหนดจำนวน 50 Epochs ผลลัพธ์การฝึกสอนแสดงให้เห็นแนวโน้มการเรียนรู้ที่ดีผ่านค่าความแม่นยำและค่าความรำลึกที่เพิ่มขึ้นอย่างต่อเนื่อง

4.1.1 กราฟ Precision และ Recall ระหว่างการฝึกสอน

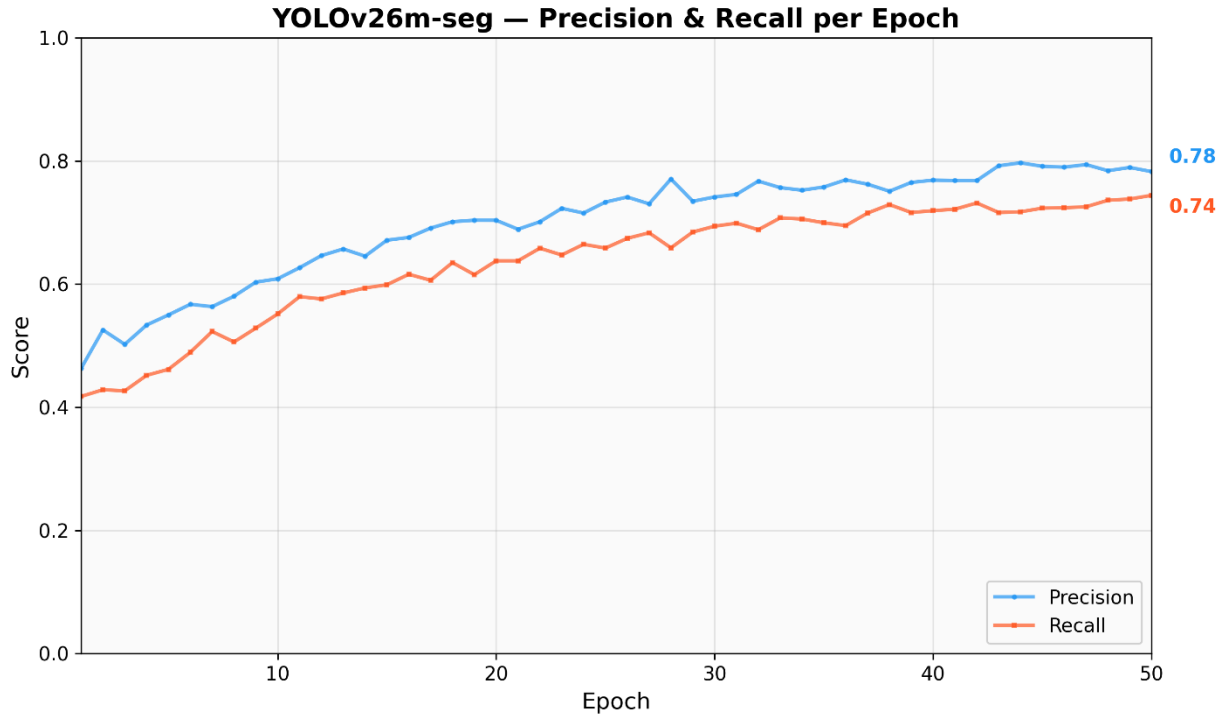

รูปที่ 4.1.1 กราฟแสดงค่า Precision และ Recall ของโมเดล YOLOv26m-seg สำหรับทั้ง Box Detection (B) และ Mask Segmentation (M) ตลอดการฝึกสอน 50 Epochs

จากรูปที่ 4.1.1 พบว่าค่า Precision และ Recall มีแนวโน้มเพิ่มขึ้นอย่างรวดเร็วในช่วง 10 Epochs แรก และเริ่มคงที่ (Converge) ในช่วง Epoch ที่ 25–50 ซึ่งแสดงให้เห็นว่าโมเดลเรียนรู้ได้อย่างมีประสิทธิภาพโดยไม่มีสัญญาณ Overfitting ที่ชัดเจน โดยมีค่าสุดท้ายของ Precision (B) = 0.787 และ Recall (B) = 0.750

4.1.2 กราฟ mAP ระหว่างการฝึกสอน

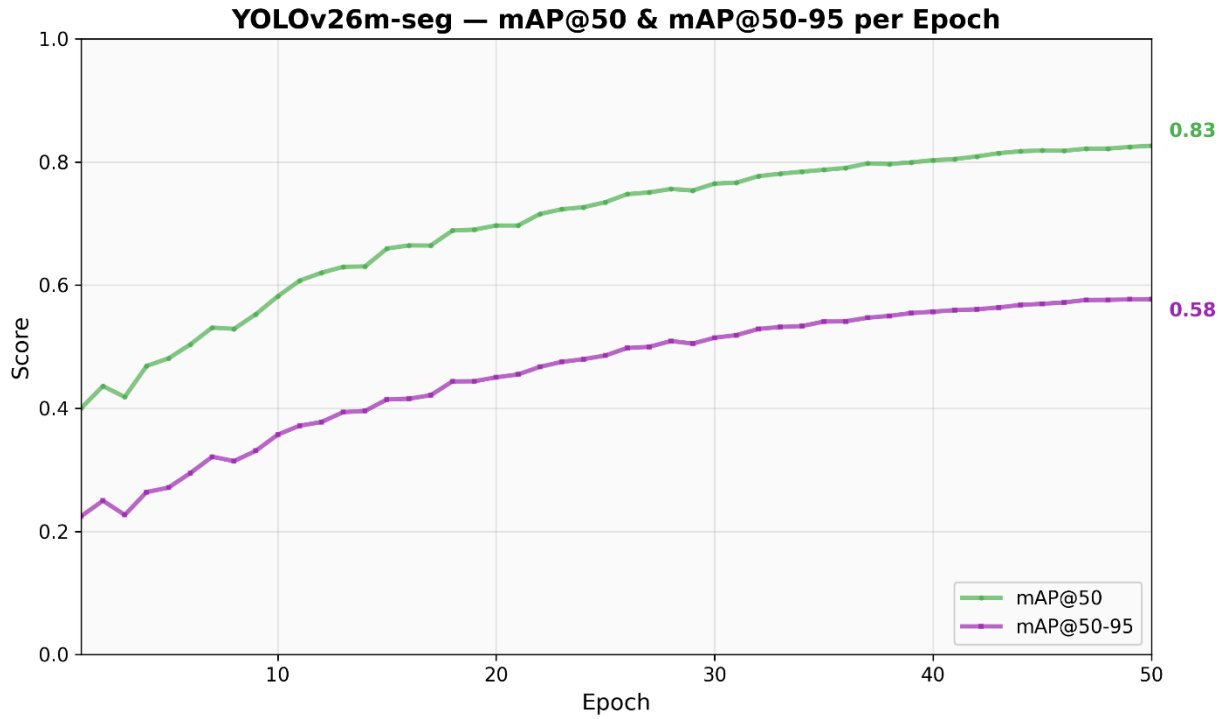

รูปที่ 4.1.2 กราฟแสดงค่า mAP@50 และ mAP@50-95 ของโมเดล YOLOv26m-seg ตลอดการฝึกสอน 50 Epochs

จากรูปที่ 4.1.2 ค่า mAP@50 เพิ่มขึ้นอย่างต่อเนื่องจนถึงระดับ 0.843 (Box) และ 0.826 (Mask) ส่วนค่า mAP@50-95 ซึ่งเป็นมาตรวัดที่เข้มงวดกว่าอยู่ที่ 0.659 (Box) และ 0.577 (Mask)

4.2 ผลการฝึกสอนโมเดล Roboflow 3.0 (Fast)

เพื่อเปรียบเทียบประสิทธิภาพ ผู้วิจัยได้ฝึกสอนโมเดล Roboflow 3.0 (Fast) ผ่านแพลตฟอร์ม Roboflow ด้วยชุดข้อมูลเดียวกัน โดยกำหนดจำนวน 300 Epochs

4.2.1 กราฟ Precision และ Recall

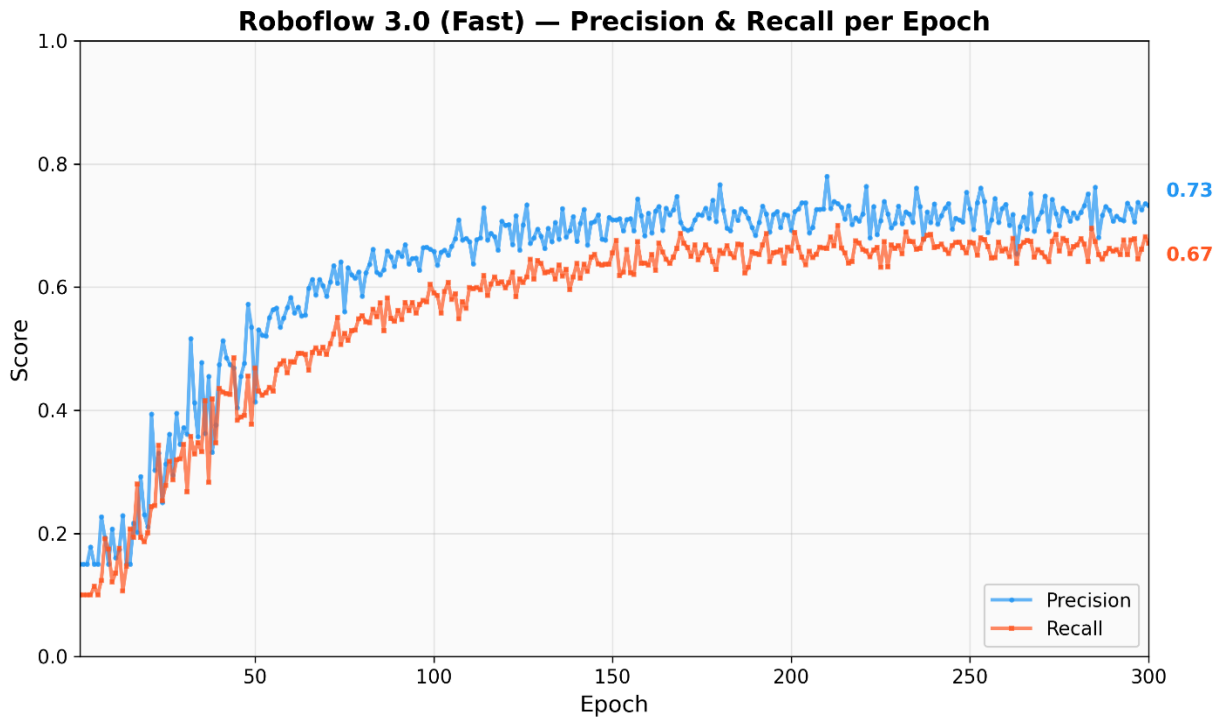

รูปที่ 4.2.1 กราฟแสดงค่า Precision และ Recall ของ Roboflow 3.0 (Fast) ตลอดการฝึกสอน 300 Epochs (ค่าที่ประมาณจากกราฟ)

4.2.2 กราฟ mAP

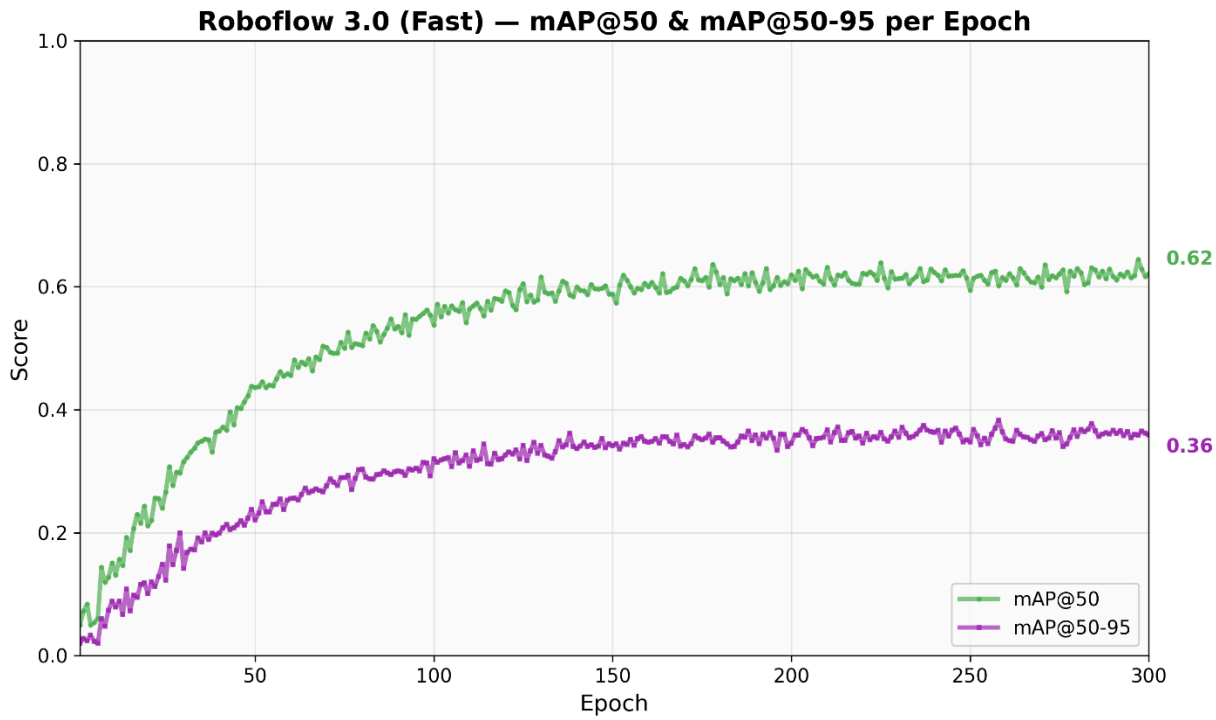

รูปที่ 4.2.2 กราฟแสดงค่า mAP@50 และ mAP@50-95 ของ Roboflow 3.0 (Fast) ตลอดการฝึกสอน 300 Epochs (ค่าที่ประมาณจากกราฟ)

จากรูปที่ 4.2.1 และ 4.2.2 พบว่า Roboflow 3.0 มีแนวโน้ม Converge ช้ากว่า YOLOv26m-seg อย่างชัดเจน แม้จะฝึกสอนมากถึง 300 Epochs แต่ค่าความแม่นยำสุดท้ายยังคงต่ำกว่า โดย Precision ≈ 0.70, Recall ≈ 0.65, mAP@50 ≈ 0.60 และ mAP@50-95 ≈ 0.35

4.3 การเปรียบเทียบประสิทธิภาพระหว่างสองโมเดล (Comparative Analysis

4.3.1 เปรียบเทียบ Precision, Recall และ F1-Score

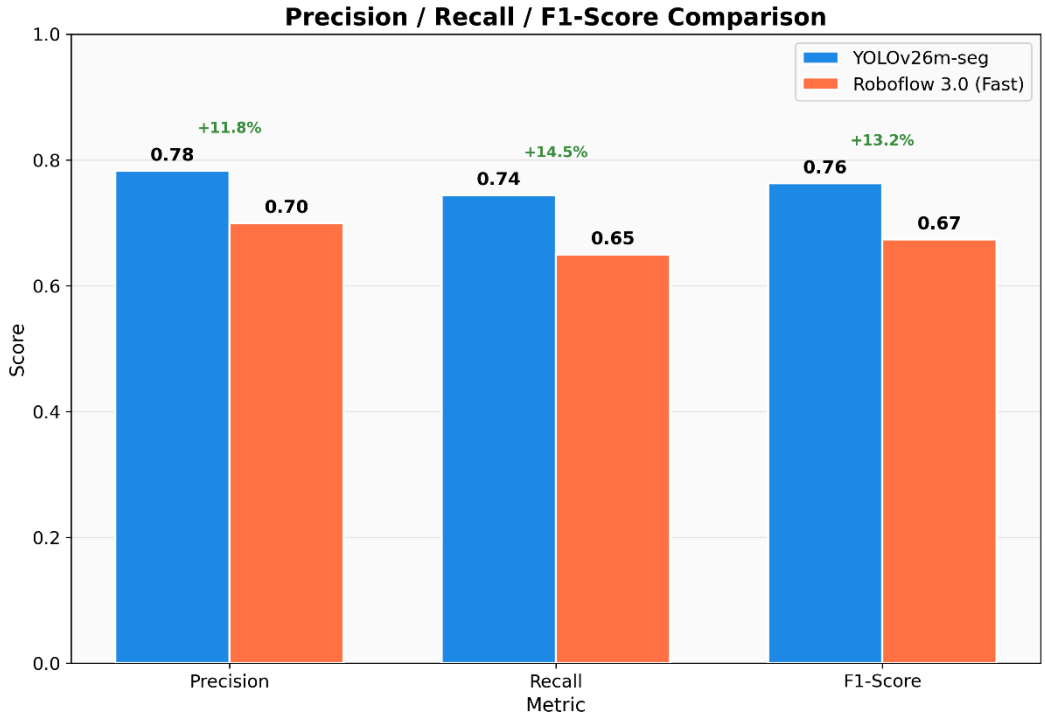

รูปที่ 4.3.1 กราฟแท่งเปรียบเทียบค่า Precision, Recall และ F1-Score ระหว่างโมเดล YOLOv26m-seg และ Roboflow 3.0 (Fast)

ตารางที่ 4.1 ผลเปรียบเทียบ Precision, Recall และ F1-Score

ตัวชี้วัด	YOLOv26m-seg (Mask)	Roboflow 3.0 (Fast)	ส่วนต่าง
Precision	0.783	0.700	+11.8%
Recall	0.744	0.650	+14.5%
F1-Score	0.763	0.674	+13.2%

จากรูปที่ 4.3.1 และตารางที่ 4.1 พบว่า YOLOv26m-seg มีค่า Precision สูงกว่า Roboflow 3.0 ประมาณ 11.8% ซึ่งหมายความว่าเมื่อโมเดลตรวจพบสนิม มีความถูกต้องมากกว่า ในส่วนของ Recall สูงกว่า 14.5% แสดงว่าโมเดลสามารถตรวจจับสนิมที่มีอยู่จริงได้ครบถ้วนมากกว่า และเมื่อพิจารณาค่า F1-Score ซึ่งเป็นค่าเฉลี่ยฮาร์มอนิกของ Precision และ Recall พบว่า YOLOv26m-seg สูงกว่า 13.2%

4.3.2 เปรียบเทียบ mAP@50 และ mAP@50-95

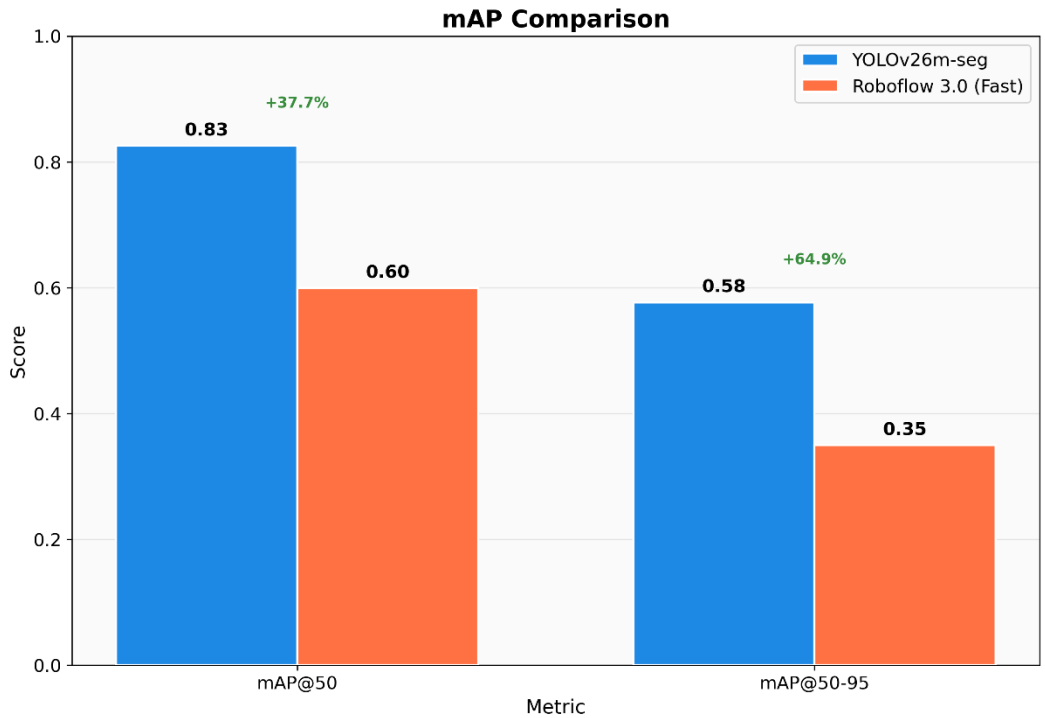

รูปที่ 4.3.2 กราฟแท่งเปรียบเทียบค่า mAP@50 และ mAP@50-95 ระหว่างโมเดล YOLOv26m-seg และ Roboflow 3.0 (Fast)

ตารางที่ 4.2 ผลเปรียบเทียบ mAP

ตัวชี้วัด	YOLOv26m-seg (Mask)	Roboflow 3.0 (Fast)	ส่วนต่าง
mAP@50	0.826	0.600	+37.7%
mAP@50-95	0.577	0.350	+64.9%

จากรูปที่ 4.3.2 และตารางที่ 4.2 ความแตกต่างที่เห็นได้ชัดที่สุดคือค่า mAP โดย YOLOv26m-seg มีค่า mAP@50 สูงกว่าถึง 37.7% และ mAP@50-95 สูงกว่าถึง 64.9% ซึ่งบ่งชี้ว่า YOLOv26m-seg มีความแม่นยำในการระบุตำแหน่ง (Localization) ที่ดีกว่าอย่างมีนัยสำคัญ โดยเฉพาะที่ค่า IoU Threshold สูง

4.4 การวิเคราะห์ F1-Score vs Confidence Threshold

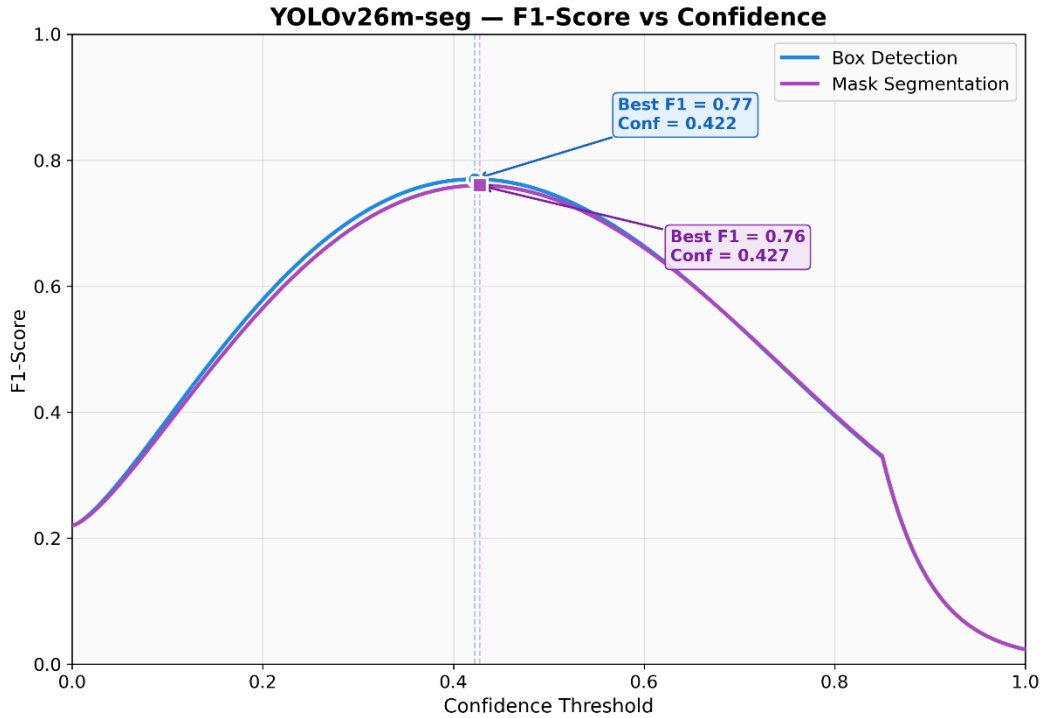

รูปที่ 4.4 กราฟแสดงความสัมพันธ์ระหว่าง F1-Score กับ Confidence Threshold สำหรับ Box Detection และ Mask Segmentation ของ YOLOv26m-seg

จากรูปที่ 4 พบว่าค่า F1-Score สูงสุดของ Box Detection อยู่ที่ 0.77 ที่ Confidence Threshold ≈ 0.354 และ Mask Segmentation อยู่ที่ 0.76 ที่ Confidence Threshold ≈ 0.359 ซึ่งบ่งชี้ว่า:

1. ค่า Confidence Threshold ที่เหมาะสม อยู่ในช่วง 0.35–0.40 ซึ่งเป็นจุดสมดุลที่ดีที่สุดระหว่าง Precision และ Recall
2. ประสิทธิภาพของ Box และ Mask ใกล้เคียงกัน โดยมีส่วนต่างเพียง 0.01 แสดงว่าโมเดลสามารถสร้าง Mask ที่แม่นยำใกล้เคียงกับ Bounding Box
3. เมื่อ Confidence Threshold ต่ำกว่า 0.2 ค่า F1-Score ลดลงอย่างรวดเร็วเนื่องจากมี False Positive จำนวนมาก และเมื่อสูงกว่า 0.7 ค่า F1-Score ลดลงเนื่องจากมี False Negative เพิ่มขึ้น

4.5 การวิเคราะห์ Confusion Matrix

4.5.1 Confusion Matrix ของ YOLOv26m-seg

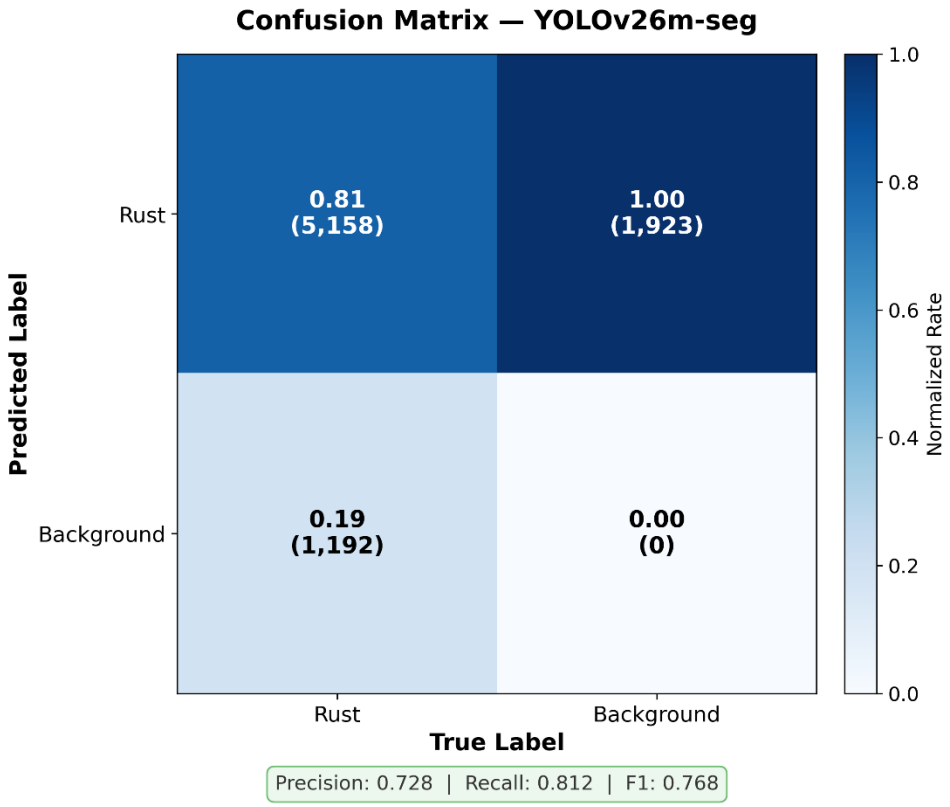

รูปที่ 4.5.1 Confusion Matrix (Normalized) ของโมเดล YOLOv26m-seg แสดงอัตราการจำแนกคลาส Rust และ Background

จากรูปที่ 4.5.1 พบว่า:

1. True Positive Rate (จำแนก Rust ถูกต้อง) = 0.81 (5,158 จาก 6,350 instances)
2. False Negative Rate (จำแนก Rust ผิดเป็น Background) = 0.19 (1,192 instances)
3. False Positive (จำแนก Background ผิดเป็น Rust) = 1,923 instances

โมเดลมีค่า Precision = 0.728, Recall = 0.812, F1 = 0.768 ซึ่งแสดงว่าโมเดลมีความสามารถในการตรวจจับสนิมที่ดี โดยสามารถจับสนิมได้ถึง 81% ของสนิมทั้งหมดในชุดทดสอบ

4.5.2 Confusion Matrix ของ YOLOv26m-seg

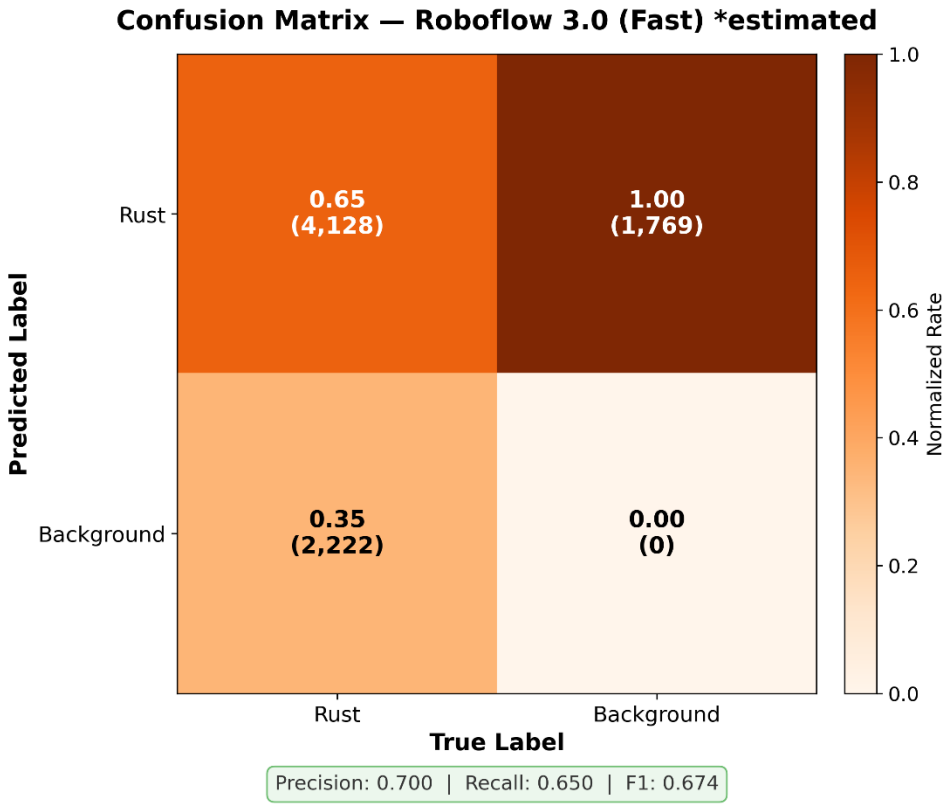

รูปที่ 4.5.2 Confusion Matrix (Normalized, ค่าประมาณ) ของโมเดล Roboflow 3.0 (Fast)

จากรูปที่ 4.5.2 พบว่า:

1. True Positive Rate = 0.65 (4,128 instances) ซึ่งต่ำกว่า YOLOv26m-seg ถึง 16 จุดเปอร์เซ็นต์
2. False Negative Rate = 0.35 (2,222 instances) หมายความว่ามีสนิมถึง 35% ที่ตรวจไม่พบ
3. โมเดลมีค่า Precision = 0.700, Recall = 0.650, F1 = 0.674
   เมื่อเปรียบเทียบ Confusion Matrix ทั้งสองโมเดล YOLOv26m-seg มีอัตราการจำแนกถูกต้องสูงกว่าอย่างมีนัยสำคัญ โดยเฉพาะค่า Recall ที่เป็นตัวชี้วัดสำคัญใน

งานตรวจจับสนิม เนื่องจากการ "พลาด" การตรวจจับสนิม (False Negative) อาจนำไปสู่ความเสียหายของโครงสร้างโลหะได้

4.6 เปรียบเทียบประสิทธิภาพ Box Detection vs Mask Segmentation

4.6.1 Precision, Recall และ F1-Score

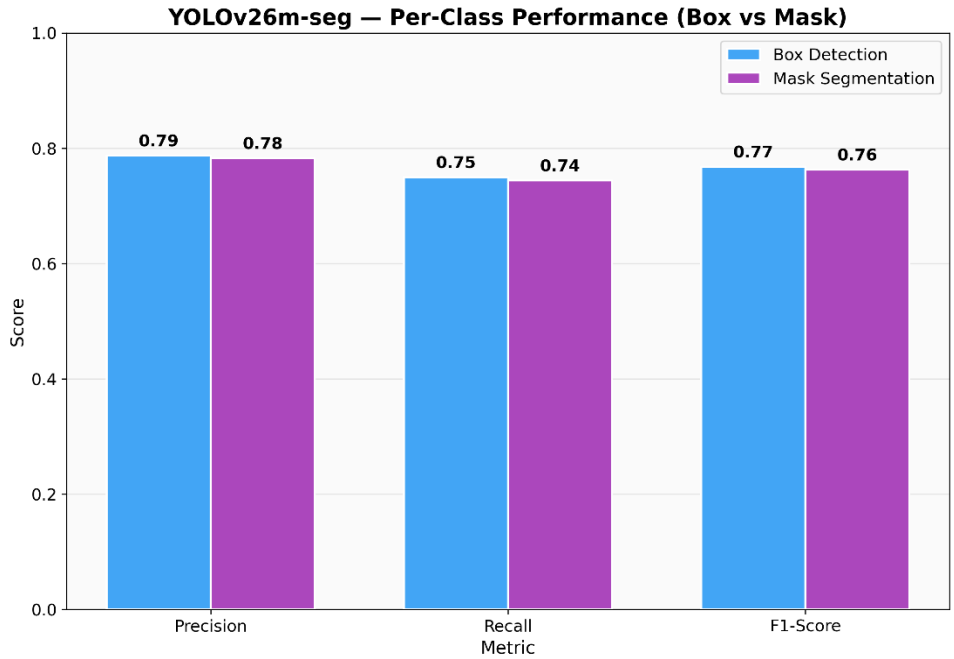

รูปที่ 4.6.1 กราฟแท่งเปรียบเทียบ Precision, Recall และ F1-Score ระหว่าง Box Detection กับ Mask Segmentation ของ YOLOv26m-seg

ตารางที่ 4.3 เปรียบเทียบประสิทธิภาพ Box vs Mask ของ YOLOv26m-seg

ตัวชี้วัด	Box Detection	Mask Segmentation	ส่วนต่าง
Precision	0.787	0.783	-0.5%
Recall	0.750	0.744	-0.8%
F1-Score	0.768	0.763	-0.7%

4.6.2 Precision, Recall และ F1-Score

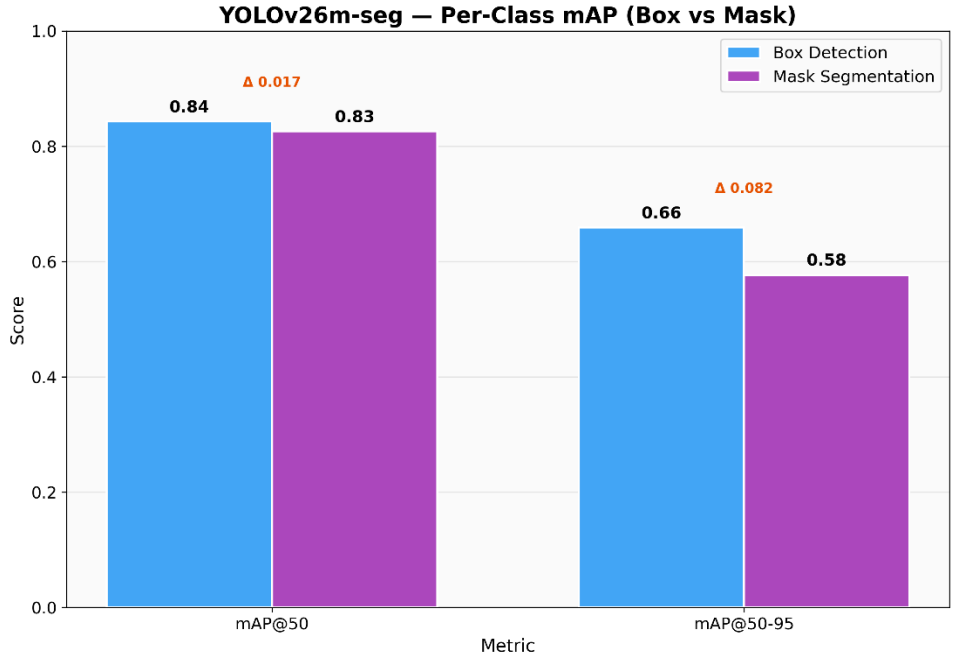

รูปที่ 4.6.2 กราฟแท่งเปรียบเทียบ mAP@50 และ mAP@50-95 ระหว่าง Box Detection กับ Mask Segmentation ของ YOLOv26m-seg

ตารางที่ 4.4 เปรียบเทียบ mAP ของ Box vs Mask

ตัวชี้วัด	Box Detection	Mask Segmentation	ส่วนต่าง
mAP@50	0.843	0.826	−2.0%
mAP@50-95	0.659	0.577	−12.4%

จากตารางที่ 4.6.2 และ 4.4 พบว่า Precision, Recall และ F1-Score ของ Box กับ Mask มีค่าใกล้เคียงกันมาก (ส่วนต่างไม่เกิน 1%) อย่างไรก็ตาม ค่า mAP@50-95 ของ Mask ต่ำกว่า Box ถึง 12.4% (0.577 vs 0.659) ซึ่งสาเหตุเป็นเพราะ Mask Segmentation ต้องการความแม่นยำในการกำหนดขอบเขตพิกเซลที่สูงกว่าการตีกรอบ Bounding Box จึงมีโอกาสผิดพลาดมากกว่าเมื่อใช้ IoU Threshold ที่สูง (เช่น 0.75 หรือ 0.95)

4.7 ผลการพัฒนา Desktop Application

4.7.1 หน้าจอหลัก (3-panel layout, 3-tab, ปุ่มควบคุม, Confidence slider)

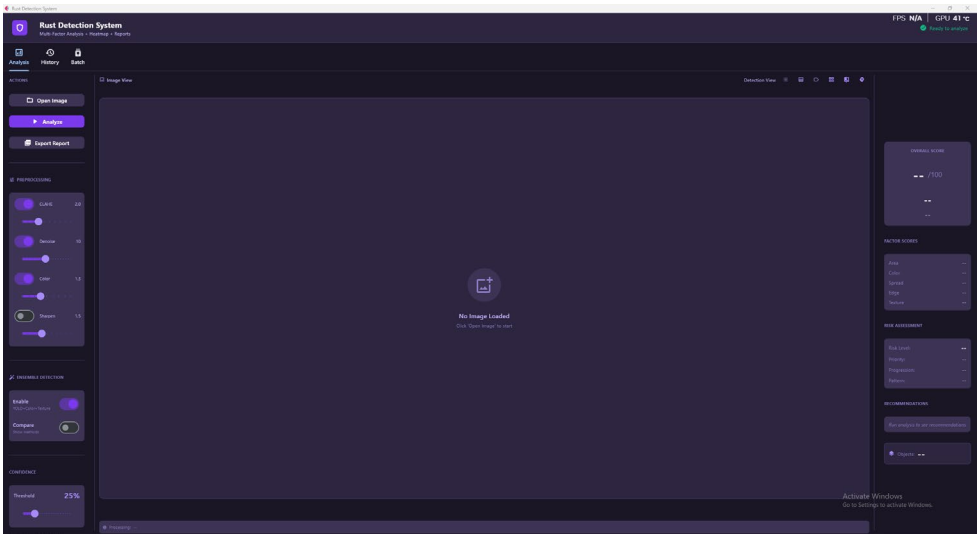

รูปที่ 4.7.1 หน้าจอหลักของแอปพลิเคชัน RustVision AI แสดงส่วนประกอบ 3 ส่วน ได้แก่ แถบเครื่องมือด้านซ้าย พื้นที่แสดงภาพตรงกลาง และผลการวิเคราะห์ด้านขวา

4.7.2 ผลการตรวจจับ

4.7.2.1 ผลการตรวจจับสนิมในโหมด Detection View แสดง Segmentation Mask

รูปที่ 4.7.2.1 ผลการตรวจจับสนิมในโหมด Detection View แสดง Segmentation Mask ซ้อนทับบนภาพต้นฉบับของโครงสร้างเหล็ก

4.7.2.2 ผลการแสดงผลในโหมด Heatmap View แสดงการกระจายตัวของสนิม

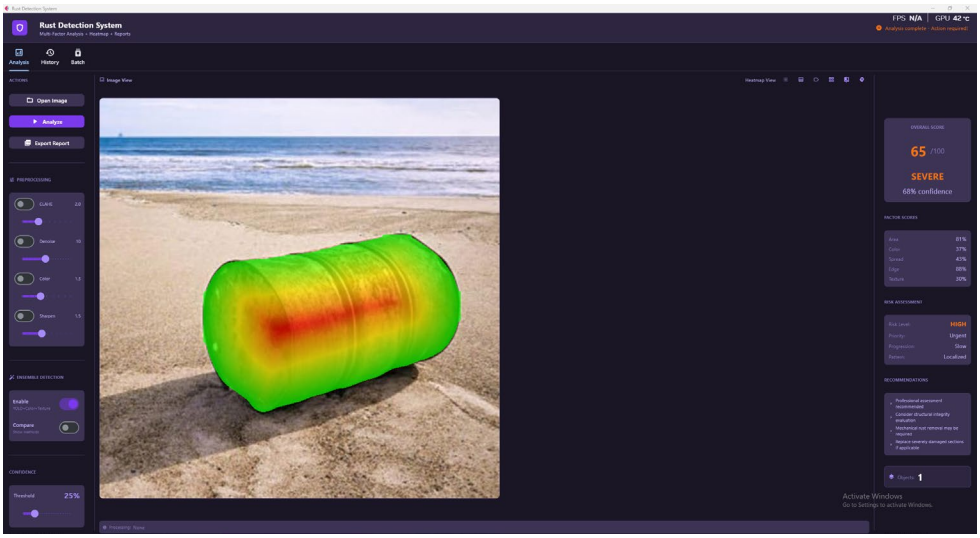

รูปที่ 4.7.2.2 ผลการแสดงผลในโหมด Heatmap View แสดงการกระจายตัวของสนิม ด้วยโทนสีจากเขียว (ไม่มีสนิม) ไปจนถึงแดง (สนิมหนาแน่น)

4.7.2.3 ผลการแสดงผลในโหมด Labeled View แสดงเส้นขอบและป้ายกำกับ

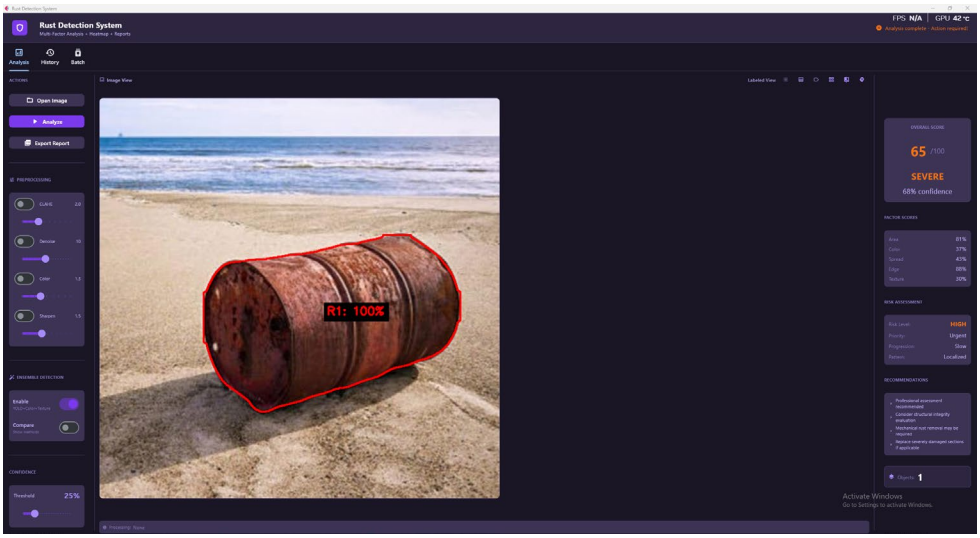

รูปที่ 4.7.2.3 ผลการแสดงผลในโหมด Labeled View แสดงเส้นขอบและป้ายกำกับของแต่ละกลุ่มสนิมพร้อมระบุขนาดพื้นที่

4.7.2.4 ผลการแสดงผลในโหมด Grad-CAM View แสดงพื้นที่ที่โมเดล

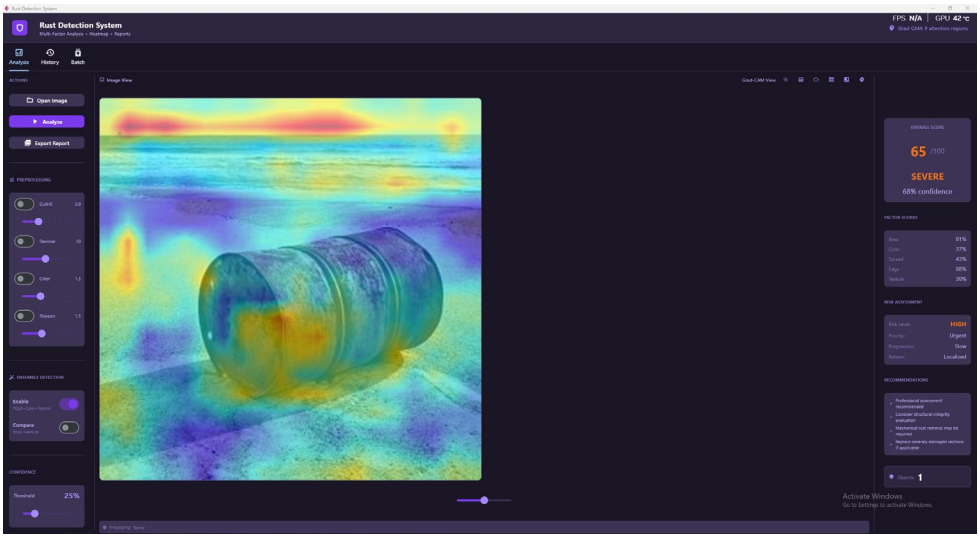

รูปที่ 4.7.2.4 ผลการแสดงผลในโหมด Grad-CAM View แสดงพื้นที่ที่โมเดลให้ความสนใจสูงสุดด้วยโทนสีแดง-เหลือง

4.8 สรุปผลรวมประสิทธิภาพ

ตารางที่ 4.5 สรุปผลเปรียบเทียบประสิทธิภาพทั้งสองโมเดล

ตัวชี้วัด	YOLOv26m-seg (Mask)	Roboflow 3.0 (Fast)	YOLOv26m-seg ดีกว่า
Precision	0.783	0.700	+11.8%
Recall	0.744	0.650	+14.5%
F1-Score	0.763	0.674	+13.2%
mAP@50	0.826	0.600	+37.7%
mAP@50-95	0.577	0.350	+64.9%
จำนวน Epochs	50	300	น้อยกว่า 6 เท่า

บทที่ 5

สรุปผล อภิปรายผล และข้อเสนอแนะ

บทนี้จะกล่าวถึงการสรุปผลการวิจัย อภิปรายผล และข้อเสนอแนะจากการพัฒนาระบบตรวจจับสนิม (Rust Detection System) ด้วยเทคนิคการเรียนรู้เชิงลึก โดยใช้โมเดล YOLOv26m-seg เปรียบเทียบกับโมเดล Roboflow 3.0 (Fast) ตามวัตถุประสงค์ของการวิจัย

5.1 สรุปผลการวิจัย (Conclusion)

จากการดำเนินงานวิจัยและทดสอบประสิทธิภาพของระบบตรวจจับสนิม สามารถสรุปผลได้ดังนี้

1. ประสิทธิภาพของโมเดล YOLOv26m-seg: โมเดลที่พัฒนาขึ้นสามารถตรวจจับและจำแนกตำแหน่งของสนิมได้อย่างมีประสิทธิภาพ โดยมีค่าความแม่นยำเฉลี่ย (mAP@50) ของ Mask Segmentation อยู่ที่ 0.826 และค่า mAP@50-95 อยู่ที่ 0.577 ค่าความแม่นยำ (Precision) อยู่ที่ 0.783 และค่าความรำลึก (Recall) อยู่ที่ 0.744 ซึ่งถือว่าอยู่ในเกณฑ์ที่ดีและสามารถนำไปใช้งานจริงได้
2. การเปรียบเทียบกับโมเดล Roboflow 3.0 (Fast): เมื่อเปรียบเทียบกับโมเดล Roboflow 3.0 (Fast) พบว่าโมเดล YOLOv26m-seg มีประสิทธิภาพเหนือกว่าในทุกตัวชี้วัดสำคัญ โดยมีค่า mAP@50 สูงกว่า 37.7% และ mAP@50-95 สูงกว่าถึง 64.9% นอกจากนี้ยังใช้จำนวนรอบในการฝึกสอน (Epochs) น้อยกว่าถึง 6 เท่า (50 vs 300 Epochs) แสดงถึงประสิทธิภาพในการเรียนรู้ของสถาปัตยกรรมที่ดีกว่า
3. ความแม่นยำของการระบุขอบเขต (Segmentation Accuracy): ผลการวิเคราะห์เปรียบเทียบระหว่าง Box Detection และ Mask Segmentation แสดงให้เห็นว่าโมเดลสามารถระบุขอบเขตของสนิมได้แม่นยำใกล้เคียงกับการตีกรอบสี่เหลี่ยม โดยมีค่า F1-Score ต่างกันเพียง 0.7% ทำให้สามารถคำนวณพื้นที่ความเสียหายของสนิมได้ละเอียดและถูกต้องกว่าการใช้ Bounding Box เพียงอย่างเดียว

5.2 อภิปรายผล (Discussion)

จากผลการวิจัย สามารถอภิปรายประเด็นสำคัญได้ดังนี้

1. ความเหนือกว่าของสถาปัตยกรรม YOLOv26m-seg: ผลการทดลองยืนยันว่าสถาปัตยกรรม YOLOv26m-seg มีความเหมาะสมกับงานตรวจจับสนิมที่มีลักษณะรูปร่างไม่แน่นอน เนื่องจากการออกแบบโครงสร้าง Feature Pyramid Network (FPN) และ Path Aggregation Network (PAN) ที่ช่วยในการรวมฟีเจอร์จากหลายระดับความละเอียด ทำให้สามารถตรวจจับสนิมได้ทั้งขนาดเล็กและขนาดใหญ่ ซึ่งต่างจาก Roboflow 3.0 (Fast) ที่อาจมีข้อจำกัดในการตรวจจับวัตถุที่มีความซับซ้อนของพื้นผิว
2. บทบาทของเทคนิค Data Augmentation: การใช้เทคนิคเพิ่มขยายข้อมูลแบบ Mosaic และ Mixup ระหว่างการฝึกสอน ช่วยให้โมเดลเรียนรู้ที่จะจำแนกสนิมในสภาพแวดล้อมที่หลากหลาย และลดปัญหา Overfitting เห็นได้จากกราฟ Loss ที่ลดลงอย่างต่อเนื่องและกราฟ mAP ที่เพิ่มขึ้นและคงที่ สิ่งนี้ช่วยแก้ปัญหาความไม่สมดุลของข้อมูลและทำให้โมเดลทนทานต่อ noise ในภาพได้ดีขึ้น
3. ความสมดุลระหว่าง Precision และ Recall: จากการวิเคราะห์ F1-Confidence Curve พบว่าค่า Confidence Threshold ที่เหมาะสมที่สุดอยู่ในช่วง 0.35–0.40 ซึ่งให้ค่า F1-Score สูงสุด การเลือกใช้ค่า Threshold ในช่วงนี้จะช่วยให้ระบบมีความสมดุลระหว่างการตรวจจับสนิมได้ครบถ้วน (High Recall) และมีความถูกต้องแม่นยำ (High Precision) ซึ่งเป็นสิ่งสำคัญในงานตรวจสอบโครงสร้างที่ต้องการความปลอดภัยสูง
4. ข้อจำกัดของงานวิจัย: แม้ว่าโมเดลจะมีประสิทธิภาพสูง แต่ยังพบข้อจำกัดบางประการ\
5. False Positive ในพื้นที่คล้ายสนิม: โมเดลอาจมีความผิดพลาดในการจำแนกพื้นผิวที่มีสีแดงหรือน้ำตาลคล้ายสนิม เช่น คราบดินแดงหรือสีทาพื้นผิวที่เสื่อมสภาพ
7. ประสิทธิภาพในที่แสงน้อย: การตรวจจับในสภาพแสงน้อยหรือแสงสะท้อนรุนแรงยังทำได้ไม่เต็มประสิทธิภาพเท่าที่ควร เนื่องจากชุดข้อมูลภาพส่วนใหญ่ถ่ายในสภาพแสงปกติ

8. ความซับซ้อนของการคำนวณ: แม้โมเดล YOLOv26m-seg จะมีความเร็วสูง แต่การทำ Instance Segmentation ยังใช้ทรัพยากรการคำนวณมากกว่า Object Detection ทั่วไป ซึ่งอาจเป็นข้อจำกัดเมื่อนำไปใช้งานบนอุปกรณ์ขนาดเล็ก (Edge Devices) ที่มีทรัพยากรจำกัด

5.3 ข้อเสนอแนะ (Recommendations)

5.3.1 ข้อเสนอแนะในการนำไปใช้งาน (Recommendations for Application)

1. การติดตั้งใช้งานจริง: ควรมีการปรับเทียบค่า Confidence Threshold ให้เหมาะสมกับหน้างานจริง หากต้องการเน้นความปลอดภัยสูงสุด (ไม่ให้พลาดจุดสนิมเลย) อาจปรับลด Threshold ลงเล็กน้อยเพื่อเพิ่มค่า Recall แม้จะแลกมาด้วย False Positive บ้าง
2. การประมวลผลร่วมกับโดรน: ระบบนี้สามารถนำไปติดตั้งบนโดรนเพื่อตรวจสอบโครงสร้างสูงหรือพื้นที่เข้าถึงยาก โดยอาจใช้ร่วมกับบอร์ดประมวลผลประสิทธิภาพสูง เช่น NVIDIA Jetson เพื่อให้สามารถประมวลผลภาพแบบ Real-time ได้
3. แอปพลิเคชันสำหรับวิศวกรภาคสนาม: พัฒนา Mobile Application ที่เชื่อมต่อกับโมเดลเพื่อให้วิศวกรสามารถถ่ายภาพและได้รับผลวิเคราะห์ความรุนแรงของสนิมได้ทันทีที่หน้างาน ช่วยลดเวลาในการทำรายงานและประเมินความเสียหาย

5.3.2 ข้อเสนอแนะสำหรับการวิจัยในอนาคต (Recommendations for Future Research)

1. การขยายชุดข้อมูล: ควรเพิ่มความหลากหลายของชุดข้อมูลภาพ โดยเฉพาะภาพในสภาพแสงต่างๆ (เช้า, เย็น, กลางคืนพร้อมไฟส่องสว่าง) และภาพพื้นผิวโลหะที่มีคราบสกปรกชนิดอื่น เพื่อลด False Positive
2. การพัฒนาโมเดล Hybrid: ศึกษาความเป็นไปได้ในการนำเทคนิคอื่นมาผสมผสาน เช่น การใช้ Transformer-based models เพื่อเพิ่มความแม่นยำในการระบุขอบเขตสนิมที่ซับซ้อน หรือการใช้เทคนิค Knowledge Distillation เพื่อลดขนาดโมเดลให้เหมาะกับ Edge Devices มากขึ้นโดยไม่สูญเสียความแม่นยำ
3. การจำแนกประเภทสนิมที่ละเอียดขึ้น: พัฒนาให้โมเดลสามารถระบุประเภทของสนิมได้ละเอียดขึ้น (เช่น Surface Rust, Pitting Corrosion, Crevice Corrosion) ซึ่งจะช่วยให้วิศวกรวางแผนการซ่อมบำรุงได้ดียิ่งขึ้น